



INSTITUT FÜR INFORMATIK  
AG TECHNISCHE INFORMATIK

*Masterarbeit*

# Integration von Schleifenschlüssen in HATSDF-SLAM

Patrick Hoffmann

November 2022

Erstgutachter: Prof. Dr. Mario Porrmann  
Zweitgutachter: Alexander Mock, M. Sc.



## Zusammenfassung

Die vorliegenden Arbeit liefert eine Lösung zum Schleifenschluss-Problem in einem *Truncated Signed Distance Field (TSDF)* basiertem *Simultaneaous Localization and Mapping (SLAM)* Ansatz. Beschrieben ist die Konzeption und Algorithmik für eine Detektion von Schleifenschlüssen und die anschließende, mehrschrittige Validierung über im Rahmen der Arbeit entwickelte Validatoren, die fehlerhafte Schleifenschlüsse aussortierten und so für eine robustere Optimierung des Pose-Graphen sorgen. Darüber hinaus sind mehrere in der Arbeit entwickelte Strategien zum Update der volumetrischen TSDF-Kartenrepräsentation dargelegt. Dabei handelt es sich um ein globales Update der Karte und zwei darauf basierte, partielle Kartenupdates, die eine deutliche laufzeittechnische Optimierung gegenüber dem globalen Update ermöglichen.

## Abstract

The present thesis provides a solution to the loop closure problem in a *Truncated Signed Distance Field (TSDF)* based *Simultaneaous Localization and Mapping (SLAM)* approach. Described is the design and algorithm for a loop closure detection and subsequent multi-step validation via validators developed as part of the thesis, which sorted out erroneous loop closures to provide more robust optimization of the pose graph. In addition, several strategies developed in the work are outlined for updating the volumetric TSDF map representation. These are a global update of the map and two partial map updates based upon it, which provide significant runtime optimization over the global update.



# Inhaltsverzeichnis

<b>1 Einleitung</b>	<b>1</b>
1.1 Motivation . . . . .	2
1.2 Herangehensweise . . . . .	3
1.2.1 Fallback . . . . .	3
<b>2 Stand der Forschung</b>	<b>5</b>
<b>3 Konzeptuelle Grundlagen und verwendete Datenstrukturen</b>	<b>11</b>
3.1 Konzeptuelle Grundlagen . . . . .	11
3.1.1 Die unterliegende Datenstruktur des Pose-Graphen . . . . .	11
3.1.2 Koordinatensysteme . . . . .	11
3.2 TSDF . . . . .	14
3.2.1 TSDF-Karte . . . . .	16
3.2.2 TSDF-Update . . . . .	18
3.3 SLAM . . . . .	20
<b>4 Identifikation von Datenassoziationen zum Karten-Update</b>	<b>23</b>
4.1 Ansatz . . . . .	23
4.2 Serialisierung der Datenassoziationen . . . . .	24
4.3 Detektions-Algorithmen . . . . .	24
4.3.1 Ray-Tracing . . . . .	24
4.3.2 Bresenham . . . . .	28
4.3.3 Ergebnisse der Algorithmen . . . . .	32
4.3.4 Evaluation . . . . .	33
4.4 Schleifenschlüsse in der Nachbearbeitung . . . . .	34
4.5 Karten-Update mittels generierter Assoziationen . . . . .	37
4.6 Evaluation und Zusammenfassung . . . . .	39
<b>5 Schleifenschlüsse und Graph-Optimierung</b>	<b>41</b>
5.1 Detektion von Schleifenschlüssen . . . . .	41
5.2 Optimierung des Pose-Graphen . . . . .	47
5.3 Evaluation der Graph-Optimierung . . . . .	48
5.3.1 Datensatz: Hannover-1 . . . . .	50

5.3.2	Datensatz: Chemnitzer Opernhaus . . . . .	52
5.3.3	Datensatz: Campus Universität Osnabrück . . . . .	54
5.4	Kapitel-Zusammenfassung . . . . .	54
<b>6</b>	<b>Karten-Update Strategien</b>	<b>57</b>
6.1	Globales Update der Karte . . . . .	58
6.2	Partielles Update der Karte . . . . .	59
6.3	Evaluation der Update-Strategien . . . . .	62
6.4	Kapitel-Zusammenfassung . . . . .	62
<b>7</b>	<b>Zusammenfassung und Ausblick</b>	<b>67</b>
7.1	Zusammenfassung . . . . .	67
7.2	Ausblick . . . . .	69
7.2.1	Optimierungen des vorgestellten Ansatzes . . . . .	71
<b>A</b>	<b>Anhang</b>	<b>73</b>

# Kapitel 1

## Einleitung

Diese Arbeit beschäftigt sich mit der Konzeption und Implementation einer Lösung zum *Loop Closure (Schleifenschluss)*-Problem in *Truncated Signed Distance Fields* (TSDF) basiertem *Simultaneous Localization and Mapping* (SLAM). Diese Arbeit setzt auf den Konzepten von Eisoldt et al. [16] auf, die einen TSDF basierten, hardware-beschleunigten SLAM Ansatz (*HATSDF-SLAM*) entwickelt und dessen Effizienz und Funktionalität verifiziert haben.

Unter SLAM versteht man den Prozess der Erstellung einer Karte einer unbekannten Umgebung, bei gleichzeitiger Positionsbestimmung innerhalb der erstellten Karte. Das SLAM Problem ist ein *Henne-Ei-Problem*, da eine vollständige Karte benötigt wird, um die Pose eines Roboters akkurat bestimmen zu können, während auf der anderen Seite eine akkurate Pose benötigt wird, um eine vollständige Karte aufbauen zu können. Für die Lösung dieses Problems gibt es sowohl in 2-D als auch 3-D verschiedene Lösungsansätze, die in Kapitel 2 grob eruiert werden. Diese Arbeit beschränkt sich auf 6-D SLAM. Unter einem Schleifenschluss versteht man in der mobilen Robotik das Problem, geschlossene Kreise in abgelaufen Pfaden durch die im SLAM-Prozess erschlossene, zunächst unbekannte Umgebung, zu identifizieren. Nach der Identifikation einer Schleife zwischen zwei Posen  $P_i$  und  $P_j$  wird die approximative Transformation  $T_{i \rightarrow j}$  bestimmt und mit der Transformation  $T_{i \rightarrow j}^{graph}$  verglichen, die aus derzeitigen Posegraphen hervorgeht. Die Differenz zwischen diesen Transformation  $T_{error}$  wird näherungsweise als der Fehler angesehen, der sich beim SLAM zwischen den Posen  $P_i$  und  $P_j$  akkumuliert hat. In einem Optimierungsschritt wird der Fehler  $T_{error}$  durch eine Anpassung des Pose-Teilgraphen zwischen  $P_i$  und  $P_j$  kompensiert. Dies sorgt für eine konsistenteren Pfad und damit verbunden für eine akkurate Karte. Als Basis für die Lösung dieses Problems dient der Ansatz von Lu und Milios [27], die ein Netzwerk aus 2-D-Poserelationen erstellen, das sowohl Relationen enthalte, die aus dem Scan-Matching abstammen, als auch Relationen aus Odometrie Messungen enthalte [27]. Borrmann et al. [6] erweitern den Ansatz von [27] auf drei Dimensionen und erstellen einen Pose-Graphen zur Speicherung von Pose-Relationen. Zur Registrierung aufeinanderfolgender Datenscans verwenden Borrmann et al. [6] den *Pairwise Iterative Closest Point Algorithm* (Pairwise ICP). Zur Detektion eines Schleifenschlusses wird eine einfache Distanz-Heuristik verwendet. Shang et al. [40] beschreiben eine vergleichbare Heuristik zur Identifikation von Schleifenschlüssen. Der gewählte Ansatz

verwende eine naive, aber effektive Heuristik, die auf der euklidischen Distanz zwischen den Posen des Graphen basiert. Posen, deren euklidische Distanz zur aktuell betrachteten Pose geringer ist als eine festgelegte Schwelle, werden als Kandidaten angesehen. Jeder dieser Kandidaten werde über ein Scan-Matching der zugehörigen Punktwolken und der Evaluation des Ergebnisses des Scan-Matching validiert [40]. [40] verwendet einen Faktor-Graphen zur Speicherung der Pose-Relationen. Hierfür wird die Implementation des Faktor-Graphen von *GTSAM* [14] verwendet, der ebenfalls in dieser Arbeit zur Speicherung und Optimierung der Pose-Relationen verwendet wird. Wichtige Voraussetzung für die Optimierung der Posen im Graphen ist eine Assoziation der Posen mit den zugehörigen Umgebungsdaten. Im Falle von Borrmann et al. [6] sind dies jeweils die zum Zeitpunkt aufgenommenen Punktwolken. [40] sorgt durch die Selektion von *Key-Frames* für einen spärlich besetzten Faktor-Graphen und sorge so für eine Ausgeglichenheit zwischen Speicherbedarf und der Dichte der Karte. Die Menge der Key-Frames ist eine Untermenge der gesamten Lidar-Frames die bei der Kartierung aufgenommen wurden. Ein Frame wird als Key-Frame genutzt, wenn zum zuletzt gewählten Key-Frame eine festgelegte Schwelle für die Translation oder Rotation überschritten wird. Diese Assoziation ist bei TSDF basiertem-SLAM, das eine diskretisierte TSDF-Karte verwendet, nicht explizit möglich, solange nicht zusätzlich die entsprechenden Punktdaten abgespeichert werden. Wird ein Schleifenschluss detektiert, muss dann die gesamte Karte auf Basis der abgespeicherten Punktdaten neu erstellt werden. Dies ist speicher- und zeitaufwändig. Dieses Problem markiert den Hauptbeitrag dieser Arbeit. Es gilt zu untersuchen, welcher Teil der TSDF Karte mit welcher Pose im Graph assoziiert werden kann, um anschließend die bereits existierende Karte zu modifizieren und zu optimieren. Dieses Problem wird im Folgenden untersucht und verschiedene Herangehensweisen werden eruiert.

## 1.1 Motivation

Ziel dieser Arbeit ist die Lösung des Schleifenschluss Problems für TSDF basierte SLAM Verfahren. Als Basis dient der Ansatz von Eislodt et al. [16], der – obgleich performant und funktional – wie die meisten SLAM Verfahren bei der Kartierung großer Umgebungen stark anfällig für Drift ist. Um diesem Problem entgegen zu wirken, soll durch die Integration von Schleifenschlüssen in TSDF-Karten die Kartierung größerer Umgebungen ermöglicht werden. Um dieses Ziel zu erreichen, soll in einem ersten Ansatz untersucht werden, ob eine bereits generierte Karte mit bekannter Posehistorie durch die Integration von Schleifenschlüssen zur Optimierung der Trajektorie verbessert werden kann. Es gilt zu untersuchen, welche Voraussetzungen für eine solche Optimierung gegeben sein müssen und ob diese Voraussetzungen in diesem ersten Szenario erfüllt werden können. Auf Basis dieser Untersuchung soll eine Einschätzung zur Nutzung von Schleifenschlüssen in einem TSDF basierten SLAM Ansatz als Nachbehandlungs-/Post-Processing-Schritt geben werden. Diese Einschätzung markiert einen wesentlichen Meilenstein dieser Arbeit, bei dem entschieden wird das beschriebene Szenario weiter zu verfolgen, oder eine Integration in einen SLAM Ansatz anzustreben und zur Laufzeit Optimierungen an der Trajektorie und Karte basierend auf identifizierten Schleifenschlüssen vorzunehmen.

Grundlegende Voraussetzung für die Optimierung von Pfad und Karte ist eine Assoziation zwischen den einzelnen Posen des Pfades mit den jeweiligen zugehörigen Umgebungsdaten. Erstes Ziel des genannten ersten Szenarios ist dementsprechend die Ermittlung von Datenassoziationen zwischen

den Posen und den zugehörigen Teilen der diskretisierten TSDF-Karte. Diese Assoziationen dienen als Ersatz zu den von von Borrmann et al. [6] und Shang et al. [40] genutzten vorgefilterten Punktwolken beziehungsweise *Key-Frames*, die mit den zugehörigen Posen assoziiert werden. In einer ersten Implementation soll dazu mittels Ray-Tracing eines simulierten Laserscans und der Detektion von Schnittpunkten mit der TSDF-Karte eine passende Indizierung und Zuordnung der Zellen ermöglicht werden. Kapitel 4 erörtert und evaluiert diesen Ansatz, beschreibt mögliche Probleme und Fallstricke und definiert, wie im weiteren Verlauf der Arbeit vorgegangen wird.

Diese Arbeit soll als Proof-of-Concept für weitere Arbeiten auf diesem Gebiet dienen und Herausforderungen und Fallstricke aufzeigen. Es soll geklärt werden wie und auf welche Weise Schleifenschlüsse in einen TSDF basierten SLAM-Ansatz integriert werden können, ob eine Nachbehandlung möglich ist, sowie ob und wie ein partielles Update der Karte möglich ist. In einem Ausblick gilt es zu analysieren, ob die Implementierungen sinnvoll beschleunigt werden können, um sie in ein Live Karierungssystem, wie HATSDF-Slam einbauen zu können, um zur Laufzeit Schleifen zu erkennen und die Karte zu optimieren. Die Implementation dieses Prototyps wird ausschließlich in Software realisiert, allerdings erfolgt eine Untersuchung des Software-Prototyps auf Potenziale zur Hardware-Beschleunigung um Raum für Optimierungen im Rahmen zukünftiger Arbeiten zu eröffnen.

Nachfolgender Abschnitt nimmt erneut Bezug auf den gegebenen Ansatz, stellt die Offenheit des Themas heraus und definiert mögliche Fallbacks zum Post-Processing Szenario auf Basis der ermittelten Datenassoziationen.

## 1.2 Herangehensweise

Wie in der vorigem Absatz definiert ist, ist das genaue Ziel dieser Arbeit offen, da die Ermittlung von Datenassoziationen aus einer generierten TSDF Map, um diese für Schleifenschlüsse zu verwenden, ein rein experimenteller Ansatz ist. Hier gilt es herauszustellen ob dieser Ansatz erfolgreich ist oder – im anderen Fall – Hürden und Probleme aufzuzeigen, sowie mögliche Lösungsansätze für zukünftige Arbeiten zu skizzieren, die nicht in den Zeitrahmen dieser Arbeit passen. Das grundlegende Ziel der Integration von Schleifenschlüssen allerdings bleibt. Zunächst werden in Kapitel ?? Lösungsansätze dokumentiert, mit deren Hilfe Datenassoziationen zwischen der TSDF-Karte und der Posehistorie generiert werden können. Dies wird evaluiert und die weitere Vorgehensweise diskutiert.

Folgender Abschnitt definiert mögliche Fallbacks zur Generation von Datenassoziationen aus dem TSDF und alternative Möglichkeiten zum (partiellen) Update der TSDF Karte.

### 1.2.1 Fallback

Sollte sich im Laufe dieser Arbeit herausstellen, dass die Generation von Datenassoziationen und das Update der TSDF Karte auf Basis dieser Assoziationen entweder nicht möglich ist oder Lösungsansätze nicht mit dem zeitlichen Rahmen dieser Arbeit vereinbar sind, sollen alternative Möglichkeiten zum Update der Karte definiert und entwickelt werden. Zunächst wird dabei ein globales Update der gesamten TSDF Karte auf Basis der zu den Posen gehörigen Punktwolken

angestrebt. Dieses soll zusätzlich um ein partielles Update der betroffenen Kartenbereiche erweitert werden. In diesem Fall wird in einem Ausblick zusätzlich Bezug zu zukünftigen Arbeiten und Lösungsmöglichkeiten für die Generation und Nutzung von TSDF-Pose-Datenassoziationen genommen werden.

## Kapitel 2

# Stand der Forschung

Dieses Kapitel untersucht den aktuellen Stand der Forschung und gibt einen Überblick über das Forschungsgebiet. Dazu wird zunächst im Grundsatz auf das Thema *SLAM*, sowie auf das Thema Schleifenschlüsse eingegangen. Im Anschluss erfolgt eine Spezifizierung auf TSDF basierte SLAM-Verfahren, sowie die Ursprünge der TSDF. Der Fokus liegt hier auf der TSDF und den Forschungsbereich der TSDF-basierten Verfahren, die in den kontextuellen Rahmen dieser Arbeit passen. Diese Verfahren sind im Abschnitt *TSDF* dargelegt.

### SLAM

Dieser Abschnitt stellt im Groben den Stand der Forschung des SLAM-Problems heraus. *Simultaneous Localization and Mapping (SLAM)* ist eines der größten Forschungsgebiete in der mobilen Robotik [9] und beschreibt den Prozess der Lokalisierung in einer Karte auf Basis ankommender Sensordaten bei einer gleichzeitigen Generation dieser Karte. Die Forschungen zu diesem Problem reichen zurück bis vor die Jahrtausendwende. SLAM besteht aus einer Lokalisations- und einer Kartierungskomponente, die aufeinander aufbauen, aber getrennt voneinander betrachtet werden können. Verschiedene Lokalisierungsansätze auf Basis von Scan-Matching-Ansätzen wie *Iterative Closest Point (ICP)* nach Besl & McKay [5], *Normal ICP (NICP)* [11] oder *Generalized ICP (GICP)* [38] werden in der Praxis verwendet ([22, 40]). Diese Algorithmen benötigen dabei in der Regel eine gute initiale Pose-Schätzung [20]. Andere Ansätze nutzen statistische Modelle zur Lokalisierung. So verwenden Montemerlo [31, 32] einen Partikelfilter um statistisch abschätzen zu können, welche Pose ein Roboter oder Sensorsystem derzeit annimmt. Im Bereich der Kartierung wird in der Regel zwischen expliziten und impliziten Darstellungen der Oberfläche abgetasteter Objekte unterschieden. Explizite Darstellungen können zum Beispiel aus einer Ansammlung inkrementell registrierter Punktwolken bestehen [22], wobei in vielen dieser Ansätze nicht jede Punktwolke, sondern nur sogenannte *Key-Frames* genutzt werden [40]. Eine Punktwolke gilt als Key-Frame, wenn die Distanz die zugehörigen Pose zur Pose des letzten Key-Frames größer ist, als eine vordefinierte Distanz [40]. Wesentlicher Faktor für die Robustheit von SLAM Ansätzen ist die Integration von Schleifenschüssen. Im Folgenden wird ein grober Überblick über dieses Thema geliefert. Implizite Darstellungen beschreiben den Raum um die abgetastete Oberfläche herum und ermöglichen eine Kontinuität, die durch eine Beschreibung der Oberfläche mit Punktdaten

nicht erreicht werden kann [13]. Dazu gehören zum Beispiel vorzeichenbehaftete Distanzfelder oder Distanzfunktionen, deren Ursprung und Forschungsstand in Kapitel *TSDF* näher behandelt wird.

Die Forschung im Bereich SLAM hat sich in verschiedene Richtungen entwickelt, die auf unterschiedlichen Grundlagen oder Annahmen über vorhandene oder ermittelte Daten arbeiten. Dissanayake et al. [15] schlagen einen SLAM Ansatz basierend auf Landmarken und einem *Erweiterten Kalman Filter (EKF)* vor. Andere Ansätze extrahieren Features aus Punktwolken und nutzen diese für einen anschließenden Datenvergleich zur Bestimmung der vorliegenden Pose-Differenz. Dazu gehören zum Beispiel die Arbeiten von Zhang & Singh [48] oder Shang & Englot [39]. Wiederum andere Ansätze nutzen eine gesonderte Betrachtung einer *Inertial Measurement Unit (IMU)*, um eine optimierte initiale Schätzung der vorliegenden Pose-Differenz zu erreichen. Um sich innerhalb dieser Forschungsgebiete zurechtzufinden, existieren diverse Arbeiten, die eine umfangreiche und detaillierte Beschreibung verschiedener SLAM-Ansätze angefertigt haben [1, 9, 42].

### Schleifenschlüsse

Um genannte SLAM-Ansätze robust gegenüber einer Akkumulation von Fehlern zu machen, die häufig in dieser Kategorie von Algorithmen auftreten, werden Schleifenschlüsse verwendet, anhand derer die Fehler nachträglich korrigiert werden können. Grundidee ist dabei anhand der gerade aufgenommenen Sensordaten zu beurteilen, ob diese zu bereits im Vorfeld aufgenommenen Daten passt und darauf basierend die erstellte Karte oder den generierten Pose-Graphen zu optimieren. Für diese Einschätzung existieren mehrere Varianten unterschiedlicher Komplexität, jeweils basierend auf der Bestimmung von Kandidaten und deren anschließenden Verifikation. Im Folgenden wird ein Überblick über das Thema der Wiedererkennung von Orten beziehungsweise Schleifenschlüsse gegeben, welches in der Literatur häufig als *Loop-Closure*, *Place-Recognition* oder *Revisiting-Problem* bezeichnet wird, wobei die genannten Bezeichnungen nicht dasselbe Thema bezeichnen, sondern lediglich eng miteinander verwandt sind. Garg et al. [18] liefern einen breiten Überblick über die Unterschiede zwischen der visuellen *Place-Recognition* in der Robotik und der Computergrafik. Der im Folgenden dargelegte Überblick über Schleifenschlüsse in der Robotik deckt bei Weitem nicht den Umfang der Forschungen in diesem Bereich ab.

Frühe Forschungen in diesem Bereich stammen von Lu & Milios [27], die einen Ansatz zur konsistenten, globalen Registrierung von 2-D Reichweiten-Scans vorschlagen. Dazu nutzen sie ein Netzwerks aus relativen Pose-Beschränkungen, die durch die Implementation eines Scan-Matching Ansatzes und Odometrie ermittelt werden, welches mit einem globalen Ansatz optimiert wird. Zu diesen Beschränkungen zählen auch ermittelte Schleifenschlüssen. Ho & Newman [21] stellen heraus, dass bei herkömmlichen Verfahren zur Identifikation von Schleifenschlüssen eine Initialschätzung notwendig ist und schlechte Schätzungen zu fehlerhaften Schleifenschlüssen führen können. Sie schlagen stattdessen ein Verfahren vor, welches unabhängig von der Navigation und einer damit verbundenen initialen Poseschätzung ist und sich auf den Abgleich charakteristischer Signaturen einzelner lokaler Szenen beziehungsweise Scans zur Detektion von Schleifenschlüssen stützt. Borrman et al. [6] schufen in ihrer Arbeit eine gute Grundlage für die Integration von Schleifenschlüssen in SLAM-Verfahren auf Basis von Pose-Graphen, die bis heute vielfach verwendet wird. Darauf aufbauend optimieren Sprickerhof et al. [41] den Schleifenschluss-Ansatz

durch Nutzung einer heuristischen Schleifenschluss-Technik, die im Gegensatz zu bisherigen Methoden einen dünn besetzten SLAM-Graphen nutzen und vergleichbare Ergebnisse bei einer reduzierten Laufzeit erzielen. In [26] stellen eine umfangreiche Forschung zur visuellen *Place-Recognition* im Robotik-Kontext dar. Xie et al. [46], sowie Tsintotas et al. [43] stellen die Notwendigkeit von weiteren Validierungsstufen für Schleifenschlüsse heraus um die Anzahl fehlerhafter Schleifenschlüsse und deren verhängnisvolle Auswirkungen auf die Optimierung eines Pose-Graphen zu reduzieren. Ähnlich wie [6] nutzen Shan et al. [40] in ihrem Feature-basierten SLAM Ansatz die euklidische Distanz zur Bestimmung von Kandidaten für Schleifenschlüsse, die durch eine Evaluation des *Fitness-Scores* von ICP nach Registrierung der zugehörigen Punktwolken der beiden Posen der jeweiligen Kandidaten verifiziert werden. Zur Optimierung des Pose-Graphen, basierend auf den so identifizierten Schleifenschlüssen, verwendet [40] die Bibliothek GTSAM [14] und deren Implementation eines Faktor-Graphen. GTSAM kapselt dabei die Funktionalität der Graph-Optimierung und ermöglicht so eine vereinfachte Optimierung basierend auf detektierten Schleifenschlüssen, die vielfach genutzt wird ([40]). Eine detaillierte Übersicht über existierende Verfahren zur Detektion von Schleifenschlüssen mit Bezug zu früheren Forschungen auf diesem Gebiet ist in dem Papier von Tsintotas et al. [43] dargelegt.

Im Folgenden wird eine Übersicht des Forschungsstands im Bereich der TSDF dargelegt mit besonderem Bezug auf TSDF-basierte SLAM Verfahren, die im vorigen Abschnitt nur grob angeschnitten wurden.

## TSDF

Die in dieser Arbeit entwickelten Algorithmen und Konzepte basieren oder zielen auf eine implizite, volumetrische Repräsentation der Umgebung eines Roboters oder Sensorsystems, die *Truncated Signed Distance Function (TSDF)*. Erste Forschungen in diesem Themengebiet stammen aus der Computergrafik, genauer der Rekonstruktion von Oberflächen aus räumlichen Daten. Hoppe et al. definieren und demonstrieren einen Algorithmus, der aus einer gegebenen Menge von unorganisierten Punkten  $\{x_1, \dots, x_n\} \in \mathbb{R}^3$  eine vereinfachte Oberfläche generiert. Dazu wird eine vorzeichenbehaftete geometrische Distanzfunktion verwendete, die Distanz zur unbekannten Oberfläche abschätzt. Ein solche Distanzfunktion wird ebenfalls von Bajaj et al. [2] die einen Ansatz zur Rekonstruktion der Oberfläche von (*Computer Aided Design (CAD)*) Modellen und deren skalaren Feldern auf Basis einer unorganisierten Sammlung von gescannten Punktdaten. Basierend auf diesen Forschungen stellen Curless & Levoy [13] eine volumetrische Methode zur Konstruktion komplexer Modelle auf Basis einer Reihe von *Range-Images*, die zum Beispiel durch Tiefenbildkameras oder *Light Detection and Ranging(Lidar)*-Sensoren generiert werden, vor. Sie basieren die Rekonstruktion der Oberfläche auf einer vorzeichenbehafteten Distanzfunktion *SDF*. Der vorgestellte Ansatz ermöglicht ein inkrementelles Update, die Repräsentation gerichteter Ungenauigkeit, sowie das Füllen von Lücken beziehungsweise Löchern in der SDF und ist robust gegen *Outlier* [13]. Zusätzlich ist der vorgestellte Ansatz unabhängig von der Reihenfolge, in der die Scans in die SDF eingefügt werden, wodurch kein Bias durch zuerst eingefügte Scans entsteht. Dieser Ansatz stellt die Basis für viele weitere Ansätze, die im Bereich der Rekonstruktion im Bereich der SDFs operieren. So präsentieren Breen et al. [7] einen Ansatz zur Generation eines Distanz-Volumens auf Basis von *Constructive Solid Geometry (CSG)* Modellen. Um die Probleme der zuvor genannten Ansätze mit Objekten veränderlichen Detailgrades zu lösen,

schlagen Frisken et al. [17] eine adaptives, vorzeichenbehaftetes Distanzfeld (*ADF*) vor, welches als eine generelle Repräsentation für Formen in der Computer-Grafik dienen soll, vor. Diese ist nach [17] vorteilhaft für räumliche Strukturen mit Features in sehr unterschiedlichen Maßstäben. In ADFs werden Abstandsfelder entsprechend der lokalen Details adaptiv abgetastet und in einer räumlichen Hierarchie für eine effiziente Verarbeitung gespeichert. Bastos & Celes optimieren den Ansatz aus [17] durch die Nutzung eines *Grafikprozessors (GPU)*. Um scharfe Details in TSDF repräsentieren zu können schlagen Novotny & Sramek [34] einen Ansatz vor, der die durch das TSDF repräsentierten Objekte nach dem Kriterium der Darstellbarkeit zu verändern. Zusätzlich werden Informationen über die Oberflächen-Normalen mit berücksichtigt. Jones et al. [23] stellen eine Übersicht über 3-D Distanzfelder vor und gehen dabei auf die verwendeten Techniken und Anwendungsbereiche ein. Sie stellen dabei unter anderem heraus, dass Methoden, die Distanzfelder nur bis zum einem festgelegten Maximalwert erzeugen, also die Charakteristiken einer TSDF aufweisen, in den Ausführungen von Mauch [29?] ihren Ursprung haben. Weitere Forschungen in diesem Themengebiet befassen sich zum Beispiel mit der Parallelisierung der volumetrischen Repräsentation. Werner et al. [44] evaluieren die Ergebnisse der Oberflächenrekonstruktion anhand von TSDF-Karten unter Berücksichtigung der Größe der Voxel und geben einige Empfehlungen für den Umgang mit TSDF.

Erste Forschungen mit TSDF basiertem SLAM stammen aus dem letzten Jahrzehnt. Izadi et al. [22] nutzen ein TSDF-Voxelgrid und eine Kinect-Tiefenkamera, um Umgebungen zu kartieren, während ein Nutzer die Kinect Kamera durch die Umgebung schwenkt. Dabei wird das aktuell betrachtete Tiefenbild der Kinect-Kamera jeweils in eine Punktwolke konvertiert und mittels ICP an die letzten Tiefenbilder registriert. Ergebnis der Registrierung ist eine 6-D Pose für die aktuelle Position der Kamera. Auf Basis der so erhaltenen Kameraposition erfolgt im Anschluss ein Update des volumetrischen Oberflächenrepräsentation, die ebenfalls auf den Ausführungen aus [13] basiert. Whelan et al. [45] optimieren diesen Ansatz durch Nutzung eines Ringbuffers zur Kartierung großer Umgebungen. Im Gegensatz zu diesen Verfahren stellt Canelhas [10] ein neues Verfahren zur Registrierung neuer Punktdaten an die TSDF-Karte vor: *Point-to-TSDF*. Dabei werden die Punktdaten mittels eines Gradientenabstiegs an das TSDF registriert. Ergebnis ist erneut eine 6-D-Pose, anhand derer das TSDF erweitert werden kann. Zusätzlich liefert Canelhas [10] einen Überblick über das Themengebiet der *TSDF*. Prisacariu et al. [35] unterteilen den 3D-Raum in starre TSDF-Teilkarten und optimieren die relativen Positionen zwischen diesen. Nach [35] ist eine anschließende Generation der globalen Karte durch ein Zusammenführen der Teilkarten möglich. [35] verwendet für jede Pose des Graphen eine eigene Teilkarte, die in sich konsistent ist. Sie erreichen eine globale Konsistenz durch eine Graph-Optimierung, die zusätzlich Schleifenschlüsse berücksichtigt. Optimierte werden die zu den Teilkarten zugehörigen Posen. Die TSDF-Teilkarten selbst werden durch die Graph-Optimierung nicht angepasst. In einem weiteren volumetrischen Ansatz von McCormac et al. [30] wird eine volumetrische, Objekt basierter SLAM Ansatz verwendet, der eine TSDF zur Repräsentation mehrerer Objekte verwendet. Dabei werden lediglich die relativen Pose-Schätzungen zwischen den Objekten verändert, aber keine Verformung der Objekte selbst durchgeführt. Eisoldt et al. [16] schlagen einen Hardwarebeschleunigten, TSDF-basierten SLAM Ansatz vor, der einen 3-D-Laserscanner anstelle einer Tiefenkamera nutzt. Eisoldt et. al [16] nutzen zur Registrierung neuer Punktwolken an die TSDF-Karte den von Canelhas [10] vorgeschlagenen *Point-to-TSDF* Ansatz, der die Distanzen

von Punkten einer neuen Punktewolke zur durch die TSDF implizit beschriebenen Oberfläche entlang des Gradienten innerhalb des TSDF minimiert. [16] implementiert keinen Ansatz zur Integration von Schleifenschlüssen und Graphoptimierung und ist dementsprechend anfällig für akkumulative Fehler. An dieser Stelle setzt diese Arbeit nun an und integriert auf Basis der zuvor genannten Ansätze, Schleifenschlüsse in einen TSDF basierten SLAM Ansatz und die TSDF Karte entsprechend der Änderungen an der Roboter-Trajektorie zu optimieren.



# Kapitel 3

## Konzeptuelle Grundlagen und verwendete Datenstrukturen

### 3.1 Konzeptuelle Grundlagen

Dieser Abschnitt beschreibt die wesentlichen konzeptuellen Grundlagen, die in dieser Arbeit an mehreren Stellen verwendet werden und daher an zentraler Stelle erläutert werden.

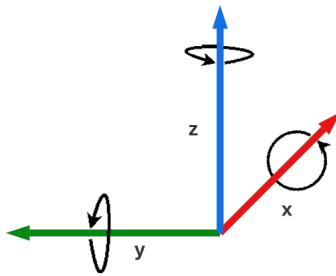
#### 3.1.1 Die unterliegende Datenstruktur des Pose-Graphen

Die Grundlage für den in dieser Arbeit vorgeschlagenen Ansatz bietet die Implementation einer Datenstruktur für den Pose-Graphen, im Folgenden auch Pose-Historie oder Pfad genannt. Die Datenstruktur ist dabei einfach aufgebaut. Sie hält einen indizierten Vektor aus Posen  $\{P_0, \dots, P_n\}$  und kapselt die Funktionalität für das Einfügen dieser Posen. Zusätzlich ist in der Datenstruktur die Funktionalität zur Identifikation von Schleifenschluss-Kandidaten gespeichert.

#### 3.1.2 Koordinatensysteme

Ein wesentliches Konzept bei der Verarbeitung räumlicher Daten ist die Verwendung von Koordinatensystemen. Sie werden genutzt um die Positionen von Daten und Objekten im Raum zu beschreiben. Koordinatensysteme können für sich alleine stehen oder relativ zu anderen Koordinatensystemen. Im Dreidimensionalen besitzt ein Koordinatensystem drei verschiedene Achsen (x, y und z-Achse), die jeweils im 90 Grad Winkel zueinander ausgerichtet sind. Rotationen im Raum werden beschrieben als Rotationen um die jeweiligen Achsen. Welche Achse in welche Richtung zeigt ist nicht eindeutig definiert. Es gibt jedoch verschiedene Standards beziehungsweise Konventionen wie das links- oder rechtshändische Koordinatensystem. In ROS wird konventionell ein rechtshändisches Koordinatensystem, abgebildet in Abbildung 3.1 dargestellt. Dies wird im Folgenden ebenfalls als Standard verwendet.

In der Robotik kommt es häufig vor, dass verschiedene (bewegliche) Komponenten relativ zu einem globalen Bezugssystem oder relativ zueinander beschrieben werden müssen. Die Bewegung



**Abbildung 3.1:** Schematische Darstellung der Konvention für Koordinatensysteme im ROS Framework. Die z-Achse zeigt nach oben, die x-Achse nach vorne und die y-Achse nach links. Die Rotation um die Achsen ist entsprechend der Konvention im Uhrzeigersinn.

eines übergeordneten Bezugssystems kann implizit für eine Veränderung der relativ zu diesem Bezugssystem platzierten Systeme führen. Dies lässt sich anhand eines Arm-Roboters zeigen, der mehrere miteinander verbundene Gelenke hat. Bewegt sich ein Gelenk werden automatisch auch die am Arm weiter außen befindlichen Gelenke mitbewegt. Aus Sicht des bewegten, übergordneten Bezugssystems hat sich die Position der untergeordneten Gelenke nicht verändert, aus Sicht des globalen Bezugssystems, wie zum Beispiel dem Montierungspunkt des Roboters, allerdings schon.

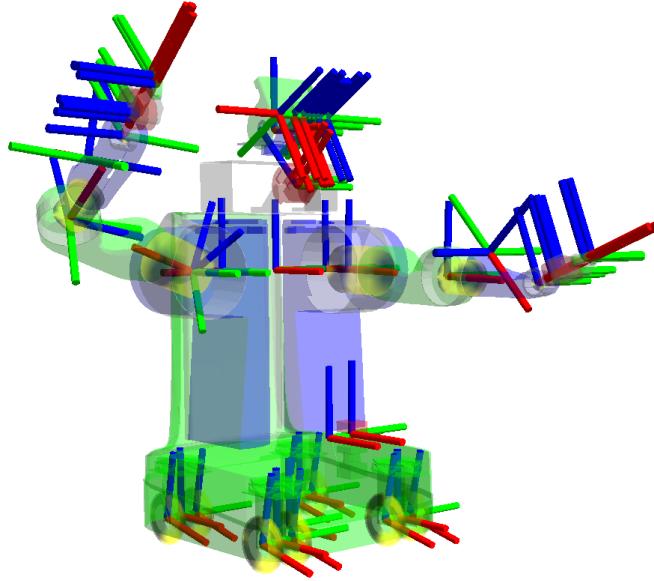
In ROS werden Anhängigkeiten zwischen Bezugssystemen in einer Baumstruktur, genannt *transformation tree (tf-tree)* dargestellt. Die Wurzel dieser Baumstruktur ist das globale Bezugssystem, wie zum Beispiel der Ursprung einer globalen Karte oder der Startpunkt der Trajektorie eines Roboters. Das globale Bezugssystem kann beliebig gewählt werden. Auf diese Weise kann ein Koordinatensystem, welches relativ zu einem anderen gelegen ist im Baum als Kindknoten seinem Bezugssystem untergeordnet werden. Es wird nur die relative Transformation (s. Kapitel 3.1.2) zwischen den Systemen im Baum gespeichert. Dies hat den Vorteil, dass bei der Bewegung eines Systems die untergeordneten Systeme nicht ebenfalls verändert werden müssen, da deren Transformationen relativ zum bewegten Bezugssystem angegeben sind und nicht global zur Wurzel des Baumes. Abbildung 3.2 zeigt ein Beispiel für einen Roboter mit mehreren voneinander abhängigen Systemen.

Auch räumliche Daten wie zum Beispiel Punktwolken aus Laserscannern können relativ zu verschiedenen Koordinatensystemen gesehen werden. So kann es nützlich sein die Punktwolke relativ zum Koordinatensystem des Scanners oder innerhalb des globalen Koordinatensystems zu betrachten. Um zwischen den Koordinatensystemen zu wechseln wird eine Koordinatensystemtransformation. Diese werden im folgenden Kapitel behandelt.

## Transformationen

Eine Koordinatensystemtransformation ist ein Sonderfall einer mathematischen Transformation, die eine Menge  $X$  auf sich selbst abbildet:

$$f : X \rightarrow X \quad (3.1)$$



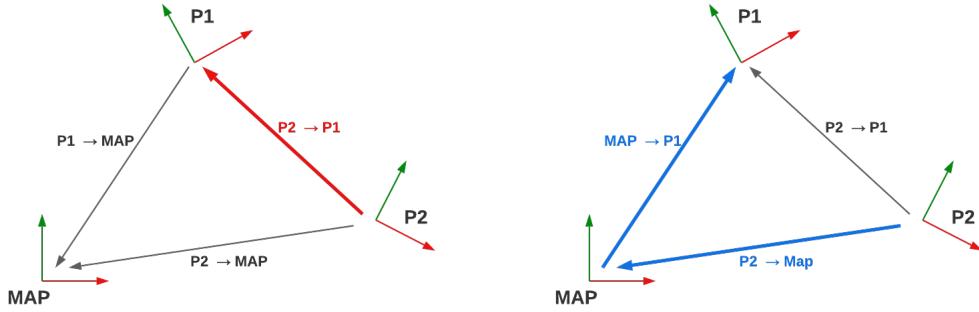
**Abbildung 3.2:** Schematische Darstellung eines Roboters und dessen beweglicher Teile. Die Ausrichtung der jeweiligen Gelenke wird mit einem lokalen Koordinatensystem beschrieben. Die globale Position einzelner Teile kann durch eine Verkettung der relativen Transformation in Richtung der Wurzel des Baumes bestimmt werden. Bild aus: [37]

Eine Koordinatensystemtransformation beschreibt die Differenz zwischen zwei unterschiedlichen Koordinatensystemen und enthält sowohl die Translationsdifferenz als auch die Rotationsdifferenz. Zur Berechnung dieser Transformation zwischen zwei beliebigen Koordinatensystem  $C_1$  und  $C_2$  wird die absolute Translation und Rotation beider Koordinatensysteme zum Ursprungskoordinatensystem, wie zum Beispiel den Ursprung einer Umgebungskarte, benötigt. Durch diese Rotations und Translationskomponenten beschreibt sich die absolute Position und Rotation der Koordinatensysteme im Raum aus Sicht des Ursprungskoordinatensystems  $C_{MAP}$ . Diese absolute Position und Rotation ist die Transformation von den jeweiligen Koordinatensystemen ins Ursprungskoordinatensystem.

Es existieren diverse Darstellungsweisen für Koordinatensystemtransformationen. Eine mögliche Darstellung ist die als Vektor. In folgendem ist die Transformation vom Koordinatensystem  $C_X$  ins Koordinatensystem  $C_{MAP}$  dargestellt. Die Variablen  $t_i$  bezeichnen dabei die Translationskomponenten und die Variablen  $r_i$  die Rotationskomponenten um die jeweiligen Achsen.

$$T_{C_X \rightarrow C_{MAP}} = (t_x, t_y, t_z, r_x, r_y, r_z)^T \quad (3.2)$$

Neben der Vektordarstellung kann eine Transformation zusätzlich als eine  $4 \times 4$  Matrix dargestellt werden. Diese Darstellungsweise hat den Vorteil, dass die Transformation direkt per Matrixmultiplikation auf Daten wie um homogene Koordinaten erweiterte Punktdaten angewandt werden kann. Auch die direkte Kombination verschiedener Transformationen ist durch eine Matrixmultiplikation möglich. Hier gilt es zu beachten, dass Matrixmultiplikation nicht kommutativ ist und



**Abbildung 3.3:** Schematische Darstellung der bestimmung einer Transformation zwischen zwei Roboter-Posen  $P_1$  und  $P_2$ , hier zur Vereinfachung dargestellt in 2D. Gesucht ist die Transformation ( $T_{P_2 \rightarrow P_1}$ ), dargestellt im linken Teil der Abbildung als roter Pfeil. Diese kann implizit bestimmt werden durch eine Verkettung der Transformationen  $T_{P_2 \rightarrow MAP}$  und  $T_{MAP \rightarrow P_1}$ , hier dargestellt im rechten Teil der Abbildung in blau. Die Transformation  $T_{MAP \rightarrow P_1}$  ist dabei nicht explizit gegeben. Sie kann berechnet werden durch eine Inversion der Transformation  $T_{P_1 \rightarrow MAP}$ . Die finale Gleichung zur Berechnung der relativen Transformation ist dargestellt in Gleichung 3.3.

ein Vertauschen der Reihenfolge bei der Multiplikation zu unterschiedlichen Ergebnissen führen kann. Bei einer Verkettung von Transformationen durch Multiplikation wird die Matrix zuerst angewandt, welche am Ende der Multiplikation steht.

In dieser Arbeit werden Transformationen zum Beispiel verwendet um zu bestimmen, wie sich ein Roboter zwischen zwei Messungen bewegt hat. Diese Transformationen beschreiben relative Differenzen zwischen Roboterpositionen im Raum. Diese Roboterpositionen werden auch *Posen* genannt. Eine Pose ist dabei eine meist absolute Beschreibung der Translation und Rotation eines Roboters zu einem gewissen Zeitpunkt  $t$  aus Sicht des Ursprungskoordinatensystems wie zum Beispiel dem Map-Ursprung  $C_{MAP}$ .

Abbildung 3.3 zeigt die Mathematik hinter der Berechnung der Posedifferenz exemplarisch. Es wird deutlich, dass eine gesuchte Transformation aus dem Koordinatensystem von Pose  $P_2$  in das Koordinatensystem von Pose  $P_1$  ( $T_{P_2 \rightarrow P_1}$ ) gegeben ist durch:

$$(T_{P_2 \rightarrow P_1}) = (T_{P_1 \rightarrow MAP})^{-1} * T_{P_2 \rightarrow MAP} \quad (3.3)$$

Basierend auf den erläuterten mathematischen Grundlagen wird in Kapitel 3.3 die Grundlagen von SLAM, insbesondere von TSDF basierten SLAM Verfahren, erörtert. Zuvor werden in nachfolgendem Abschnitt die Eigenschaften und Anwendungsbereiche der TSDF beschrieben.

## 3.2 TSDF

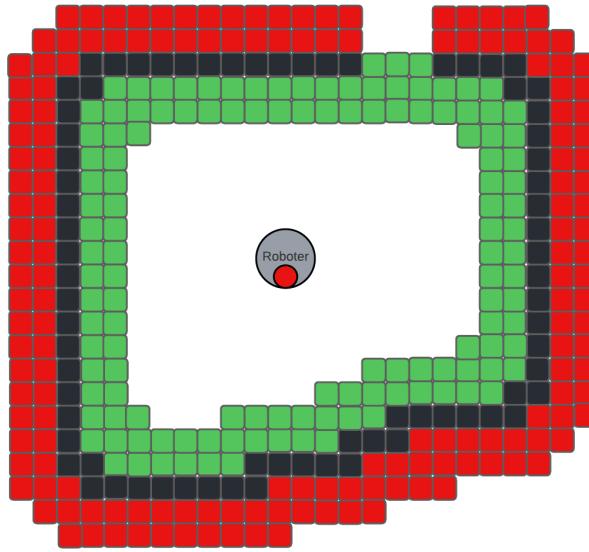
Zur Lösung des *Simultaneous Localization and Mapping (SLAM)* (siehe Kapitel 3.3) Problems in unbekannten Umgebungen wird im Regelfall eine Form der Kartenrepräsentation und die Algorith-

mik benötigt, sich auf Basis der Kartenrepräsentation zu lokalisieren um diese im Anschluss aktualisieren zu können. Bei vielen Lösungsansätzen wie zum Beispiel einer inkrementellen *Registrierung* (siehe Kapitel 3.3) mit dem *Iterative Closest Point (ICP)* [4] oder *Generalized Iterative Closest Point* [38] Algorithmus werden als Kartenrepräsentation registrierte Punktwolken verwendet. Punktwolken stellen dabei keine geschlossenen Oberflächenrepräsentationen dar und benötigen viel Speicher im Gegensatz zu einigen geschlossenen Repräsentationen wie aus den Punktwolken generierten Dreiecksnetzen. Ein großer Nutzen einer solchen Repräsentation ist die vereinfachte Lokalisierung und Navigation auf Basis der Kartenrepräsentation durch deren Geschlossenheit beziehungsweise Kontinuität. Eine weitere Form der geschlossenen Oberflächenrepräsentation der Umgebung sind *Signed Distance Fields (SDF)*. Im Gegensatz zu Dreiecksnetzen sind die SDF implizite, volumetrische Beschreibung der Oberfläche [44]. Sie beschreiben die Oberfläche nicht direkt, sondern den Raum um die Oberfläche herum. Die *Signed Distance* ist die orthogonale metrische Distanz eines beliebigen Punktes  $p$  zur Oberfläche räumlicher Daten, wie zum Beispiel der approximierten Oberfläche von Punktwolken. Diese Distanz kann sowohl negativ, als auch positiv sein. Unterschieden wird zwischen dem Innenbereich, räumlich gesehen vor einer Wand oder einem Hindernis, und dem Außenbereich, welcher räumlich gesehen hinter dem vom Laser getroffenen Objekt befindlich ist. Positive SDF-Werte kennzeichnen Freiraum, negative den Raum hinter gesehenen Oberflächen oder Hindernissen. Der Übergang zwischen positiven und negativen TSDF-Werten beschreibt näherungsweise die gesehene Oberfläche. Abbildung 3.4 zeigt ein schematisches Beispiel für eine zweidimensionale, diskretisierte TSDF nach Abtasten der Oberfläche einer unbekannten Umgebung durch einen Laserscanner.

Die *Truncated Signed Distance Function (TSDF)* ist eine Unterklasse der SDF. Sie betrachtet die Distanz zur Oberfläche nur bis zu einer maximalen Distanz  $tsdf_{max}$ , auch  $\tau(\tau)$  genannt [16]. Alle Werte die weiter von der Oberfläche entfernt oder unbekannt sind, erhalten als Wert  $\tau$  selbst. Dies spart Rechenaufwand, da nur die Werte in direkter Nähe zur Oberfläche angepasst werden müssen. In Gebieten, in denen der TSDF-Wert  $\tau$  entspricht, kann jedoch keine Aussage darüber getroffen werden, wo die nächste Oberfläche ist, oder wie weit sie entfernt ist. Es ist lediglich bekannt, dass die betrachtete Position nicht in direkter Nähe zur Oberfläche befindlich und mindestens  $\tau$  entfernt ist. Das Intervall möglicher Werte  $v_i$  der TSDF ist:

$$I_v = [-\tau, \tau] := \{x \in \mathbb{R} | \tau > 0\} \quad (3.4)$$

Über SDF und TSDF können kontinuierliche Karten erstellt werden. Da kontinuierliche Karten aber unendlich viel Speicherplatz benötigen, wird der Raum diskretisiert. Die Diskretisierung erfolgt durch eine Aufteilung der Umgebung in *Voxel* beziehungsweise *Zellen* mit definierbarer, fester Seitenlänge  $v_{res}$  [16, 45]. Jeder Voxel enthält einen approximierten (T)SDF-Wert. Dieser Wert beschreibt die Distanz des Voxel-Zentrums zur nächsten Oberfläche. Ist eine Zelle noch nicht beschrieben, erhält sie einen Default-TSDF-Wert von  $\tau$ . Diese Form der Darstellung kann auch als quasi-kontinuierlich angesehen werden, da durch eine Approximation über benachbarte Zellen ein approximierter TSDF-Wert für jeden beliebigen Raumpunkt berechnet werden kann. Dadurch sind TSDF basierte Karten ideal, um mittels des *Marching Cubes Algorithmus* [25] eine polygonale Netz-Repräsentation, wie zum Beispiel ein Dreiecksnetz generieren zu können. Dieses kann zum Beispiel als optische Referenz für die Qualität der Karte verwendet werden.



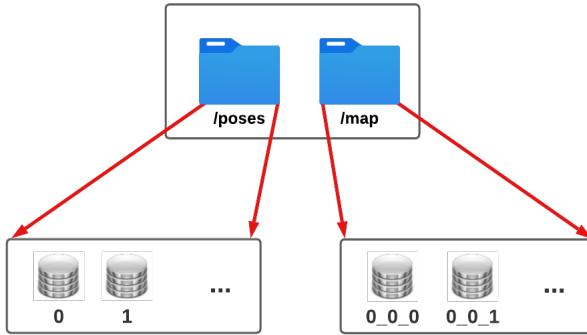
**Abbildung 3.4:** Schematische Darstellung einer diskretisierten 2-D TSDF Karte. Abgebildet sind nur Voxel mit TSDF-Werten im Intervall  $]-\tau, \tau[$ . In der Mitte der Karte befindet sich ein Roboter mit einem Laserscanner (hier dargestellt in rot). Der Roboter befindet sich zum Beispiel in einem Raum. Der Innenbereich (des Raumes) mit positiven TSDF-Werten ist hier dargestellt in grün, der Außenbereich mit negativen TSDF-Werten in rot. Die Oberfläche, in deren Umgebung die TSDF-Werte nahezu Null sind, ist abgebildet in schwarz.

Neben dem TSDF-Wert enthält jede TSDF-Zelle ein Gewicht für die Sicherheit des enthaltenen TSDF-Wertes.

Diese Arbeit beschäftigt sich mit einer möglichen Integration von Schleifenschlüssen in einen auf einer TSDF-Karte basierenden Ansatz wie vorgestellt von Eisoldt et al. [16]. Der Aufbau und die Verwendung der TSDF-Karte ist im nachfolgenden Abschnitt beschrieben. Ziel ist die Korrektur von Fehlern bei der Registrierung und der damit verbundenen Korrektur der TSDF-Karte. Dies ist in Kapitel 5 und 6 beschrieben.

### 3.2.1 TSDF-Karte

Eisoldt et al. [16] basieren ihren SLAM Ansatz auf einer diskreten, inkrementell erweiterten TSDF Karte. Zur Registrierung (vergleiche Kapitel 3.3) verwenden sie ebenfalls die TSDF-Karte. Punkt wolken werden dabei mit einer *Point-to-TSDF* Strategie an die TSDF Karte registriert [16]. In [16] werden neue Punktdaten nicht an die globale TSDF Karte registriert sondern an eine lokale TSDF Karte fester Größe. Lediglich die lokale Karte befindet sich im Arbeitsspeicher und lädt wenn nötig Daten aus der globalen Karte, die durch einer *HDF5*-Datei repräsentiert ist und auf der Festplatte gespeichert ist, nach. Das *Hierarchical Data Format 5 (HDF5)* [19] ist ein Dateiformat für die Speicherung und Verwaltung von Daten in einem hierarischen System, das dem Dateisystem von Windows oder UNIX Betriebssystemen ähnelt. HDF5 erlaubt die Gruppierung von zusammengehörigen Daten und die Speicherung von Metadaten wie zum



**Abbildung 3.5:** Innere Struktur der HDF5-Datei, die die globale TSDF-Karte repräsentiert. Auf der obersten hierarchischen Ebene werden die Daten in zwei Gruppen aufgeteilt. */poses* enthält dabei die Trajektorie des Roboters, separiert in einzelne Posen, die mit Null beginnend indiziert sind. */map* enthält die eigentliche TSDF-Karte. Sie ist in unterteilt in Chunks, die ein Datenarray aus Paaren von TSDF-Wert und TSDF-Gewicht enthalten. Das Label der Chunks entspricht den diskreten Koordinaten der Chunks im Raum.

Beispiel den Hyperparametern der verwendeten Karte. Auch Schachtelungen sind möglich. HDF5 eignet sich besonders für die effiziente Serialisierung und Deserialisierung komplexer Daten oder Objekte und kann die interne Struktur der zu serialisierenden Objekte abbilden. Diese Aufteilung in eine globale und eine lokale Karte sorgt dafür, dass [16] auch für große Umgebungen (*Large-Scale*) geeignet ist und der Arbeitsspeicher nicht überläuft. Die Implementation dieser TSDF-Kartenstruktur wird auch in dieser Arbeit verwendet. Sie dient als Basis für die Bestimmung der Datenassoziationen wie beschrieben in Kapitel ?? und bildet die Grundlage für jegliche Form der Kartenoptimierung, die in dieser Arbeit vorgenommen wird.

Die globale TSDF-Karte ist unterteilt in Teilstücke beziehungsweise *Chunks* fester Größe, deren Seitenlänge durch die Anzahl der TSDF-Voxel entlang einer Seitenlänge definiert ist. Bei Bedarf kann ein beliebiger Chunk in den Arbeitsspeicher geladen oder zurück auf die Festplatte in die HDF5-Datei geschrieben werden. Diese enthält in der hierarchischen Struktur ein Datenset für jeden angelegten Chunk. Neben den TSDF-Informationen ist nach Durchlaufen des SLAM-Algorithmus zusätzlich die erstellte Pose-Historie in der HDF5 gespeichert. Abbildung 3.5 zeigt den internen Aufbau der HDF5 Datei, in der die globale Karte abgespeichert ist.

Die Bezeichnung (TSDF-)Karte beziehungsweise *Map* wird im Folgenden für die implizite TSDF Repräsentation der Umgebung verwendet. Der Ursprung der Karte ist im Folgenden als Ursprung des Weltkoordinatensystems definiert. Der folgende Abschnitt befasst sich mit dem inkrementellen Update der lokalen Karte auf Basis der Daten in Form einer Pose  $P_{new}$ , deren Translation und Rotation zum Beispiel durch eine Registrierung der zugehörigen Punktwolke  $C_{new}$  bestimmt wird. Dieses Update ist nicht mit dem Update der Karte im Anschluss an eine Graph-Optimierung zu verwechseln. Das im folgenden beschriebene Update widmet sich lediglich dem inkrementellen Update der Karte im SLAM und wird getrennt von Schleifenschlüssen und Graph-Optimierungen betrachtet.

### 3.2.2 TSDF-Update

Dieser Abschnitt eruiert das inkrementelle Update der lokalen TSDF-Karte basierend auf einer neuen Pose  $P_{new}$  und der zugehörigen Scan-Punktwolke  $C_{new}$ . Dies kann sowohl das erste Datenpaar sein, auf Basis dessen ein Update der TSDF-Karte durchgeführt wird oder ein Datenpaar, welches in eine bereits teilweise gefüllte Karten eingefügt wird. Für ein Konsistentes Einfügen der neuen Daten wird dazu die Karte zunächst in Richtung der neuen Pose verschoben, sodass das Zentrum der Karte genau auf der neuen Pose liegt. Dabei werden Teile der lokalen Karte, die außerhalb des neuen Sichtbereichs liegen zurück in die globale Karte geschrieben und Teile der globalen Karte, die nun in den Sichtbereich der lokalen Karte gelangen, aus der globalen Karte nachgeladen. Dieses Verschieben ist optional und kann gegebenenfalls durch andere Strategien ersetzt werden um die Anzahl dieser Laufzeit-intensiven Operationen zu reduzieren. Möglich ist zum Beispiel erst dann eine Verschiebung der Karte durchzuführen, wenn die neue Pose eine definierte Entfernung zum alten Zentrum der Karte überschreitet. Da diese Arbeit den Fokus nicht auf diese Art von Optimierungen legt, wird im Folgenden von einer Verschiebung der Karte für jede neue Pose ausgegangen. Im Anschluss an die Verschiebung ist das neue Zentrum der Karte äquivalent zum Translations-Anteil  $t_{new}$  der neuen Pose  $P_{new}$ . Ausgehend von der Pose werden zum Update der Karte Rays zwischen der neuen Pose und jedem Datenpunkt  $p_i$  der Scan-Punktwolke abgelaufen. Der Strahl stoppt dabei nicht am Punkt  $p_i$ , sondern wird um eine Länge von  $\tau$  verlängert, damit auch der negative Bereich bis  $-\tau$  berücksichtigt wird. Die vom Strahl  $r_i$  geschnittenen TSDF-Zellen der diskretisierten lokalen Karte werden entsprechend der Entfernung des Zentrums der Zelle zum Punkt  $p_i$  gefüllt. Durch die Diskretisierung der Karte ist es möglich, dass mehrere Strahls dieselbe Zelle schneiden. In diesem Fall wird für die Zelle die kleinste berechnete Distanz gewählt. Die Tupel aus TSDF-Wert und Gewicht  $\langle \text{value}(v_i), \text{weight}(\omega_i) \rangle$  einer vom Strahl  $r_i$  in Richtung  $p_i$  getroffenen Zelle wird wie folgt berechnet. Dabei bezeichnete  $d_i$  die euklidische Distanz des Voxelzentrums zum Punkt  $p_i$  [10, 16].  $d_i$  ist negativ, wenn der Strahl über den Punkt  $p_i$  hinaus belaufen wird. Dies ist zunächst nicht der Wert, der in die Karte geschrieben wird, sondern lediglich der, der im späteren Verlauf mit dem aktuellen Karteninhalt verglichen wird und gegebenenfalls für ein Update sorgt.

$$\omega_i = \begin{cases} 1 \cdot \frac{(\tau+v)}{(\tau-\frac{\tau}{10})}, & \text{if } v_i < -\frac{\tau}{10} \\ 1, & \text{otherwise} \end{cases} \quad (3.5)$$

$$v_i = \begin{cases} \min(d_i, \tau), & \text{if } d_i \geq 0 \\ \max(d_i, -\tau), & \text{if } d_i < 0 \end{cases} \quad (3.6)$$

Diese Gleichungen sind entnommen aus [10, 16]. Für das Gewicht ergibt sich eine lineare Abnahme im negativen Bereich, hinter der betrachteten Oberfläche, ab einer gegebenen Schwelle von  $v_\epsilon = -\frac{\tau}{10}$ . Der TSDF-Wert  $v$  nimmt Werte entsprechend des Intervalls  $I_v$ , gegeben die Distanz vom Voxel-Zentrum zum Punkt  $p_i$ , an. Wie zuvor erörtert ist, können mehrere Strahls dieselbe Zelle schneiden. In diesen Fällen wird jeweils das Tupel mit dem TSDF-Wert gewählt, der näher in Richtung der Oberfläche, als einem TSDF-Wert von 0 gelegen ist. Diese so generierten

Tupel werden nun mit dem derzeitigen Inhalt der Karte verglichen. Dabei gelten die folgenden Vorschriften zur Berechnung des in die Karte geschriebenen Tupels  $\langle v_{new}, \omega_{new} \rangle$ . Gegeben das aktuell in der Karte vorliegende Tupel  $\langle v_{map}, \omega_{map} \rangle$ , sowie das zuvor berechnete Tupel  $\langle v_i, \omega_i \rangle$ .  $\omega_{max}$  definiert das maximale Gewicht einer Zelle, welches dafür sorgt das Änderungen an der Zelle, die im späteren Verlauf vorgenommen werden, einen Effekt auf den TSDF-Wert haben können. Es ergibt sich:

$$\omega_{new} = \begin{cases} \min(\omega_{map} + \omega_i, \omega_{max}), & \text{if } \omega_i > 0 \text{ and } \omega_{map} > 0 \\ \omega_i, & \text{if } \omega_i \neq 0 \text{ and } \omega_{map} \leq 0 \end{cases} \quad (3.7)$$

$$v_{new} = \begin{cases} \frac{v_{map} \cdot \omega_{map} + v_i \cdot \omega_i}{\omega_{map} + \omega_i}, & \text{if } \omega_i > 0 \text{ and } \omega_{map} > 0 \\ v_i, & \text{if } \omega_i \neq 0 \text{ and } \omega_{map} \leq 0 \end{cases} \quad (3.8)$$

Im Anschluss wird das neue Tupel anstelle der vorliegenden Werte in die Karte geschrieben. Neben dem Update der vom Strahl geschnittenen Zellen erfolgt zusätzlich eine vertikale Interpolation der umliegenden Zellen aller geschnittenen Zellen [16]. Diese Idee gründet in den Erfahrungen mit modernen Laserscannern, die ein horizontales Sichtfeld von  $360^\circ$  aufweisen und in der Horizontalen eine gute Dichte der Punktdaten liefern, allerdings in vertikaler Richtung eine starke Begrenzung der Auflösung durch eine Sensor-spezifische Anzahl von Scan-Linien vorweisen. Die Abstände zwischen den Scan-Linien vergrößern sich dabei mit der Entfernung des Laserscanners zur betrachteten Oberfläche. Dies sorgt für ein dünn besetztes und nicht geschlossenes TSDF mit mehreren Lücken in vertikaler Richtung, abhängig von der Anzahl Scan-Linien des Sensors. Gegeben den Richtungsvektor  $\vec{d}_{r_i}$  des Strahls  $r_i$ , sowie einen Vektor  $\vec{up}$ , der im lokalen Koordinatensystem des Scanners, gegeben durch die aktuell betrachtete Pose  $P_{new}$ , in Richtung der z-Achse schaut, ergibt sich der Interpolations-Vektor  $\vec{v}_{int}$  als:

$$\vec{v}_{int} = vecd_{r_i} \times (vecd_{r_i} \times \vec{up}) \quad (3.9)$$

Entlang dieses Vektor wird ausgehend vom aktuellen Schritt  $s_i^j$  beim Ablauen des Strahls  $r_i$  eine Interpolation durchgeführt. Die Schrittweite entlang des Strahls ergibt sich aus der Seitenlänge der TSDF-Zellen und wird mit der Hälfte dieser Seitenlänge initialisiert. Es wird sowohl in Richtung  $\vec{v}_{int}$  als auch  $-\vec{v}_{int}$  interpoliert. Die vom Interpolations-Vektor geschnittenen Zellen erhalten einen identischen TSDF-Wert zu dem der aktuell von  $r_i$  geschnittenen Zelle. Dabei werden nur dann Werte in Zellen geschrieben, wenn sie zuvor noch an keiner anderen Stelle beschrieben wurden. Die Interpolation in negative und positive Richtung von  $\vec{d}_{r_i}$  ist begrenzt durch den halben Abstand  $\Delta_z$  zur nächsten Scan-Linie nach oben und unten und berechnet sich aus dem vertikalen Öffnungswinkel des Sensors  $\alpha_{sensor}$  und der Anzahl verfügbarer Scan-Linien  $n_{lines}$ . Gegeben die Länge des Vektors zwischen der Scanner-Position und dem aktuell betrachteten Schritt  $l_s$  als, ergibt sich  $\Delta_z$  als:

$$\Delta_z = \frac{\tan\left(\frac{\alpha_{sensor}}{n_{lines}}\right) \cdot l_s}{2} \quad (3.10)$$

Diese Begrenzung sorgt dafür, dass keine Zellen interpoliert werden, die näher an den Strahlen benachbarter Scan-Linien gelegen sind. Damit Zellen, die interpolierte Daten enthalten, identifiziert werden können, wird ein negatives Gewicht zugewiesen. Nicht inkrementelle Updates auf Basis identifizierter Schleifenschlüsse, wie vorgestellt in Kapitel 4 und 6 müssen die interpolierten Zellen beachten. Im Folgenden wird zunächst auf die Grundlagen von SLAM eingegangen. Dabei wird sich unter anderem auf Verfahren fokussiert, die das hier vorgestellte TSDF als Kartenrepräsentation nutzen.

### 3.3 SLAM

Dieser Abschnitt befasst sich mit den Grundlagen von SLAM, stellt heraus welche Varianten von SLAM Verfahren es gibt und wie sich TSDF basierte Verfahren, insbesondere der HATSDF-SLAM Ansatz von Eisoldt et al. ?? von diesen unterscheidet.

SLAM ist der Prozess der simultanen Generierung einer Karte einer unbekannten Umgebung und der Lokalisierung innerhalb dieser Karte beziehungsweise Umgebung. SLAM ist ein *Henne-Ei-Problem*, da auf der einen Seite eine vollständige Karte benötigt um die Pose des Roboters akkurat zu bestimmen, auf der anderen Seite allerdings eine akkurate Posenhistorie benötigt wird um eine gute Karte der Umgebung aufbauen zu können. Eine grobe Übersicht über existierende SLAM Verfahren liefert der Stand der Forschung in Kapitel ???. Im Folgenden werden einige der genannten Verfahren und die darunterliegenden Strukturen erneut aufgegriffen und erläutert. Schlussendlich wird erklärt, welche der SLAM Verfahren für diese Masterarbeit von Interesse sind und wie sie genutzt werden.

Grundlage für jeden SLAM-Algorithmus ist eine inkrementell erweiterte Kartenstruktur und die Algorithmik, sich innerhalb der Kartenstruktur auf Basis neuer Daten zu lokalisieren. Im Anschluss erfolgt die Erweiterung der Kartenstruktur unter Nutzung der neuen Daten. Die Lokalisierung innerhalb der Karte auf Basis neuer Daten, wie zum Beispiel einer Initial-Schätzung der Pose im Raum basierend auf Odometrie oder einer Akkumulation von IMU Daten in Kombination mit den zum Zeitpunkt aufgenommenen Umgebungsdaten. Dieser Prozess wird häufig als Registrierung oder Scan-Matching bezeichnet. Einer der bekanntesten Algorithmen dafür ist der *Iterative Closest Points (ICP)* Algorithmus nach Besl und McKay [4].

— todo — Als *Registrierung* wird der Prozess der Zusammenführung von Punktwolken bezeichnet, die von unterschiedlichen Orten aus aufgenommen werden. Um Punktwolken möglichst gut zusammenzuführen, wird versucht die aus den Laserscans entstandenen Punktwolken maximal zu überlappen. Dieser Prozess wird auch *Scan Matching* genannt. Beim Scan Matching wird zwischen dem *Model* und dem *Scan* unterschieden. Als Scan bezeichnet werden die Daten, die an das Model registriert werden sollen. Das Ergebnis des Scan Matching ist eine Approximation der Transformation  $T_{Scan \rightarrow Model}$  zwischen den Posen von denen aus die Punktwolken aufgenommen wurden. Damit untersucht werden kann, wie gut diese Approximation ist, liefern ICP und

verwandte Algorithmen wie zum Beispiel *Generalized Iterative Closest Points* [38] ein Maß für die Genauigkeit der Approximation. Dies ist im Fall von ICP und GICP der sogenannte *Fitness-Score*. Er beschreibt die durchschnittliche quadrierte Distanz zwischen den *Nearest Neighbors* (*nächsten Nachbarn*) der Punktwolken nach Anwendung der approximierten Transformation  $T_{Scan \rightarrow Model}$  der Scanpunktwolke in das Koordinatensystem der Modelpunktwolke. Er gibt dementsprechend an, wie groß die durchschnittliche quadrierte Distanz eines Punktes aus der Modelpunktwolke zum euklidisch nächsten Punkt der transformierten Scanpunktwolke ist.

Sowohl ICP, als auch GICP sind inkrementelle Algorithmen, dass heißt sie nähern sich inkrementell einem Optimum immer weiter an. Dabei wird die approximierte Transformation jeweils um ein  $\delta T$  verändert. Fällt dieses  $\delta T$  in einer Iteration unter einen vom Benutzer gewählten Schwellwert, oder wird eine maximale Anzahl an Iterationen erreicht, bricht der Algorithmus ab und gibt die finale Transformation zurück. Genanntes Optimum ist dabei im Regelfall allerdings kein globales, sondern lediglich ein lokales Optimum aus dem weder ICP noch GICP herauskommen, sobald sie hineingeraten. Aus diesem Grund gilt es die jeweiligen Ausgaben der Algorithmen zum Beispiel basierend auf dem resultierenden Fitness-Score zu analysieren.

Beide Algorithmen werden in Kapitel ?? und Kapitel 5 in Bezug auf die Identifikation von Schleifenschlüssen evaluiert.

Varianten (auf die eingegangen wird):

ICP Graph-SLAM - $\zeta$  Global Relaxation

Einzelne Verfahren näher beschreiben, erklären welche Bibliotheken verwendet werden

1. Grundlagen von SLAM beschreiben - $\zeta$  Varianten des SLAM - $\zeta$  Bezug zu HATSDF-SLAM
2. Voraussetzungen (Repräsentationen für Posen (Pfad) und Umgebung)
3. Überleitungen in weitere Sektionen machen - $\zeta$  Loop Closure als mögliche Verbesserung des SLAM - $\zeta$  TSDF als Kartenrepräsentation - $\zeta$  auf Vorteile von TSDF eingehen (z.B. einfache Integration in Marching Cubes Algorithmus)



## Kapitel 4

# Identifikation von Datenassoziationen zum Karten-Update

Wie in der Einleitung beschrieben, soll in einem ersten Ansatz analysiert werden, ob eine TSDF Karte mit gegebenem initialen Pfad durch dessen Optimierung mittels Schleifenschlüssen verbessert werden kann. Dazu ist im ersten Schritt zu identifizieren, welcher Teil der Karte mit welcher Pose assoziiert ist, um bei einer Veränderung der Trajektorie entscheiden zu können, wie die Karte angepasst werden muss. Dies Kapitel befasst sich mit der Generation von Datenassoziationen zwischen den Posen des Pfades und der TSDF-Karte.

### 4.1 Ansatz

Wie in Kapitel 3.2 beschrieben, wird die TSDF Karte von Eisdoldt et al. [16] inkrementell erweitert, sobald eine definierte minimale Distanz zurückgelegt wurde. Dabei werden nicht nur neue Zellen beschrieben, sondern auch die Werte bereits beschriebener Zellen gewichtet verändert. Dementsprechend kann die Information in einer Zelle eine Akkumulation beliebig vieler Updates sein und beliebig vielen Posen zugeordnet werden. Diese Information gilt es zu berücksichtigen, wenn auf Basis einer gegebenen TSDF Karte Datenassoziationen identifiziert werden sollen. Eine Möglichkeit der Generation dieser Assoziation wäre eine *1:1* Beziehung zwischen den Zellen und Posen aufzubauen. Dann würde eine Zelle maximal einer Pose zugeordnet werden. Da bereits bekannt ist, dass eine Zelle von mehreren Posen angepasst werden kann, ist diese Art der Beziehung zwischen Posen und TSDF-Zellen allerdings von einem großen Informationsverlust geprägt. Die Alternative zur *1:1* Beziehung ist eine *1:N* Beziehung zwischen einer Zelle und *N* Posen. Diese Beziehung ist aufgrund der genannten Eigenschaften des TSDF-Karten Updates der *1:1* Beziehung zu bevorzugen.

Die Informationen darüber, welche Position welche TSDF Zelle beschrieben hat, lässt sich allerdings nicht aus der TSDF Karte herauslesen. Um dies zu ermöglichen könnte der Ansatz

von Eisoldt et al. [16] um die Funktion erweitert werden, an jeder Zelle zusätzlich ein Array zu speichern, in dem die Posen enthalten sind, die die betroffene Zelle modifiziert haben. Dieses Array muss in einem eigenen Datensatz gespeichert sein, da die Anzahl Posen, die auf diese Weise einer Zelle zugeordnet werden können, dynamisch ist. Das bedeutet, dass für jede einzelne TSDF Zelle ein eigenes Datensatz gespeichert werden muss, in dem die zugehörigen Posen enthalten sind. Je nach Auflösung der diskretisierten Karte müssten nach diesem Ansatz mehrere Millionen separate Datensätze gespeichert werden. Ein solches Vorgehen erfordert nicht nur viel Speicher, sondern ist auch aus hierarchischer Betrachtungsweise keine sinnvolle Herangehensweise. Eine Möglichkeit, die gewünschten Daten auf Basis einer gegebenen TSDF Karte zu generieren ist diese über die Methode, mit der die Daten generiert wurden, zu regenerieren. In [16] wird die TSDF-Karte über ein *Ray-Marching* generiert. Eine alternative zum Ray-Marching stellt der Bresenham Algorithmus dar, der die Diskretisierung der Karte ausnutzt. Beide Varianten werden im Folgenden beschrieben, evaluiert und miteinander verglichen. Zunächst beschreibt der folgende Abschnitt die Serialisierung der Datenassoziation in der HDF5-Datenstruktur.

## 4.2 Serialisierung der Datenassoziationen

Dieser Abschnitt beschreibt, wie identifizierte Assoziationen in der hierarchischen Struktur der HDF5-Datei gespeichert werden, die Daten der TSDF-Karte, sowie die zugehörige Pose-Historie enthält. Wie in Kapitel 3.2 beschrieben, enthält die HDF5 Struktur mehrere Gruppen, die jeweils weitere Daten enthalten. Zu diesen Gruppen gehören in diesem Fall */map* und */poses*. Die Map-Gruppe enthält die serialisierten TSDF-Zellenwerte und TSDF-Zellengewichte. Die Poses-Gruppe enthält die serialisierten 6D Posen des Pfades als Datensätze. Der HDF5 interne Pfad eines dieser Pose-Datensätze ist */poses/[index]*, wobei *index*, der Index der Pose im Pfad ist. An dieser Stelle wird nun einer Erweiterung vorgenommen, um die generierten Assoziationen zu serialisieren. Anstelle der Datensätze wird für jede Pose eine eigene Gruppe erstellt. Diese Gruppe erhält als Namen ebenfalls den Pfadindex der Pose. Innerhalb dieser Gruppe wird ein Datensatz für die Pose und optional ein weiteres Datensatz für die Datenassoziationen angelegt, sofern erforderlich. Abbildung 4.1 zeigt die neue interne HDF5 Struktur nach dieser Änderung.

Auf Basis dieser Änderungen wird im Folgenden erläutert, wie die zu speichernden Zellen für jede Pose ermittelt werden.

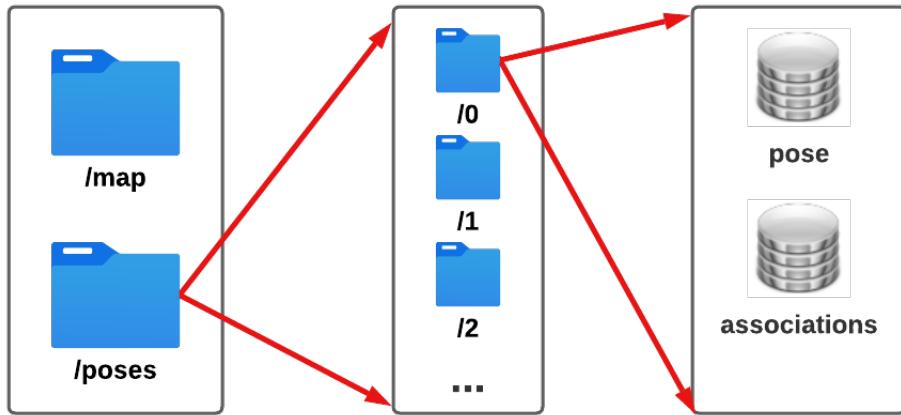
## 4.3 Detektions-Algorithmen

Dieser Abschnitt stellt die Algorithmen heraus, mit denen beschriebene Assoziationen identifiziert werden können. Die Ergebnisse der Algorithmen werden miteinander verglichen und evaluiert.

### 4.3.1 Ray-Tracing

Eine Möglichkeit der Ermittlung der mit einzelnen Posen assoziierten Teilbereiche der TSDF Karte ist die die Erstellung eines künstlichen Laserscans innerhalb der TSDF Karte, ausgehend von der entsprechenden Pose. Entsprechend wurde im Zuge dieser Arbeit ein *Raytracer* entwickelt, der simulierte Laserstrahlen ausgehend von einer definierten 6D-Pose generiert und die Schnittpunkte

TODO: anhand mehrerer Datensätze Assoziationen bilden und schauen, von wie vielen Posen eine Zelle im Durchschnitt angepasst wurde und hochrechnen, was das für den Speicher bedeutet



**Abbildung 4.1:** Schematische Darstellung der HDF5 internen Datenstruktur nach Speicherung der generierten Datenassoziationen zwischen TSDF-Zellen und Posen. Die in Kapitel 4.1 beschrieben 1:N Beziehung zwischen einer Zelle und den zugehörigen Posen ist hier indirekt realisiert. Anstelle pro Zelle ein Datensatz zu erstellen, wir für jede Pose ein Datensatz enthält, das alle assoziierten TSDF-Zellen enthält. Verschiedene Posen können dabei dieselbe TSDF-Zelle assoziieren. Das Datensatz *pose* enthält die Transformation der aktuellen Pose ins Ursprungskoordinatensystem. Das Datensatz *associations* enthält ein Array der assoziierten Zellkoordinaten, die durch die Diskretisierung ganzzahlig sind und als Integer abgespeichert werden.

der Strahlen mit der TSDF Karte überprüft. Der Raytracer ist beliebig konfigurierbar und kann an die Parameter verschiedenster realer Laserscanner angepasst werden. Die wesentlichen Parameter und deren Bedeutung sind Tabelle 4.1 zu entnehmen.

Zur Emulation des Laserscans wird zunächst ein Array erstellt, in dem die aktuellen Endpunkte der jeweiligen Strahlen gespeichert werden. Die Anzahl an Endpunkten  $n$  ist definiert durch die konfigurierte Auflösung. Sie beträgt:

$$n = \text{vert\_res} \cdot \text{hor\_res} \quad (4.1)$$

Der Startpunkt jedes Strahls ist die Pose  $P_i$ , von der aus der Laserscan ausgesendet wird. Ziel ist in jeder Iteration alle Strahlen um *step\_size* zu verlängern und die TSDF-Zellen zu evaluieren, die derzeit von den einzelnen Strahlen getroffen werden. Für diese Verlängerung der Strahlen müssen diese zunächst initialisiert werden. Diese Initialisierung erfolgt auf Basis der parametrisierten Öffnungswinkel des Laserscanners *opening\_degree\_vert* und *opening\_degree\_hor*, sowie der konfigurierten vertikalen und horizontalen Auflösung *vert\_res* und *hor\_res*. Zunächst werden die Winkelbereiche definiert, in den der Raytracer operiert. Diese setzen sich aus den Öffnungswinkeln zusammen. Der Winkelbereich in horizontaler Richtung beträgt:

$$I_{\text{hor}} = [-\text{opening\_degree\_hor}, \text{opening\_degree\_hor}] \quad (4.2)$$

**Tabelle 4.1:** Parameter des in dieser Arbeit entwickelten Raytracers zur Bestimmung des mit einer beliebigen Pose assoziierten Teilbereichs der TSDF-Karte. Der horizontale Öffnungswinkel wird an dieser Stelle als 360 Grad angenommen.

Parameter	Funktionsweise	Default-Wert
<i>opening_degree</i>	Definiert den vertikalen Öffnungswinkel des Raytracers. Anzugeben in Grad.	45
<i>hor_res</i>	Definiert die horizontale Auflösung des Laserscanners. Der gegebene Wert entspricht der Anzahl Strahlen pro Scanebene.	1024
<i>vert_res</i>	Definiert die vertikale Auflösung des Laserscanners. Der gegebene Wert entspricht der Anzahl an Scanebenen im Laserscan.	128
<i>step_size</i>	Definiert, wie groß die Schrittweite beim Aussenden der einzelnen Strahlen ist. Der Wert ist in Metern anzugeben. Der Default-Wert ist direkt an die Zellgröße der diskreten TSDF-Karte <i>mapres</i> gekoppelt und beträgt $\frac{mapres}{2}$ .	0.032
<i>ray_size</i>	Definiert die Dicke des Strahls in der Visualisierung. Dieser Parameter dient lediglich zur erleichterten Visualisierung des Laserscans bei unterschiedlicher Konfiguration. Der Wert ist in Metern anzugeben.	0.01

Der Winkelbereich in vertikaler Richtung beträgt:

$$I_{vert} = [-opening\_degree\_vert, opening\_degree\_vert] \quad (4.3)$$

Die jeweiligen Winkelbereiche werden durch die konfigurierte Auflösung diskretisiert. Die horizontale Schrittweite des Laserscanners beträgt:

$$\Delta_{hor} = \frac{opening\_degree\_hor}{hor\_res} \quad (4.4)$$

Die vertikale Schrittweite des Laserscanners beträgt:

$$\Delta_{vert} = \frac{opening\_degree\_vert}{vert\_res} \quad (4.5)$$

Basierend auf den unteren und oberen Winkelschranken und der berechneten Schrittweite zwischen diesen Schranken kann nun das Array initialisiert werden. Dazu wird in zwei Schleifen über die beiden Winkelintervalle  $I_{vert}$  und  $I_{hor}$  iteriert und der aktuelle Wert jeweils um die berechneten

Delta  $\Delta_{vert}$  und  $\Delta_{hor}$  inkrementiert. Aus den beiden Winkeln  $\alpha$  und  $\beta$  der aktuellen Iteration der Schleifen, sowie einer beliebigen Distanz initialen Länge des Strahls, wie zum Beispiel der Schrittweite *step\_size* können nun für jeden Punkt die initialen Ray-Punkte berechnet werden, die den Richtungsvektor des Strahls definieren. Hierzu ist eine Umwandlung von Kugelkoordinaten in das Kartesische Koordinatensystem notwendig. Mit *alpha*, *beta* und *step\_size* wird in Kugelkoordinaten genau ein Punkt im dreidimensionalen Raum beschrieben. Um diese in kartesische Koordinaten im ROS Koordinatensystem umzuwandeln wird folgende Formel verwendet ( $\alpha$  und  $\beta$  gegeben in Radianen,  $\alpha$  beschreibt den aktuellen Winkel um die z-Achse,  $\beta$  die aktuelle Rotation um die y-Achse):

$$\begin{pmatrix} x_{P_i} \\ y_{P_i} \\ z_{P_i} \end{pmatrix} = \text{step\_size} \cdot \begin{pmatrix} \cos(\alpha) \cdot \cos(\beta) \\ \sin(\alpha) \cdot \cos(\beta) \\ \sin(\beta) \end{pmatrix} \quad (4.6)$$

Der Punkt  $(x_{P_i}, y_{P_i}, z_{P_i})^T$  beschreibt hier zunächst nur den Startpunkt des Strahls aus Sicht des lokalen Karten-Koordinatensystems, das durch  $P_i$  beschrieben ist. Um diesen aus Sicht des globalen Koordinatensystems  $\mathbb{M}$  zu betrachten, muss dieser Punkt dorthin transformiert werden. Grundlagen zur Transformation werden in Kapitel 3.1.2 behandelt. Es ist essentiell, dass an dieser Stelle nicht nur die Translation, sondern auch die Rotation berücksichtigt wird um den Scan von Pose  $P_i$  bestmöglich replizieren zu können. Die Transformation des Vektors  $(x_{P_i} y_{P_i} z_{P_i})^T$  vom Koordinatensystem beschrieben durch Pose  $P_I$  in das globale Koordinatensystem  $\mathbb{M}$  mit der Transformationsmatrix  $T_{P_i \rightarrow \mathbb{M}}$  ist gegeben durch:

$$\begin{pmatrix} x_{\mathbb{M}} \\ y_{\mathbb{M}} \\ z_{\mathbb{M}} \end{pmatrix} = T_{P_i \rightarrow \mathbb{M}} \cdot \begin{pmatrix} x_{P_i} \\ y_{P_i} \\ z_{P_i} \end{pmatrix} \quad (4.7)$$

Auf diese Weise werden alle initialen Endpunkte des emulierten Laserscans berechnet. Auf Basis der berechneten initialen Endpunkte und des bekannten Anfangspunktes gegeben durch den Translationsanteil von  $P_i$  kann das inkrementelle Ray-Tracing beginnen. In jeder Iteration des Ray-Tracing werden alle Strahlen um *step\_size* verlängert und die entsprechend getroffenen Zellen evaluiert. Um einen Vektor  $\vec{v}$  gegeben durch den Translationsanteil  $\vec{t}_i$  und den aktuellen Endpunkt des betrachteten Strahls  $\vec{r}_i$  um *step\_size* zu verlängern und daraus den neuen Endpunkt des Strahls  $\hat{\vec{r}}_i$  zu berechnen wird folgende Formel verwendet:

$$\hat{\vec{r}}_i = \frac{\|\vec{r}_i - \vec{t}_i\| + \text{step\_size}}{\|\vec{r}_i - \vec{t}_i\|} \cdot (\vec{r}_i - \vec{t}_i) + \vec{t}_i \quad (4.8)$$

Nach der Verlängerung eines Strahls  $\vec{r}_i$  wird die in der aktuellen Iteration  $j$  getroffene TSDF-Zelle  $C_i^j$  evaluiert. Je nach Schrittweite *step\_size* und Auflösung des Raytracers ist es möglich, dass  $C_i^j$

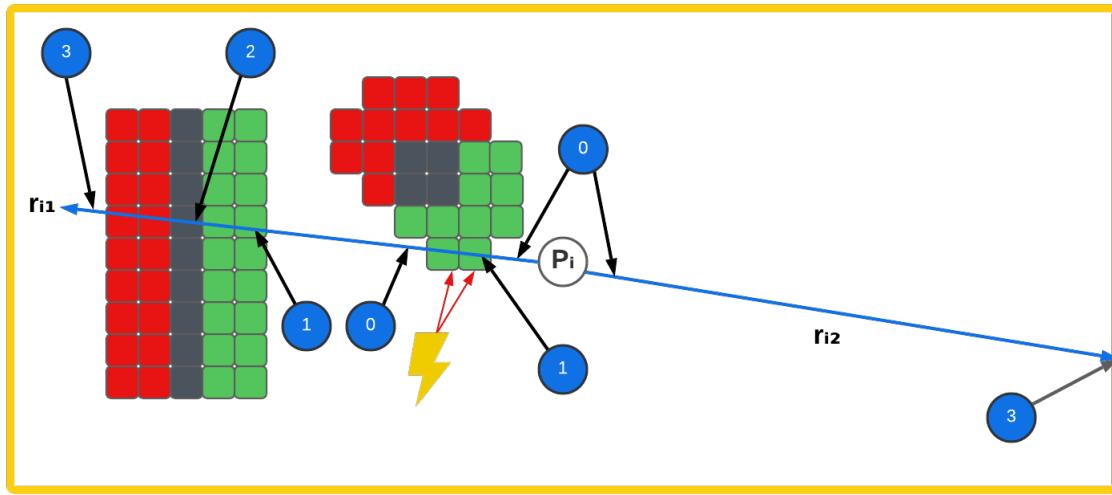
bereits evaluiert wurde und schon eine Assoziation mit der Pose  $P_i$  hergestellt ist. Um diesen Fall zu überprüfen und zu verhindern, dass duplizierte Assoziationen gespeichert werden, wird eine Hash-Map genutzt, deren Hash auf Basis der Koordinaten der TSDF-Zelle berechnet wird. Ist  $C_i^j$  bereits in der Hash-Map gespeichert, ist der aktuell betrachtete Strahl  $\vec{r}_i$  für diese Iteration fertig evaluiert und der nächste Strahl kann betrachtet werden. Um zu entscheiden, ob eine nicht assozierte Zelle  $C_i^j$  als Assoziation in Frage kommt, müssen mehrere Zustände des Strahls definiert werden. Abbildung 4.2 zeigt die benötigten Zustände und die Bedingungen für einen Wechsel des Status gegeben den aktuellen Status und die betrachtete Zelle  $C_i^j$ , sowie dieren TSDF-Wert und TSDF-Gewicht. Ein Strahl ist beschränkt durch die lokale Karte um  $P_i$  3.2.1, sowie die Struktur der TSDF-Karte. Detektiert ein Strahl einen einen Wechsel von positive auf negative TSDF-Werte (*Nulldurchgang*) in der TSDF, stoppt der Raytracer, sobald er erneut positive Werte detektiert. Diese Herangehensweise sorgt dafür, dass mit der Pose  $P_i$  keine Zellen assoziiert werden, die von dieser Pose aufgrund der Begrenzungen der lokalen Karte nicht gesehen werden konnten oder hinter Wänden befindlich sind.

Die Ergebnisse dieses Ansatz sind in Abbildung 4.5 im Vergleich mit den Ergebnissen des Bresenham Algorithmus dargestellt, der im nachfolgenden Abschnitt behandelt wird. In dem genutzten Datensatz können nur etwa 91% der Zellen assoziiert werden. Diese Zahl ähnelt auch der von Bresenham. . Abschnitt 4.3.4 evaluiert die Ergebnisse von Ray-Tracing und Bresenham und vergleicht diese miteinander. Zudem wird Bezug zum Informationsverlust bei der Assoziationsidentifikation genommen.

### 4.3.2 Bresenham

Eine alternative algorithmische Herangehensweise an das beschriebene Problem der Assoziationsidentifikation ist die Nutzung des Bresenham-Algorithmus [8]. Dieser wurde ursprünglich verwendet, um einen digitalen Plotter mittels eines Computers zu kontrollieren und beliebige zweidimensionale Linien und Kurven approximativ abzubilden. Der Plotter lässt sich dabei in acht Richtungen auf einem diskretisierten Raster bewegen. Bresenham [8] beschreibt, wie sich die Zellen im Raster berechnen lässt, die das gegebene Liniensegment einer Kurve oder eine Linie am besten beschreibt. Der Bresenham Algorithmus findet heutzutage vielfach Anwendung im Bereich der Computergrafik. Hier liegt eine Diskretisierung durch die Auflösung des Bildschirms in Pixeln vor. Mittels des Bresenham Algorithmus kann bestimmt werden, durch welche Pixel eine Linie oder ein Liniensegment beschrieben werden kann. Abbildung 4.4 zeigt die initiale Idee des Bresenham Algorithmus in zwei Dimensionen. Eine ähnliche Diskretisierung weist auch die in dieser Arbeit verwendete TSDF-Karte auf. Sie ist allerdings im Gegensatz zu den beschriebenen Beispielen in drei Dimensionen diskretisiert. Mittels Bresenham soll bestimmt werden, welche Voxel der TSDF-Karte zu einem Strahl gehören, der von einer Position  $\vec{p}$  ausgesendet wurde und sich mit der TSDF-Karte schneidet. Ziel ist die Beschleunigung des Ray-Tracing Ansatzes durch die Ausnutzung der Diskretisierung der Karte. Dabei gelten die gleichen Voraussetzungen wie beim zuvor beschriebenen Ray-Tracing und die Initialisierung der einzelnen Strahlen erfolgt analog. Im Gegensatz zum Ray-Tracing wird allerdings nicht der Strahl schrittweise verlängert, sondern basierend auf den initialen Richtungsvektoren der Strahlen jeweils das nächste Voxel berechnet, das den Strahl am besten beschreibt.

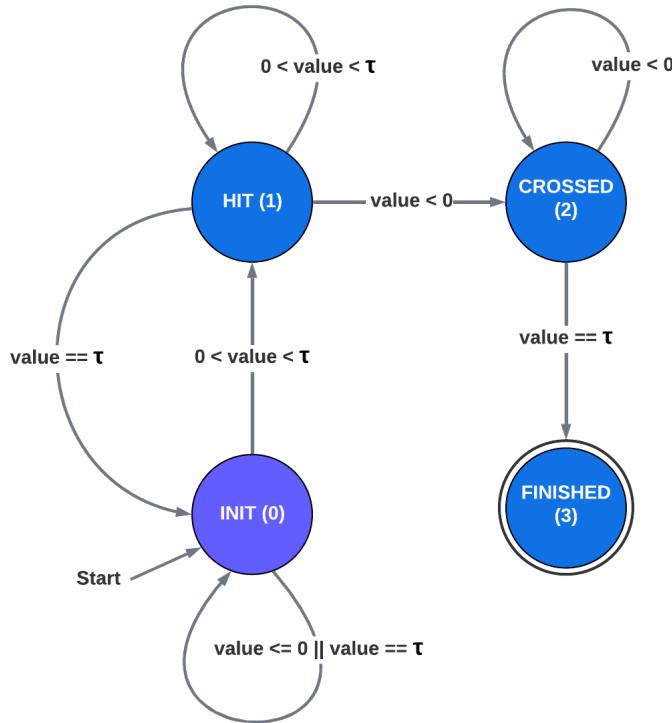
Für mehrere  
Datensätze  
zahlen bilden,  
graphisch  
darstellen



**Abbildung 4.2:** Schematische Darstellung 2D Darstellung der verschiedenen Zustände eines einzelnen Strahls des Raytracers innerhalb einer TSDF-Darstellung. Negative TSDF-Werte sind rot dargestellt, positive in grün. Der approximierte Nulldurchgang in der TSDF ist hier gräulich dargestellt, die umgebende lokale Karte in gelb. Ausgehend von Pose  $P_i$  sind zwei Strahlen  $r_{i1}$  und  $r_{i2}$  dargestellt, die die verschiedenen Fälle abdecken, die es zu berücksichtigen gilt. Eine genaue Beschreibung der Zustandsänderungen der Strahlen im Zustandsdiagramm 4.3 zu entnehmen. Die entsprechenden Zustände sind dargestellt als blaue Kreise, die die jeweilige Zustandsnummer enthalten. Die entsprechenden Definitionen der Zustände sind ebenfalls im Zustandsdiagramm 4.3 zu entnehmen. Die mit einem Blitz markierten Zellen werden zwar von dem ausgesandten Strahl  $r_{i1}$  getroffen, dürfen allerdings aufgrund der Evidenz im aktuellen Strahl nicht mit der Pose assoziiert werden, da im Anschluss an diese Zellen kein Nulldurchgang, sondern Freiraum folgt. Der Freiraum ist hier in weiß dargestellt und setzt sich aus den TSDF-Zellen zusammen, die Default-Werte enthalten und entsprechend außer der minimalen Entfernung  $\tau(\tau)$  zur Oberfläche, keine räumlichen Informationen besitzen. Gleicher Ausnahmefall tritt ein, wenn der Strahl lediglich negative TSDF-Zellen trifft. Diese werden ebenfalls nicht aufgrund der Evidenz des betrachteten Strahls mit der Pose assoziiert.

Die Grundlage für die Berechnung der zum Strahl gehörigen Voxel bildet ein Startvoxel  $\vec{V}_{start}$ , gegeben durch die aktuell betrachtete Pose beziehungsweise Scannerposition  $P_i$  und ein Endvoxel  $\vec{V}_{end}$ . Letzterer berechnet sich aus dem Schnittpunkt des betrachteten Strahls mit der Bounding-Box der lokalen Karte, gekennzeichnet durch ihren Ursprung  $p_{lmap}$  und ihre Seitenlängen  $(s_x, s_y, s_z)^T$ . Basierend auf den berechneten Start- und Endvoxeln jedes Strahls können nun die dazwischenliegenden Voxel mittels Bresenham ermittelt werden. Der Pseudo-Code in Abbildung 1 legt die Logik für die Bestimmung der der Voxel dar, die die Linie gegeben durch den Startvoxel  $\vec{V}_{start}$  und Endvoxel  $\vec{V}_{end}$  beschrieben.

ggf. Mathematik dahinter erklären



**Abbildung 4.3:** Zustandsdiagramm der internen Zustände eines Strahls. Zustandsübergänge sind beschrieben durch einen initialen Zustand und den TSDF-Wert der aktuellen Zelle ( $value$ ). In Zustand 1 werden gefundene Assoziationen zunächst nicht abgespeichert, da noch nicht bekannt ist, ob diese Zellen zu einem Nulldurchgang gehören oder ob der Strahl nur Zellen kreuzt, die von einer anderen Pose aus befüllt wurden. Je nach TSDF-Wert der aktuellen Zelle werden die zwischengespeicherten Assoziationen aus Zustand 1 entweder verworfen oder in der HDF5 gespeichert.

---

**Algorithm 1** Bresenham Algorithmus adaptiert in 3D (nach [8])

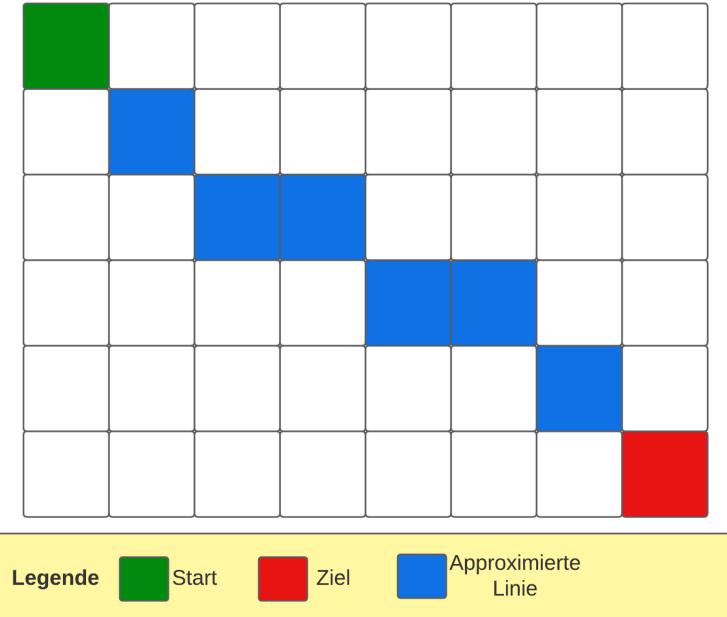
---

```

1: procedure BRESENHAM(  $\vec{V}_{start}$ ,  $map_l$ ,  $r_i^j$ )
2:   Initialisierung:
3:   Berechne die Endposition  $\vec{V}_{end}$  als Schnittpunkt des Strahls  $r_i^j$  mit der lokalen Karte  $map_l$ 
4:   Berechne Bresenham Parameter (absolute Abstände und Raumrichtungen):
5:    $dx = \left| \vec{V}_{end}^x - \vec{V}_{start}^x \right|$  // Absolute zwischen den Punkten in alle Raumrichtungen
6:    $dy = \left| \vec{V}_{end}^y - \vec{V}_{start}^y \right|$ 
7:    $dz = \left| \vec{V}_{end}^z - \vec{V}_{start}^z \right|$ 
8:    $dm = \max(dx, dy, dz)$  // Maximale Komponente der Manhattan Distanz
9:    $sx = \vec{V}_{start}^x < \vec{V}_{end}^x ? 1 : -1$  // Raumrichtung
10:   $sy = \vec{V}_{start}^y < \vec{V}_{end}^y ? 1 : -1$ 
11:   $sz = \vec{V}_{start}^z < \vec{V}_{end}^z ? 1 : -1$ 
12:  Temporäre Vektoren zur Iteration initialisieren:
13:   $\vec{v}_0 = (x_0, y_0, z_0)^T = \vec{V}_{start}$  und  $\vec{v}_0 = (x_1, y_1, z_1)^T = \left( \frac{dm}{2}, \frac{dm}{2}, \frac{dm}{2} \right)^T$ 
14:  for  $i = 1; i < dm; i++$  do //  $(dm - 1)$  mal iterieren
15:    Berechnung des nächsten Voxels (gegeben durch  $\vec{v}_0$ )
16:     $x_1 = \text{INTEGRATION\_ON\_SCHLEIFE} \text{ if } (\text{ON\_SCHLEIFE}) \text{ else } \text{INTEGRATION\_IN\_HALF\_TSDF-SLAM}$ 
17:     $y_1 = y_1 - dy; \quad \text{if } (y_1 < 0) \{ y_1+ = d_m; \quad y_0+ = s_y; \}$ 
18:     $z_1 = z_1 - dz; \quad \text{if } (z_1 < 0) \{ z_1+ = d_m; \quad z_0+ = s_z; \}$ 
19:    Neues Linien-Voxel gegeben durch:  $\vec{v}_0$  bzw.  $(x_0, y_0, z_0)^T$ 
20:  end for
21: end procedure

```

---



**Abbildung 4.4:** Schematische Darstellung des Bresenham-Algorithmus in zwei Dimensionen. Der Bresenham Algorithmus bestimmt, welche Voxel die Linie zwischen einem gegebenen Startvoxel und einem Endvoxel am besten beschreiben.

Mit Hilfe dieser Logik lässt sich iterativ für jeden Strahl  $r_i^j \in R_i$  der nächste zugehörige Voxel berechnen und evaluieren. Die Evaluation der von Bresenham ermittelten, aktuell vom Strahl getroffenen TSDF-Zellen erfolgt analog zu der Evaluation des Ray-Tracing entsprechend des Zustandsdiagramms in Abbildung 4.3. Das Abbruchkriterium für jeden Strahl  $r_i^j$  beim Bresenham ist entweder das Erreichen des Zielzustands im Zustandsdiagramm oder das Erreichen des zu  $r_i^j$  zugehörigen Endvoxels  $V_{end}^j$ . Insgesamt ergibt sich der in Abbildung 2 dargestellte Pseudo-Code, bei variabler Verwendung von Bresenham oder Ray-Tracing. Dieser Pseudo Code wird zur Assoziationsbestimmung ausgehend von jeder Pose  $P_i$  ausgeführt, für die die Assoziationen bestimmt werden sollen.

**Algorithm 2** Asssoziations-Berechnung mittels Bresenham oder Ray-Tracing

---

```

1: procedure ASSOZIATIONS-BERECHNUNG(  $P_i, map_{local}$  )
2:   Initialization:
3:     Initialisiere die Strahlen  $R_i$  um  $P_i$  wie beschrieben in 4.3.1
4:     Initialisiere ein Array  $r_{status}$  der Größe der Anzahl der Strahlen, welches die aktuellen
   Zustände der Strahlen, gegeben durch das Zustandsdiagramm in 4.3 beschreibt
5:     Initialisiere einen Zähler für die Anzahl der fertigen Strahlen:  $cnt_{fin} = 0$ 
6:     while  $cnt_{fin} < \text{size}(r_{status})$  do
7:       for  $r_i^j$  in  $R_i$  do
8:         Ermittle nächstes Voxel  $V_i^j$  mittels Ray-Tracing oder Bresenham
9:         Evaluiere  $V_i^j$  auf Basis des Zustandsdiagramms in 4.3
10:        Speichere  $V_i^j$  als Assoziation, wenn es gemäß 4.3 mit  $P_i$  assoziiert ist
11:       end for
12:     end while
13:     Speichere die gefundenen Assoziationen gemäß 4.1 in der HDF5
14:   end procedure

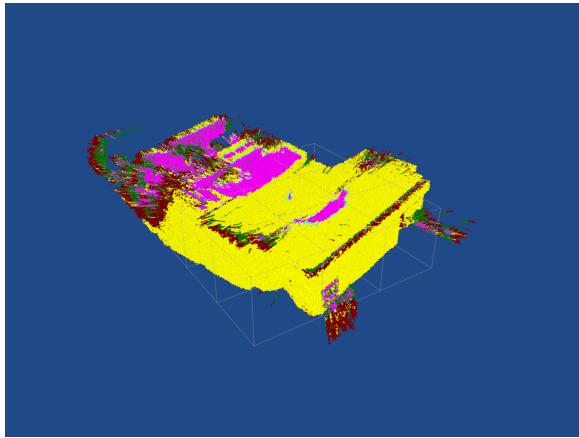
```

---

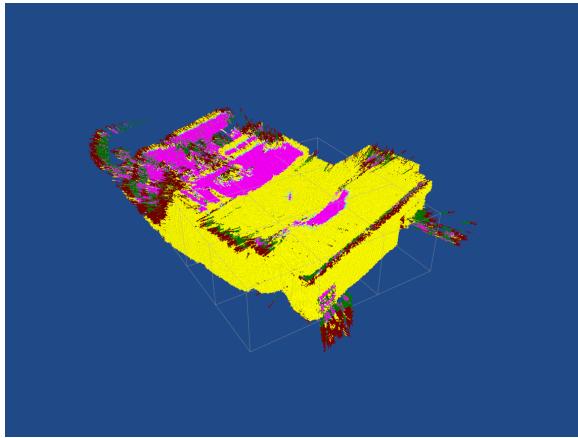
In den folgenden beiden Abschnitten werden die Ergebnisse der Assoziationsbestimmung evaluiert und es findet ein Vergleich zwischen den beiden vorgestellten Algorithmen statt.

### 4.3.3 Ergebnisse der Algorithmen

Abbildung 4.5 zeigt eine Gegenüberstellung der Ergebnisse der Evaluationsbestimmung zwischen Bresenham und dem Ray-Tracing Ansatz. Es ist ersichtlich, dass in beiden Experimenten sehr ähnliche Ergebnisse erzielt werden konnten. Dies lässt sich auch an dem Prozentsatz der assoziierten Zellen von der Gesamtheit der Zellen kenntlich machen. Hier beträgt der Unterschied zwischen den beiden Ansätzen lediglich 0.23%, die vom Raytracer zusätzlich assoziiert wurden. Dieser Unterschied lässt sich anhand einiger Eigenschaften von Bresenham deutlich machen. Der Algorithmus erlaubt unter gewissen Umständen, dass aufeinander folgende Zellen nur an der Ecke miteinander verbunden sind. Dann gilt zum Beispiel  $C_i = (0, 0, 0)^T$  und  $C_{i+1} = (1, 1, 1)^T$ . Dies ist eine der Ursachen die dazu führt, dass grundsätzlich nicht alle Zellen assoziiert werden können. Auch das Ray-Tracing weist ähnliche Probleme aufgrund der Diskretisierung der Schritte auf. Hier können durch die diskreten Schritte Zellen Zellen übersprungen werden, die in einer kontinuierlichen Betrachtungsweise vom Strahl getroffen werden. Dieses Problem ist beim Raytracer allerdings vernachlässigbar, solange die Schrittweite identisch zu der gewählt wird, die beim Update der TSDF- verwendet wird. Dadurch kann sichergestellt werden, dass Zellen, die beim Update der TSDF-Karte ausgehend von  $P_i$  verändert wurden, auch von dem Raytracer zur Datenassoziation getroffen werden. Dies erklärt dementsprechend nicht die restlichen knapp 9% der Zellen, die durch den Raytracer nicht assoziiert werden konnten. Der Prozentsatz variiert je nach verwendetem Datensatz und der Struktur der Daten. Nachfolgender Abschnitt erörtert das Problem der nicht assoziierten Zellen.



(a) Assoziationen identifiziert mit Bresenham.



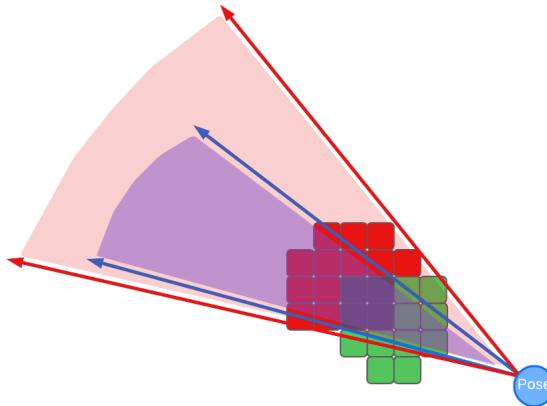
(b) Assoziationen identifiziert mit Ray-Tracing.

**Abbildung 4.5:** Gegenüberstellung der generierten Assoziationen für einen Beispieldatensatz. Die durch Bresenham gefundenen Assoziationen sind auf der linken Seite, die durch Ray-Tracing auf der rechten dargestellt. In diesem Fall wurden von Bresenham 91,74 Prozent der Zellen assoziiert, während vom Ray-Tracing 91,97 Prozent der Zellen assoziiert wurden. Zellen in gelb: assoziierte TSDF Zellen mit  $value < 0$ , Zellen in pink: assoziierte TSDF Zellen mit  $value > 0$ , Zellen in türkis: approximierter Nulldurchgang (Wechsel von positivem zu negativem Wert), Rest: nicht assoziierte Zellen. Zellen die nicht assoziiert werden, sind in diesem Fall größtenteils Teil von Verdeckungen oder Reflexionen des Laserscans und können als Outlier identifiziert werden.

#### 4.3.4 Evaluation

Dieser Abschnitt befasst sich mit den Problematiken bei der Bestimmung von Assoziationen zwischen einer gegebenen Trajektorie und einer bestehenden TSDF-Karte. Zusätzlich erfolgt im zweiten Teil eine Evaluation der Laufzeiten zwischen dem Bresenham Algorithmus und dem Ray-Tracing.

Im vorigen Abschnitt wurde beschrieben, dass ein je nach Datensatz variabler Prozentsatz der Karte nicht durch den Raytracer und ebenfalls nicht durch Bresenham mit einer der Posen assoziiert werden kann. Dieses Problem wird sowohl durch die diskreten Schritte beim Raytracer, als auch durch eine unpassende Wahl der nächsten Zelle im 3-D Bresenham Algorithmus ausgelöst. Diese beiden Probleme sorgen allerdings nur zum Teil für die nicht assoziierten Zellen. Eine wesentliche Ursache sind durch die Diskretisierung eintretende Verdeckungen und Reflexionen beziehungsweise nicht gefiltertes Sensorrauschen bei der Generation der Karte, das für einzelne in der Luft schwebende TSDF-Zellen sorgt. Ein Beispiel für beschriebene Verdeckungen sind zum Beispiel Türen. In der Realität kann ein Laserscanner beliebig nah am Türrahmen vorbei scannen. Hier wird der Sichtbereich durch die Tür lediglich vom Türrahmen eingeschränkt. In einer diskretisierten TSDF-Karte wird der Sichtbereich durch die Tür je nach der Auflösung der Karte eingeschränkt. Abbildung 4.6 zeigt dieses Problem schematisch in 2-D anhand einer Pose und einem Hindernis, wie zum Beispiel einem Pfeiler. Es ist erkenntlich, dass ein Teil des ursprünglichen Sichtbereichs nun durch die diskretisierte TSDF-Karte verdeckt ist und alle Zellen, die sich im verdeckten Bereich hinter dem Hindernis nicht mehr assoziiert werden können.



**Abbildung 4.6:** Diese Abbildung zeigt die Vergrößerung des Verdeckungsbereichs durch die Diskretisierung der Karte als TSDF. Zu sehen ist der ehemalige Verdeckungsbereich des in schwarz gefärbten Objektes. Dieser ist als halbtransparenter blauer Bereich gekennzeichnet. Darum herum zeigt sich der neue Verdeckungsbereich, der durch die Diskretisierung der Karte auftritt, ausgehend von der aktuell betrachteten Pose. Er ist halbtransparent in rot dargestellt. Diese Vergrößerung kommt durch die Beschaffenheit der Karte zustande. Nur außerhalb der roten Pfeile, also außerhalb des Verdeckungsbereichs kann mit Sicherheit gesagt werden, dass der simulierte Strahl Freiraum passiert. Durch die Diskretisierung hat sich der Bereich, in dem ein Objekt sein könnte, vergrößert. Dies ist die Hauptursache für nicht assoziierbare Zellen.

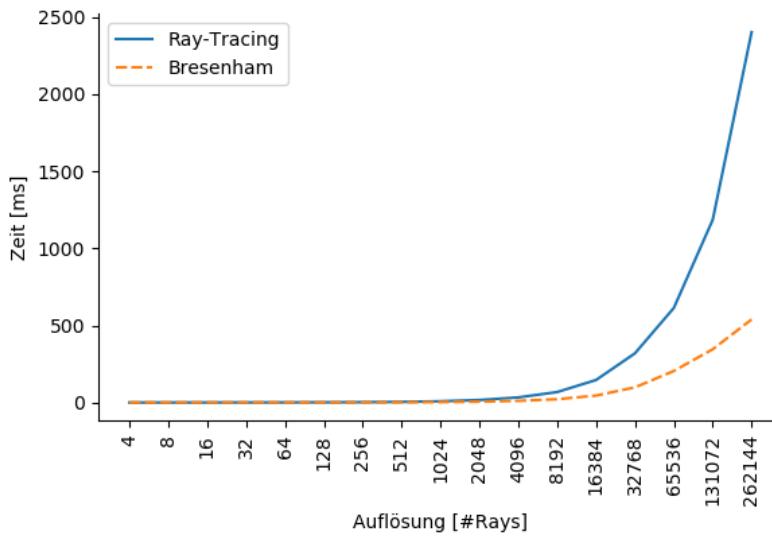
Dies ist die Hauptursache für beschriebene Probleme bei der Assoziationsbestimmung und kann ohne zusätzliche Informationen innerhalb der TSDF-Karte nicht gelöst werden. Eine Möglichkeit wäre, es dem Raytracer zu erlauben, durch Wände hindurch zu sehen, was allerdings dazu führen könnte, dass Zellen mit der Pose assoziiert werden, die nicht zu ihr gehören. Dies ist einer der Hauptgründe für eine grundlegende Veränderung der Herangehensweise an das in dieser Arbeit formulierte Problem. 4.4 eruiert weitere Probleme dieses ersten Ansatzes.

Abbildung 4.7 zeigte eine Gegenüberstellung der Laufzeiten des Bresenham-Algorithmus in 3D gegenüber des vorgestellten Ray-Tracing Ansatzes. Es wird deutlich, dass durch die Einführung des Bresenham Algorithmus eine deutliche Steigerung der Effizienz erzielt wird.

Der folgende Absatz beschäftigt sich mit der Identifikation von Schleifenschlüssen innerhalb dieses ersten Ansatzes.

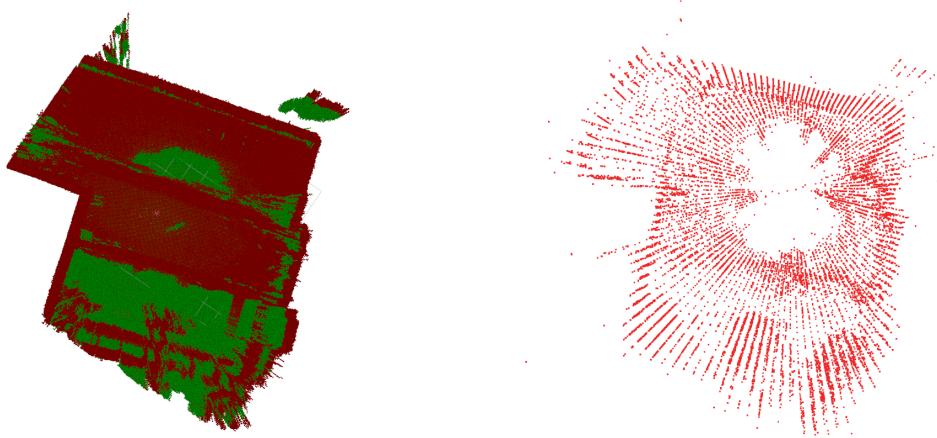
#### 4.4 Schleifenschlüsse in der Nachbearbeitung

Wie in Kapitel ?? eruiert wurde, ist es für die Identifikation von Schleifenschlüssen notwendig zu detektieren, dass der Roboters oder das Systems räumlich gesehen an derselben Pose oder in der Nähe der aktuellen Pose bereits gewesen ist. Dies lässt sich zum Beispiel über eine Distanzheuristik ermitteln. Alle Posen, deren euklidische Distanz zur aktuellen Pose geringer ist als eine festgelegte Schwelle sind Kandidaten für potentielle Schleifenschlüsse, die dann in den Posegraphen, gegeben durch die Posen des Roboters und gegebenenfalls vorige Schleifenschlüsse, eingefügt werden können. Um zu bestimmten, ob einer der ermittelten Schleifenschluss-Kandidaten für einen



**Abbildung 4.7:** Laufzeiten der vorgestellten Algorithmen zur Bestimmung der Assoziationen. Es handelt sich bei den jeweiligen Werte um das Mittel der Laufzeiten mehrerer künstlicher Scans beider Algorithmen, ausgehend von ungefähr 30 verschiedenen Positionen. Es ist zu sehen, dass – obwohl der Zeitbedarf beider Algorithmen exponentiell mit der Anzahl an Strahlen steigt – der Bresenham Algorithmus wesentlich effizienter ist. Bei den Laufzeiten handelt es sich um nicht beschleunigte, rein CPU basierte Ansätze. Beide Varianten können durch die Nutzung einer *Graphics Processing Unit (GPU)* oder mittels CPU basierter Beschleunigung durch eine Parallelisierung deutlich beschleunigt werden. Diese Beschleunigung liegt jedoch nicht im Fokus dieser Arbeit. Dieses Benchmark bestätigt die Hypothese, dass die Laufzeit durch die Ausnutzung der Diskretisierung erheblich verbessert wird. wobei ähnliche Ergebnisse erzielt werden können.

Schleifenschluss in Frage kommt, muss die Umgebung jeder einzelnen in Frage kommenden Pose gegen die Umgebung der aktuellen Pose verglichen werden. Das Mittel der Wahl ist hier ein Scan-Matching Ansatz wie vorgeschlagen in [6, 27, 40]. Dieser Ansatz basiert allerdings auf räumlichen Punktdaten, die an dieser Stelle nicht vorhanden sind. Die Einzige Repräsentation der Umgebung ist die bereits fertiggestellte TSDF-Kartendarstellung. Aus dieser können allerdings Punktfolgen approximiert werden. Grundlage dafür bildet in dieser Arbeit der zuvor entwickelte Raytracer. Dieser wird wie gehabt mit einer beliebigen Auflösung initialisiert und alle Strahlen werden schrittweise verlängert. Anstelle nun Assoziationen zu ermitteln, wird der erste Schnitt des Raytracers mit einem Nulldurchgang, einem Wechsel von positiven auf negative TSDF-Werte, gesucht. Ist ein solcher gefunden, wird die Ebene zwischen den beiden Voxeln berechnet, die die gesuchte Oberfläche am besten beschreibt. Diese Ebene ergibt sich aus den Positionen der Voxel  $\vec{V}_i$  und  $\vec{V}_j$ , sowie den zugehörigen TSDF-Werten  $v_i$  und  $v_j$ . Die TSDF-Werte bestimmen, wo die Ebene zwischen den beiden Voxeln liegt. Gegeben die Zentren der Voxel  $\vec{c}_i$  und  $\vec{c}_j$  in globalen Koordinaten, sowie die zugehörigen TSDF-Werte ist die Ebene beschrieben durch einen Ortsvektor  $\vec{v}_{ij}$ , sowie eine Normale  $n_{ij}$ . Die beiden Komponenten berechnen sich wie folgt:



(a) Lokale TSDF Karte ausgehend von einer festgelegten Pose.

(b) Aus der lokalen Karte generierte Punktwolke.

**Abbildung 4.8:** Gegenüberstellung eines Ausschnitts der TSDF-Karte und einer dazugehörigen, approximierten Punktwolke.

$$\vec{v}_{ij} = \vec{c}_i + (\vec{c}_j - \vec{c}_i) \cdot \frac{|\vec{v}_i|}{|\vec{v}_i| + |\vec{v}_j|} \quad (4.9)$$

$$\vec{n}_{ij} = (\vec{c}_j - \vec{c}_i) \quad (4.10)$$

Auf Basis der durch  $\vec{v}_{ij}$  und  $\vec{n}_{ij}$  gegebenen Ebene lässt sich nun ein Punkt der Punktwolke als Schnitt des betrachteten Strahls mit der zuvor berechneten Ebene errechnen. Das Ergebnis dieser Approximation ist in Abbildung 4.8 dargestellt. Eine Zuordnung der approximierten Punktwolke zur Pose von welcher ausgehend die Punktwolke generiert wurde ist jedoch nicht sinnvoll, da unbekannt ist, welcher Teil der Karte tatsächlich von dieser Pose aus generiert wurde. Dasselbe Problem gilt auch für die Bestimmung von Punktwolken aus einer statischen Karte zur Berechnung potentieller Schleifenschlüsse um auf Basis der Schleifenschlüsse erneut die Karte zu optimieren. Dies scheitert schon bei der Generierung von Punktwolken aus einer potentiell unvollständigen oder gänzlich falschen Karte. Die approximierten Punktwolken stellen dann in jedem Fall auch unvollständige oder falsche Daten dar. Auch ein Scan-Matching mit potentiell unvollständigen oder falschen Daten ist nicht zielführend. Aus den genannten Gründen wird die Idee der Punktwolkenapproximation zur Identifikation von Schleifenschlüssen an dieser Stelle verworfen.

Im Folgenden wird unabhängig vom Ergebnis dieses Abschnitts, der die Problematik der Detektion von Schleifenschlüssen in der gegebenen Kartenrepräsentation darlegt, untersucht inwiefern ein Karten-Update auf Basis der generierten Assoziationen möglich ist.

## 4.5 Karten-Update mittels generierter Assoziationen

Dieser Abschnitt befasst sich mit dem Problem des TSDF-Kartenupdates, gegeben ein initialer Pfad  $\mathfrak{P}_{init}$  und ein durch Schleifenschlüsse optimierter Pfad  $\mathfrak{P}_{opt}$ , sowie eine generierte Karte auf Basis des initialen Pfades. Ziel ist die Erstellung einer optimierten Karte, angepasst an den optimierten Pfad  $\mathfrak{P}_{opt}$ . Um dieses Ziel zu erreichen, müssen Teilbereiche der Karte entsprechend der Veränderungen der Posen verschoben werden. Dazu ist eine Assoziation zwischen Teilen der Karte und den zugehörigen Posen herzustellen. Entsprechend wurde ein Manager implementiert, der die zu bestimmenden Assoziationen verwaltet. Jeder Pose des alten Pfades wird ein HDF5-serialisierbares Assoziations-Objekt zugewiesen. Die Assoziationen selbst werden in einer  $1:N$  Beziehung durch Ray-Tracing oder den vorgestellten 3D-Bresenham Ansatz generiert. Dies liefert für jede Position  $P_i \in \mathfrak{P}_{init}$  eine Menge  $M = \{C_1, \dots, C_N\}$ , wobei die Anzahl der Assoziationen für jede Position unterschiedlich ist.

Die grundsätzliche entwickelte Logik für das Update der Karte auf Basis der generierten Assoziationen wird im Folgenden diskutiert. Zunächst wird in einem ersten Schritt für jedes Pose-Paar aus initialem und korrigiertem Pfad eine Pose-Differenz errechnet. Diese wird später genutzt um die neue Position assoziierter Zellen zu bestimmen. Gegeben die initialen Posen aus Pfad  $\mathfrak{P}_{init}$ , sowie die optimierten Posen aus  $\mathfrak{P}_{opt}$ , berechnen sich die einzelnen Pose-Differenzen beziehungsweise Transformationen  $T_i$  wie folgt:

$$T_i = (T_{i \rightarrow map}^{opt})^{-1} \cdot T_{i \rightarrow map}^{init} \quad (4.11)$$

Im Anschluss daran werden drei Level von Daten generiert, die jeweils aufeinander aufbauen und den Informationsgehalt erhöhen. Zwei dieser Level verwenden Hashmaps um schnell detektieren zu können ob ein Eintrag für eine Zellposition schon existiert um dann entsprechend reagieren zu können. *Level-1* enthält für jede assozierte TSDF-Zelle ein Tupel der alten Zellposition, der neuen, akkumulierten Zellposition, des zugehörigen TSDF-Werts und Gewichts, sowie einen Zähler für die Anzahl an Posen, die mit dieser Zelle assoziiert werden. Gegeben ein Array der mit der aktuellen Zelle  $\vec{C}_i$  assoziierten Posen  $[P_x, \dots, P_{x+n}]$ , sowie ein Array aus Pose-Differenzen, gegeben als Transformationsmatrix,  $[T_0, \dots, T_{N-1}]$  berechnet sich die akkumulierte Zellposition dabei wie folgt:

$$\vec{C}_{acc} = \sum_{j=x}^{x+n} T_j \cdot \vec{C}_i \quad (4.12)$$

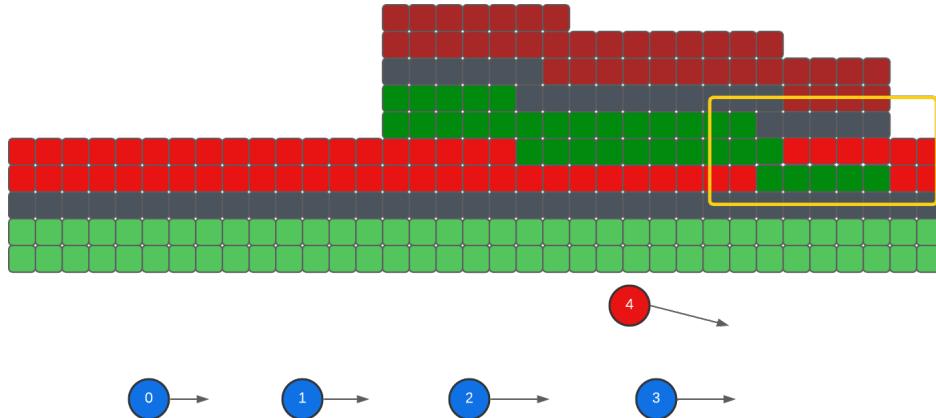
Anhand der generierten *Level-1* Daten lassen sich nun *Level-2* Daten generieren. Hier wird berücksichtigt, dass die neue Position mehrerer initialer TSDF-Zellen identisch sein kann. In diesem Fall wird hier zunächst das arithmetische Mittel der TSDF-Werte und Gewichte gebildet und der neuen Position zugewiesen. Da für die Akkumulation dieser Daten Hashmaps verwendet wurden, haben die nun generierten Daten keinerlei räumliche Zusammengehörigkeit. Dies führt zu Problemen, wenn sich die zu schreibende Zelle außerhalb der aktuellen lokalen Karte befindet und diese entsprechend verschoben werden muss. Das Verschieben der Karte ist eine Ressourcen und zeitintensive Operation, die möglichst selten ausgeführt werden sollte. Durch die Unordnung muss

im schlimmsten Fall für jede neue Zelle eine Verschiebung beziehungsweise ein *Shift* stattfinden. Bei Millionen von TSDF-Zellen und einer durchschnittlichen Dauer des Shifts von über einer Sekunde, würde alleine dieser Schritt über 10 Tage in Anspruch nehmen. Dementsprechend sind *Level-3* Daten spezifisch angeordnet, um die Anzahl an Shifts auf ein Minimum zu reduzieren. Dazu wird die *3-D Bounding-Box* des Raumes berechnet, den die neuen Zellpositionen einnehmen. Durch eine Aufteilung der Bounding-Box in Quader der Größe der lokalen Karte und eine Zuordnung der Zellen zu jedem dieser Quader wird die Anzahl der Shifts auf das gesuchte Minimum reduziert und die benötigte Zeit von Tagen auf Sekunden reduziert. Schlussendlich werden die initialen, assoziierten Zellen gelöscht und die neuen Zellpositionen mit den berechneten TSDF-Werten und Gewichten in die Karte geschrieben. Alle nicht assoziierbaren Zellen werden gelöscht. Da allerdings in der Regel kein globales, sondern nur ein lokales Update der TSDF-Karte vorgenommen werden soll lässt sich durch eine lokale Assoziationsbestimmung nicht sagen, ob die nicht assoziierbaren Zellen bedenkenlos gelöscht werden können, weil sie gegebenenfalls in einer globalen Assoziationsbestimmung assoziiert werden könnten. Ohne sicherzustellen, dass dies nicht der Fall ist, riskiert ein Löschen der genannten Zellen einen nicht zu kompensierenden Informationsverlust, was die Idee eines lokalen Updates in diesem Falle zunichte macht.

Wie in vorigen Abschnitten herausgestellt ist, kann zusätzlich nicht mit Sicherheit gesagt werden, dass jede so assoziierte Zelle auch von der assoziierten Pose generiert wurde. Dies lässt sich anhand von Abbildung 4.9 zeigen. Durch einen Fehler in der Registrierung im initialen Pfad befindet sich eine Pose an einer fehlerhaften Stelle. Von dieser Pose aus wurde allerdings bereits ein – ebenfalls fehlerhaftes – TSDF Update durchgeführt. Die Daten, die zu dieser Pose gehören befinden sich nun hinter einer Wand, die zuvor von anderen Posen aus erstellt wurde. An dieser Stelle kann nun unmöglich ermittelt werden, welche Pose für die Erstellung der fehlerhaften Wand verantwortlich ist. Da der implementierte Raytracer nicht durch Wände hindurch schauen kann, wird daher ein falscher Teilbereich der Karte mit dieser fehlerhaften Pose assoziiert. Das Problem doppelter Wände ist dabei ein Problem, dass durch akkumulierten Drift im SLAM regelmäßig auftritt und durch Schleifenschlüsse gelöst werden kann. Dazu müssen die fehlerhaften Daten, wie zum Beispiel fehlerhaft positionierte Wände, allerdings auch mit den entsprechenden Posen assoziiert werden können. Diese Prämisse kann mit diesem Ansatz nicht erfüllt werden.

Zusätzlich zum oben beschriebenen Problem existiert ein weiteres Problem, dass die Zellennachbarschaften betrifft. Benachbarte Zellen einer Wand sollten auch in der korrigierten Variante in direkter Nachbarschaft liegen, sodass die lokale Konsistenz der Karte gewährt bleibt. Wird nun eine Zelle von zwei verschiedenen Pose assoziiert und auf Basis eines Mittels der Pose-Änderungen verschoben, die Nachbarzelle allerdings durch einen Diskretisierungsfehler nur von einer Pose aus assoziiert und entsprechend verschoben, werden die beiden Zellen auseinander gezogen. Dies sorgt für ein merkliches Rauschen in der Karte und für zusätzliche Ungenauigkeiten. Eine Lösung hier wäre die lokale Konnektivität der Karte beim Update zu berücksichtigen. Dies wurde im Rahmen dieser Arbeit, besonders aufgrund der oben genannten Probleme allerdings nicht weiter verfolgt.

Um den oben beschriebenen Update-Prozess zu evaluieren, wurden einfache Transformationen, wie eine gleichmäßige Translation oder Rotation des Pfades vorgenommen und ein Kartenupdate auf Basis dieses neuen Pfades durchgeführt. Gleichmäßige Translationen stellten in dieser Hinsicht



**Abbildung 4.9:** TSDF-Karte nach Update durch eine fehlerhaft registrierte Pose (Pose 4, dargestellt in rot). Der fehlerhaft hinzugefügte Teil der TSDF-Karte ist farblich durch einen dunkleren Rot- und Grünton hervorgehoben. Eine Assoziationsbestimmung ausgehend von Pose 4 würde hier nicht den fehlerhaften Teil der Karte assoziieren da dieser hinter einer Wand befindlich ist. Der stattdessen mit dieser Pose assoziierte Teil der Karte wurde ursprünglich von anderen Positionen aus generiert. Der gelbe Rahmen markiert einen Teil der Karte, indem bereits generierte TSDF-Zellen mit den Werten neu erstellter Zellen verrechnet werden müssen. Der neue TSDF-Wert errechnet sich dann gemäß der alten, sowie neuen Gewichte und Werte. Ein mögliches Szenario dieses Updates für den Fall, dass die Gewichte beider Zellen jeweils 1 ist, ist in der Abbildung dargestellt. Es wird deutlich, dass die TSDF-Karte durch die fehlerhaften Daten nun eine Inkonsistenz in den Gradienten aufweist, die nicht ohne Weiteres aufgelöst werden kann. Die Farben der Zellen im Überlappungsbereich wurde auf Basis der Zelle gewählt, die dominiert, also den größeren Einfluss auf das Endergebnis hat.

mit Ausnahme der nicht assoziierbaren Zellen keine Probleme dar. Sobald der Pfad oder Teile des Pfades in eine beliebige Richtung rotiert werden, trifft dies nicht mehr zu und durch die beschriebenen Probleme verliert die Karte ihre lokale Konnektivität und es bleibt lediglich ein inkonsistentes Rauschen. Fast jeglicher räumlicher Informationsgehalt geht verloren.

Der nachfolgende Abschnitt evaluiert die um jetzigen Zeitpunkt gefundenen Erkenntnisse und beschreibt, wie im weiteren Verlauf der Arbeit vorgegangen wird.

## 4.6 Evaluation und Zusammenfassung

Ziel dieses Kapitels ist die die Evaluation des Ansatzes zur Optimierung eines gegebenen Pfades durch Schleifenschlüßen und – damit verbunden – eine Optimierung der initial gegebenen TSDF-Karte auf Basis der zugrunde liegenden Pose-Änderungen. Die vorigen Absätze haben gezeigt, dass in grundlegenden Fällen, wie gleichmäßigen Translationen, ein Update mit dem vorgestellten Ansatz möglich ist. Diese grundlegende Fälle sind allerdings eine Abstraktion, die im realen Fall nicht gegeben ist. Zusätzlich scheitert der Ansatz bereits an der Ermittlung des optimierten Pfades. Wie oben beschrieben ist das Auffinden von Schleifenschlüßen und damit verbunden eine Optimierung des Pfades basierend auf den gegebenen Daten nicht möglich. Zudem gibt es

mehrere Probleme bei der Ermittlung der Assoziationen, wie vergrößerte Verdeckungsbereiche durch die Diskretisierung der TSDF-Karte oder gänzlich falsch eingetragene Teilbereiche der Karte, die wiederum von anderen Teilen der Karte verdeckt und entsprechend nicht mehr assoziiert werden können. Aufgrund der Fülle der genannten Probleme und dem Nichtvorhandensein von Lösungen wird nun an dieser Stelle der erste Ansatz verworfen. Stattdessen wird im Folgenden auf einer größeren Datenbasis gearbeitet, die auch die Nutzung aufgenommener Punktwolken erlaubt. Dies ermöglicht eine Nutzung dieses Ansatzes sowohl innerhalb eines vorhandenen SLAM Ansatzes, als auch losgelöst in einem Nachbearbeitungsschritt. Ziel ist die Untersuchung von Schleifenschlüssen, sowie globalen und partiellen Updates der TSDF-Karte auf Basis dieser erweiterten Datenbasis. Das folgende Kapitel widmet sich nun der Grundlage für die Optimierung der Karte, der Identifikation von Schleifenschlüssen und damit verbunden der Optimierung der Roboter-Trajektorie beziehungsweise des Pfades.

# Kapitel 5

## Schleifenschlüsse und Graph-Optimierung

Dieses Kapitel beschäftigt sich mit der Detektion von Schleifenschlüssen und der damit verbundenen Optimierung der initialen Schätzung einer Trajektorie beziehungsweise eines Pose-Graphen, entlang dessen ein Sensorsystem bewegt wurde. Im Folgenden wird zunächst näher auf den Detektionsschritt eingegangen. Auf Basis dessen wird in den drauf folgenden Abschnitten die in dieser Arbeit verwendete Methode zur Optimierung des Pose-Graphen eruiert.

### 5.1 Detektion von Schleifenschlüssen

Dieser Abschnitt befasst sich mit der Detektion von Schleifenschlüssen in einem Pose-Graphen. Die hier vorgestellte Methode kann sowohl in einem inkrementell erweiterten Pose-Graphen, zum Beispiel als zusätzlicher Schritt in einem SLAM Verfahren, als auch in einem Nachbearbeitungsschritt auf einen bereits fertigen Graphen angewandt werden. Die Methode und die Optimierung des Graphen ist dabei zunächst vollständig losgelöst von der TSDF-Karte, die im Anschluss optimiert wird. Mehr dazu in Kapitel 6. Die vorliegenden initiale Schätzung der Roboter-Trajektorie kann das Ergebnis eines inkrementellen SLAM Ansatzes sein oder lediglich auf Odometrie-Schätzung beruhen.

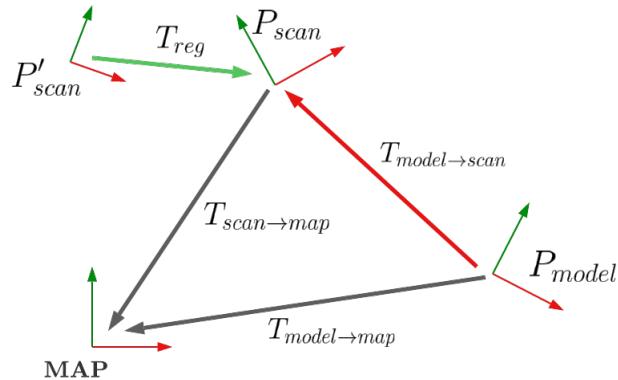
Bevor nach Schleifenschlüssen gesucht werden kann, gilt es zu bestimmen, von welcher Pose aus gesucht werden soll. In einem inkrementellen SLAM Verfahren wäre das jeweils die aktuell betrachtete, zuletzt in den Graphen eingefügte Pose. In einem Nachbearbeitungsschritt wird dieser inkrementelle Prozess imitiert, indem der Pose-Graph, beginnend von der ersten eingefügten Pose, abgelaufen wird. In beiden Fällen wird also ein Schleifenschluss mit Posen gesucht, die früher in den Graphen eingefügt wurden als die aktuelle Pose  $P_{cur}$ . In einem ersten Schritt wird hierzu eine Menge von Schleifenschluss-Kandidaten erstellt. Diese Menge ergibt sich aus der in [6, 40] vorgestellten euklidischen Distanzmetrik, die in dieser Arbeit verwendet wird. Eine Pose  $P_i$  gilt als Schleifenschluss-Kandidat zu  $P_{cur}$ , wenn die euklidische Distanz zwischen den beiden Posen geringer ist als eine parametrisierbare Schwelle  $d_{max}$ . Zusätzlich zu diesem Parameter

wird an dieser Stelle ein weiterer Parameter  $d_{trav}$  eingeführt der die minimale Distanz definiert, die der Sensorsystem entlang des Teilpfades gegeben durch  $P_i$  und  $P_{cur}$  zurückgelegt hat. Um Posen zu identifizieren, die diese Voraussetzungen Erfüllen, wird ein *k-d tree* (*k-d Baum*) [3] verwendet. Ein k-d Baum ist eine Datenstruktur zur Speicherung von (räumlichen) Informationen, die durch assoziative Suchen abgefragt werden können. Ein k-d Baum eignet sich aufgrund der optimierten Laufzeit besonders für räumliche Suchen. Dabei steht das  $k$  für die Dimensionalität des Suchraums [3]. An dieser Stelle wird der k-d Baum zur Speicherung von *3-d* Daten genutzt. Diese ergeben sich aus den Posen des Pfades. Vor jeder Detektion wird ein neuer k-d Baum aus den Translationsanteilen aller zuvor eingefügten Posen aufgebaut. Im Anschluss wird eine Radius-Suche durchgeführt, die alle Daten des k-d Baumes (hier 3-d Punkte) zurückliefert, deren euklidische Distanz zu einer übergebenen Position geringer ist als eine übergebene Schwelle. Die übergebene Position ist dabei der Translationsanteil von  $P_{cur}$  und die übergebene Schwelle  $d_{max}$ . Ergebnis ist eine Menge von Kandidaten für Schleifenschlüsse  $\mathbb{K} = \{K_0, \dots, K_k\}$ . Diese Arbeit verwendet die k-d Baum Implementation der *Pointcloud Library (PCL)* ??.

Über die generierten Kandidaten ist an dieser Stelle lediglich bekannt, dass sie sich im nicht optimierten Pfad in der Nähe der aktuellen Pose  $P_{cur}$  befinden. Diese räumliche Nähe ist an dieser Stelle allerdings nur eine Annahme, die es zu verifizieren gilt. Als Basis für die Verifikation dient die in diesem Ansatz gegebene Datenbasis in Form von zu jeder Pose des Pose-Graphen  $\mathfrak{P}_{init} = \{P_0, \dots, n\}$  zugehörigen Punktwolken  $\mathbb{C} = \{C_0, \dots, C_n\}$ . Für die aktuell betrachte Pose  $P_{cur}$  und die zugehörige Punktwolke wird ein Scan-Matching gegen jeden Kandidaten aus  $\mathbb{K}$  und dessen zugehörigen Punktwolken  $C_i$  durchgeführt und evaluiert. Konvergiert das Scan-Matching mit einer festgelegten Genauigkeit ist der Kandidat validiert. Im Folgenden wird die Punktwolke der aktuell betrachteten Pose  $P_{cur}$  als Scan-Punktwolke  $C_{scan}$  und die zum zu validierenden Kandidaten zugehörige Punktwolke als Model-Punktwolke  $C_{model}$  bezeichnet. Grundlage für das Scan-Matching der beiden Punktwolken ist ein Algorithmus wie *ICP*, *GICP* oder vergleichbare Algorithmen zur Registrierung von Punktwolken. Diese Algorithmen liefern neben einer Information zur Konvergenz in der Regel zusätzlich ein Maß dafür zurück, wie gut die Punktwolken nach der Registrierung aufeinander passen. In dieser Arbeit werden hierzu die Implementationen der Algorithmen der Pointcloud Library [36] verwendet. Diese liefern für beide Algorithmen einen *Fitness-Score* ( $\Gamma$ ) zurück, der die durchschnittliche quadrierte Distanz zwischen einem Punkt der Scan-Punktwolke und dem euklidisch nächste Punkt der Model-Punktwolke nach Registrierung der Scan-Punktwolke an die Model-Punktwolke beschreibt. Nachfolgende Formel zeigt diesen Sachverhalt mit  $s_i$  als aktuellen Scanspunkt und  $m_i$  als zugehörigen, euklidisch nächsten Punkt der Model-Punktwolke und  $N$  als Anzahl der Punkte in der Scan-Punktwolke.

$$\Gamma = \frac{\sum_{i=0}^N \|\vec{m}_i - \vec{s}_i\|^2}{N} \quad (5.1)$$

Liegt der Fitness-Score unter einer vordefinierten Schwelle  $\Gamma_{max}$ , ist der Kandidat validiert. Zusätzlich liefern die Algorithmen die bestimmte finale Transformation  $T_{fin}$  der Registrierung von Scan zu Model. Da GICP und ICP deutlich bessere Ergebnisse erzielen, wenn zwischen den Daten bereits eine Initialschätzung vorliegt, wird eine solche, auf Basis der jeweiligen Pose-Differenzen, genutzt. Die Punktwolkendaten liegen hier jeweils relativ zur Pose, von derer sie aufgenommen



**Abbildung 5.1:** Diese Grafik stellt die Posen und Transformationen dar, die bei der Detektion eines Schleifenschlusses zur Verwendung kommen. Dabei bestimmt  $T_{model \rightarrow scan}$  die Vortransformation vom lokalen Model-Koordinatensystem in das des Scans (dargestellt in rot). In grün dargestellt ist die Transformation  $T_{reg}$ , die von dem verwendeten Algorithmus zur Registrierung der Scan-Punktwolke an die mit  $T_{model \rightarrow scan}$  vortransformierte Model-Punktwolke, ausgegeben wird. Eine Kombination der Transformationen  $T_{reg}$  und  $T_{model \rightarrow scan}$  ergibt die finale, zur Optimierung des Pose-Graphen verwendete Transformationen. Diese Kombination ist in Gleichung 5.3 definiert.

wurden, vor. Für die Initialschätzung wird nun die Model-Punktwolke ins Koordinatensystem der Scan-Punktwolke transformiert. Dazu wird zunächst die Transformation  $T_{model \rightarrow scan}$  über die zugehörigen Posen  $P_{model}$  und  $P_{scan}$  und die zugehörigen Transformationen  $T_{model \rightarrow map}$  und  $T_{scan \rightarrow map}$  von den Posen ins Ursprungskoordinatensystem bestimmt:

$$T_{model \rightarrow scan} = T_{scan \rightarrow map}^{-1} \cdot T_{model \rightarrow map} \quad (5.2)$$

Im Anschluss wird jeder Punkt  $p_{model}^i$  der Punktwolke  $C_{model}$  mit der bestimmten Transformation  $T_{model \rightarrow scan}$  transformiert. Nun ist die Model-Punktwolke in das Koordinatensystem der Scan-Punktwolke, gegeben die aktuellen Pose-Schätzungen, vortransformiert. Diese Vortransformation muss nach der anschließenden Registrierung mittels ICP, GICP oder einem ähnlichen Verfahren für die Berechnung der finalen Transformation berücksichtigt werden. Dies ist in Abbildung 5.1 dargestellt. Sie führt zusätzlich die vom zur Registrierung berechneten Algorithmus bestimmte Transformation  $T_{reg}$ , sowie die sich daraus ergebene neue, approximative Pose  $P'_{scan}$ , von der die Scan-Punktwolke aufgenommen wurde. Die finale Transformation  $T_{scan' \rightarrow model}$  die im weiteren Verlauf für die Optimierung des Pose-Graphen benötigt wird ergibt sich wie folgt:

$$T_{scan' \rightarrow model} = T_{model \rightarrow scan}^{-1} \cdot T_{reg} \quad (5.3)$$

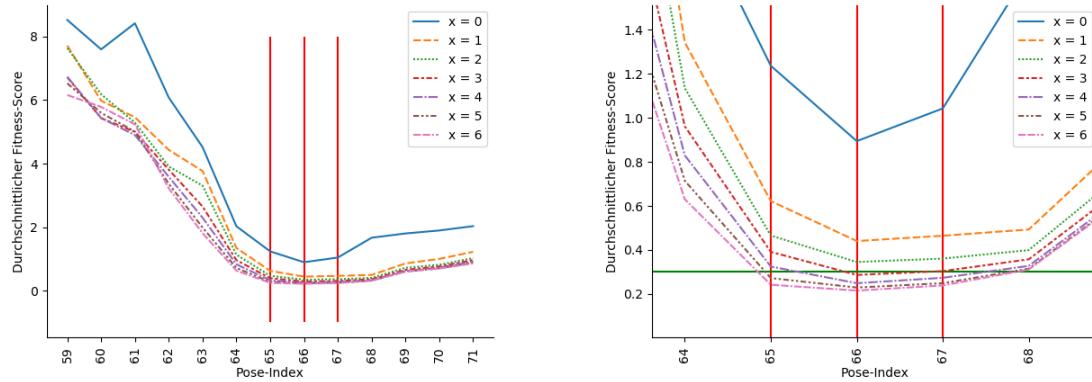
Auf diese Art und Weise können nur wenige Schleifenschlüsse identifiziert werden. Ursache ist zu diesem Zeitpunkt das Scan-Matching, welches zwar in den meisten Fällen konvergiert, jedoch fast keinen der Kandidaten aufgrund zu hoher Fitness-Scores validieren kann. Zusätzlich

sind einige der identifizierten Schleifenschlüsse, besonders in Bereichen von Fluren oder Orten mit wenigen Features, fehlerhaft. Hier sind zwar die genannten Rahmenbedingungen erfüllt, allerdings verschlechtern die Schleifenschlüsse das Ergebnis maßgeblich. Um diese Problem zu lösen wurden mehrere Ansätze implementiert und evaluiert. Dazu wurde zunächst das Problem des Scan-Matching näher betrachtet. Dabei stellt sich heraus, dass für ein gute Transformations-Schätzung der Scan-Matching Algorithmen neben einer guten Initial-Schätzung zusätzlich eine dichtere Model-Punktwolke essentiell ist. Basierend auf der Annahme, dass eine lokale Umgebung  $\{P_{i-x}, \dots, P_i, \dots, P_{i+x}\}$  um eine Pose  $P_i$  konsistent registriert ist, wurde die Model-Punktwolke um die Punktwolken aus der direkten Nachbarschaft, gegeben durch den Parameter  $x$ , angereichert. Dazu wird jeweils die Pose-Differenz zur Model-Punktwolke berechnet und die Punktwolke entsprechend der berechneten Transformation ins Koordinatensystem der Model-Punktwolke angereichert. Ergebnis ist eine deutlich dichtere Punktwolke, was die Korrespondenzfindung für die Scan-Matching Algorithmen deutlich verbessert und so zu einem besseren Endergebnis führt. Abbildung 5.2 zeigt die durchschnittlichen Fitness-Scores aller Schleifenschluss-Kandidaten der jeweiligen Iteration für ein durch  $x$  gegebenes Fenster um die Model-Punktwolke herum.

Ein weiteres bereits angeschnittenes Problem sind Schleifenschlüsse, die zwar die vorgegebenen Rahmenbedingungen erfüllen, allerdings grundsätzlich fehlerhaft sind. Hier ist zum Beispiel in einem Flur das Scan-Matching aufgrund einer sehr Feature armen Umgebung konvergiert und die Validierung auf Basis des Fitness-Scores konnte zusätzlich keinen Fehler bei der Registrierung identifizieren. Dann werden häufig Posen, die in einer initialen Schätzung weit auseinander liegen aufeinander gezogen. Zusätzlich kann es vorkommen, dass das Scan-Matching mit einem guten Fitness-Score konvergiert, obwohl die Umgebungen nicht zueinander passen. Die berechnete finale Transformation ist in diesem Fall so fehlerhaft, dass sie nicht mit der initialen Schätzung vereinbar ist. Aus diesem Grund wurden zwei Validatoren beziehungsweise *Rejector* entwickelt, die neben dem Fitness-Score zusätzliche Validations-Stufen einführen. Dies ist zum einen der *Linien-Rejector* und auf der anderen Seite der *Reichweiten-Rejector*. Diese nutzen die Unsicherheiten der einzelnen Posen aus. Vor Beginn des Algorithmus erfolgt eine Einschätzung über die Sicherheit der initial bestimmten Posen. Diese kann beliebig schlecht gewählt werden um sicherzustellen, dass bei der Optimierung gewünschte Änderungen vorgenommen werden. Dies erhöht allerdings die Wahrscheinlichkeit für fehlerhafte Schleifenschlüsse, die durch die beiden im Folgenden beschriebenen Validatoren nicht erfasst werden können. Kann für eine Initial-Schätzung zum Beispiel aufgrund voriger Erfahrungen ein gewisser Fehler für die Translation und Rotation zwischen aufeinander folgenden Posen abgeschätzt werden, sollte dieser im Folgenden verwendet werden. Die Notwendigkeit einer solchen Evaluationsstufe wird unter anderem in [43] und [46] herausgestellt. Beide Papiere beschreiben, dass die Nutzung einer fehlerhaften Schleifenschlusses verhängnisvolle Auswirkungen auf das Ergebnis der Optimierung des Pose-Graphs hat. Diese Einschätzungen decken sich mit den hier festgestellten Bobachtungen.

### **Linien-Rejector**

Je nach Parametrisierung ist es möglich, dass Schleifenschlüsse zwischen Posen  $P_{cur}$  und  $P_{prev}$  identifiziert werden, deren Zwischen-Posen näherungsweise auf einer Linie liegen. Der maximale Abstand einer Zwischen-Pose zur durch  $P_{cur}$  und  $P_{prev}$  definierten Linie ist mit  $d_{line}$  definiert und parametrisierbar. Standardmäßig ist  $d_{line} = 0.5m$ . Eine beschriebene Identifikation ist im Regelfall



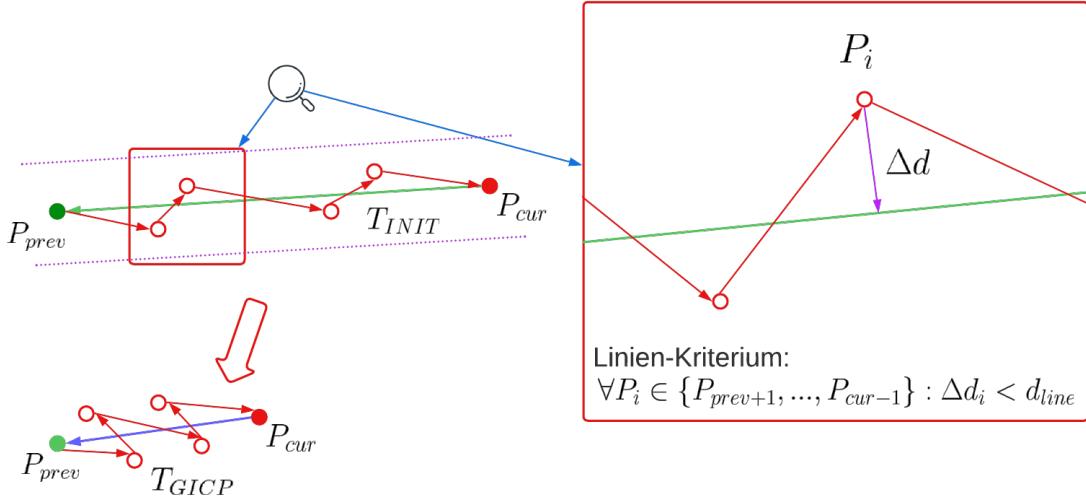
(a) Durchschnittlicher Fitness-Score für gefundene Schleifenschluss-Kandidaten eines Datensatz von Pose 0 bis Pose 80, Posen ohne Kandidaten sind nicht dargestellt.

(b) Vergrößerung des Bereiches von links, in dem Schleifenschlüsse gefunden und validiert wurden. Dargestellt als grüne horizontale Linie ist die parametrisierte Schranke für Schleifenschlüsse.

**Abbildung 5.2:** Diese Grafik zeigt den Einfluss des Fensters für die Anreicherung der Model-Punktwolke bei der Validierung gefundener Schleifenschluss-Kandidaten, gegeben die Größe des Fensters  $x$ . Rote vertikale Linien markieren Posen, an den Schleifenschlüsse detektiert und aufgrund des geringen Fitness-Scores validiert wurden. Die Gesamtmenge der Posen, deren Punktwolken zu einer dichten Model-Punktwolke zusammengeführt werden, beträgt  $2 \cdot x + 1$ . Es ist zu erkennen, dass der durchschnittlich berechnete Fitness-Score mit steigendem  $x$  im Schnitt niedriger ist. Allerdings wird die Verringerung ab einem gewissen Punkt unwesentlich. Hier sind zwischen einer Wahl von  $x = 2$  bis  $x = 6$  nur geringe Unterschiede zu erkennen. Die größten Veränderungen sind zwischen  $x = 0$  und  $x = 2$  zu erkennen. Hier sinkt der durchschnittliche Fitness-Score merklich. Dies trifft auch auf die Ergebnisse im Scan-Matching zu. Diese verbessern sich bei zunehmendem  $x$ , hier sind ebenfalls die größten Veränderungen zwischen  $x = 0$  und  $x = 2$  zu sehen. Die Wahl des Fenster korreliert zusätzlich mit dem durchschnittlichen absoluten Fehler zwischen der durch die Schleifenschlüsse optimierten Trajektorie eines Datensatz und der zugehörigen *Ground-Truth*.

möglich, wenn, wenn  $d_{max} > d_{trav}$ . In Ausnahmefällen kann dies bei bestimmten Trajektorien schon für geringere  $d_{trav}$  der Fall sein. Diese Art von Schleifenschlüssen stellt im Grundsatz kein Problem dar, allerdings ist es durch die Bewertung des Ergebnisses des Scan-Matching anhand des Fitness-Scores besonders in Fluren oder ähnlichen Regionen, die unvorteilhaft für ein Scan-Matching sind, möglich, dass am Schleifenschluss beteiligte Posen ohne Rücksicht auf die initialen Schätzungen und Zwischen-Posen aufeinander gezogen werden. Abbildung ?? zeigt dieses dies schematisch und nimmt zusätzlich Bezug auf die Identifikation von diesen besonderen Fällen.

Wie zuvor beschrieben ist eine mögliche Lösung dieses Problems die Ausnutzung von relativen, lokalen Unsicherheiten zwischen aufeinanderfolgenden Posen. Der Linien-Rejector nutzt dabei die definierten Unsicherheiten für die Translation als Vektor aus den gegebenen Standardabweichungen:  $\vec{\sigma}_t = (\sigma_x, \sigma_y, \sigma_z)$ . Diese können entweder konstant gegeben oder für jede Pose-Differenz aufeinander folgender Posen einzeln, zum Beispiel anhand von Berechnungen im SLAM Ansatz, gegeben sein. Im Folgenden werden die Standardabweichungen als konstant angenommen. Gegeben



**Abbildung 5.3:** Diese Grafik beschreibt die Funktionsweise des Linien-Rejectors. Zusätzlich definiert sie das mathematische Kriterium für eine approximative Linie, gegeben  $d_{line}$ :  $\forall P_i \in \{P_{prev+1}, \dots, P_{cur-1}\} : \Delta d_i < d_{line}$ . Die Abbildung ist zweigeteilt. In der rechten Vergrößerung eines Teilbereichs der oben links dargestellten Trajektorie ist das Linien-Kriterium dargestellt. Die Linie zwischen den beiden Posen  $P_{cur}$  und  $P_{prev}$  ist oben links und in der Vergrößerung in grün dargestellt. Sie wird durch den Translationsanteil von  $T_{INIT}$ , der initial gegebenen Transformation zwischen  $P_{cur}$  und  $P_{prev}$ , sowie den Translationsanteil von  $P_{cur}$  als Stützvektor gegeben. Durch lila gestrichelte Linien ist die Umgebung dargestellt, in der sich das Sensorsystem befindet. In diesem Fall handelt es sich um einen besonders Feature-armen Flur. Bei der Validierung mittels Scan-Matching (in diesem Fall per GICP) wurde die durch  $T_{GICP}$  beschriebene Transformation ermittelt. In diesem Fall ist das Scan-Matching mit einem sehr guten Fitness-Score konvergiert, obwohl die Transformation augenscheinlich fehlerhaft ist. Dies liegt an der beschriebenen Umgebung, die aus Sicht des Laserscanners für verschiedene Posen sehr ähnlich, wenn nicht nahezu identisch aussieht. Dies sind sehr schlechte Voraussetzungen für ein Scan-Matching. Unten links ist die zu erwartende Optimierung der Trajektorie auf Basis der fehlerhaften Transformation  $T_{GICP}$ . Bei den Zwischen-Posen tritt durch die Stauchung der Geraden ein Ziehharmoneika-Effekt auf. Dies hat fatale Auswirkungen auf die generierte Karte und den weiteren Verlauf der Trajektorie.

$P_{cur}$  und  $P_{prev}$ , die Anzahl an Zwischen-Posen  $N_{between}$ , sowie die konstante Standardabweichung der Translation  $\vec{\sigma}_t$  lässt sich nun Konfidenzintervall berechnen, in dem basierend auf der gegebenen Standardabweichung ein gewisser Prozentsatz der für  $P_{cur}$  möglichen liegt. Dies ist in 3D ein räumlicher Bereich. Als Erwartungswert wird die initiale Schätzung für  $P_{cur}$ , genauer gesagt dessen Translationsanteil  $\vec{t}_{cur}$  verwendet. Damit ergibt sich für die untere Grenze  $\vec{t}_u$  und obere Grenze  $\vec{t}_o$  des Konfidenzintervalls unter Ausnutzung der akkumulierten Standardabweichungen zwischen  $P_{prev}$  und  $P_{cur}$ :

$$\vec{t}_u = \vec{t}_{cur} - (N_{between} + 1) \cdot k \cdot \vec{\sigma}_t \quad (5.4)$$

$$\vec{t}_o = \vec{t}_{cur} + (N_{between} + 1) \cdot k \cdot \vec{\sigma}_t \quad (5.5)$$

Dabei bezeichnet  $k$  die verwendete standardisierte Intervallgrenze. Im Folgenden wird hierfür 1 verwendet, eine beliebige Anpassung dieses Wertes ist möglich. Für  $k = 1$  werden für eine gegebene Standardabweichung im Konfidenzintervall etwa 80% bis 85% der möglichen relativen Pose-Änderungen zwischen aufeinander folgenden Posen abgedeckt. Der Prozentsatz des durch  $\vec{t}_u$  und  $\vec{t}_o$  abgedeckten Volumens berechnet sich aus folgender Potenz:

$$\prod_{i=0}^{N_{between}} 0.8 \quad (5.6)$$

Zugrunde liegt die Schätzung des Prozentsatzes, der durch die Intervallgrenzen, gegeben  $k$  abgedeckt wird (hier etwa 80%). Für 4 Zwischen-Posen beträgt die Abdeckung in diesem Fall in etwa 33%. Für eine größere Abdeckung ist ein größeres  $k$  zu wählen. Mit zunehmender Anzahl an Zwischen-Posen wird der durch den Rejector abgedeckte Bereich verhältnismäßig immer kleiner, obwohl er linear vergrößert wird. Dies hat eine sehr strenge Behandlung von Schleifenschlüssen auf Linien zur Folge. Mit einem größeren  $k$  kann dies entschärft werden. Liegt  $P_{cur}$  nach Bestimmung der neuen Transformation  $T_{GICP}$  außerhalb des durch  $\vec{t}_u$  und  $\vec{t}_o$  beschriebenen Volumens, der gefundene Schleifenschluss als ungültig angesehen. Liegt die neue Pose innerhalb des Volumens, ist sie validiert. Auf diese Weise konnten in einem Beispieldurchlauf für eine Fenster-Größe von  $x = 0$  und  $\Delta d = 2.0m$  bei einem Datensatz mit 200 Posen 8 fehlerhafte Schleifenschlüsse identifiziert und verworfen werden. Mit größerer Fenstergröße reduziert sich die Anzahl dieser fehlerhaften Schleifenschlüsse. So konnten bereits bei einer Größe von  $x = 2$  in diesem Datensatz keine fehlerhaften Schleifenschlüsse identifiziert werden. Diese sind jedoch auch weiterhin nicht ausgeschlossen, weshalb der Rejector als weitere Sicherheitsschranke hinter das Scan-Matching geschaltet wird.

### **Reichweiten-Rejector**

Der *Reichweiten-Rejector* basiert auf dem identischen Prinzip wie der zuvor erläuterte Linien-Rejector. Hier wird zusätzlich zur Standardabweichung in der Translation auch die Standardabweichung in der Rotation berücksichtigt. Zusätzlich ist das Vorhandensein einer Linie keine Voraussetzung für diesen Rejector. Alle anderen mathematischen Verhältnisse aus dem oben vorgestellten Rejector treffen so auch hier zu und werden analog sowohl für die Translation, als auch für die Rotation angewandt. Dieser Rejector greift ist dem Linien-Rejector nachgeschaltet.

Der nachfolgende Abschnitt beschäftigt sich mit der Optimierung des Pose-Graphen auf Basis identifizierter Schleifenschlüsse.

## **5.2 Optimierung des Pose-Graphen**

Für die Optimierung des Pose-Graphen wird in diesem Fall die C++ Bibliothek GTSAM [14] verwendet. GTSAM implementiert die Fusion von Sensor Daten für Anwendungen im Bereich von Robotik und Computergrafik und kommt insbesondere in SLAM-Ansätzen zum Einsatz [14]. Als unterliegende Datenstruktur für den hier verwendeten Anwendungsfällen dient ein Faktorgraph. Faktorgraphen sind grafische Modelle, die sich gut für komplexe Schätzungsprobleme wie SLAM und deren Modellieren eignen. Ein Faktorgraph ist ein bipartiter beziehungsweise paarer Graph,

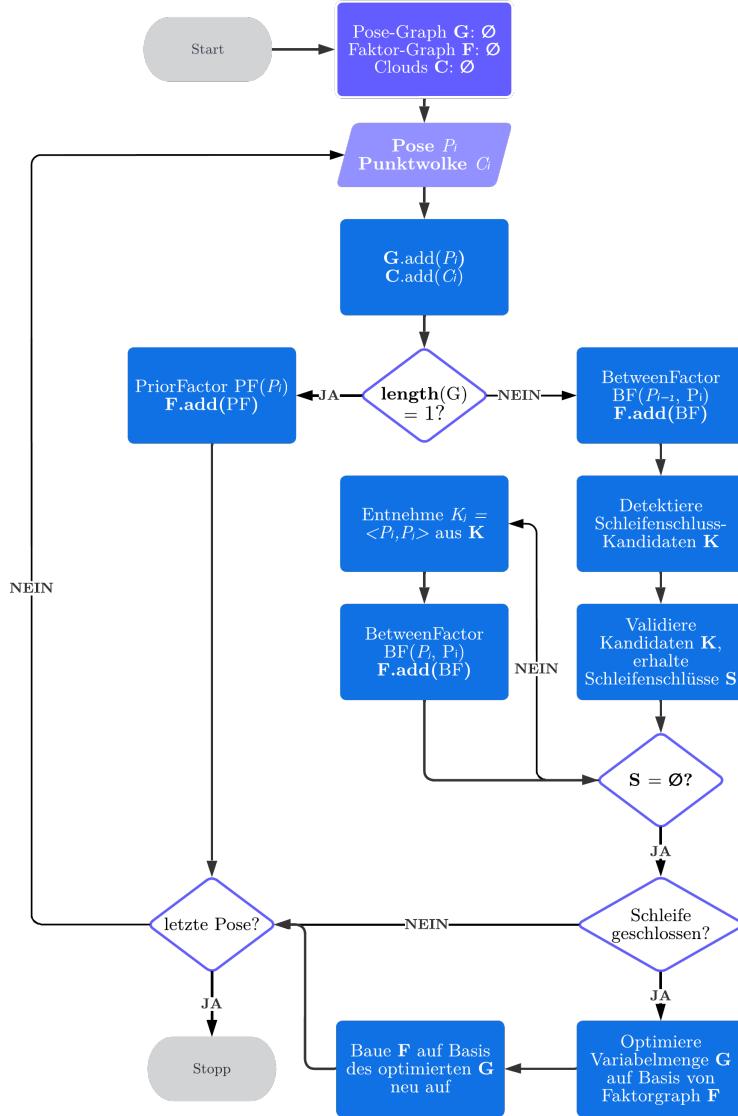
der Beziehungen zwischen zwei Mengen darstellt. Der Graph besteht aus Faktoren beziehungsweise *Graph-Constraints*, die mit der Menge der *Variablen* verbunden sind. Dabei stellen die Variablen die unbekannten Zufallsvariablen des Schätzproblems dar, während die Faktoren probabilistische Beschränkungen oder Voraussetzungen für diese Variablen darstellen, die aus Messungen wie Odometrie, *IMU (Intertial Measurement Unit)*-Schätzungen, gesichteten Landmarken oder SLAM-Schätzungen abgeleitet werden [14]. Im Folgenden sind die Zufallsvariablen des Schätzproblems die gesuchten optimierten Posen des Pose-Graphs. Als Faktoren werden die initialen Pose-Schätzungen verwendet, die durch eine zusätzliche Vorregistrierung mittels GICP verbessert werden, sowie die identifizierten Schleifenschlüsse. GTSAM stellt für diese Faktoren vordefinierte Klassen, die in Tabelle 5.1 vorgestellt werden.

In den Faktor-Graph selbst werden beim Durchlauf des Algorithmus lediglich die beschriebenen Faktoren eingefügt. Zu einem beliebigen Zeitpunkt besteht er aus dem initialen Prior-Faktor der ersten Pose, sowie mehreren Between-Faktoren für aufeinander folgenden Posen und Schleifenschlüsse. Der Verbund mit der Menge der Variablen wird durch die Verwendung von Indices erreicht. Dabei erhält der Prior-Faktor den Index 0, der er sich lediglich auf die erste Pose des Pose-Graphen bezieht, die mit 0 indiziert ist. Between-Faktoren erhalten jeweils zwei Indices, die ebenfalls den entsprechenden Posen des Pose-Graphen zugeordnet werden können. Die beiden Indices legen fest, zwischen welchen Variablen der Faktor gilt und in welche Richtung er gilt. Der grundlegende Ablauf bei dem Einfügen neuer Faktoren in den Faktorgraphen und der anschließenden Optimierung der Variablenmenge, hier dem verwendeten Pose-Graphen, ist in Abbildung 5.4 dargestellt.

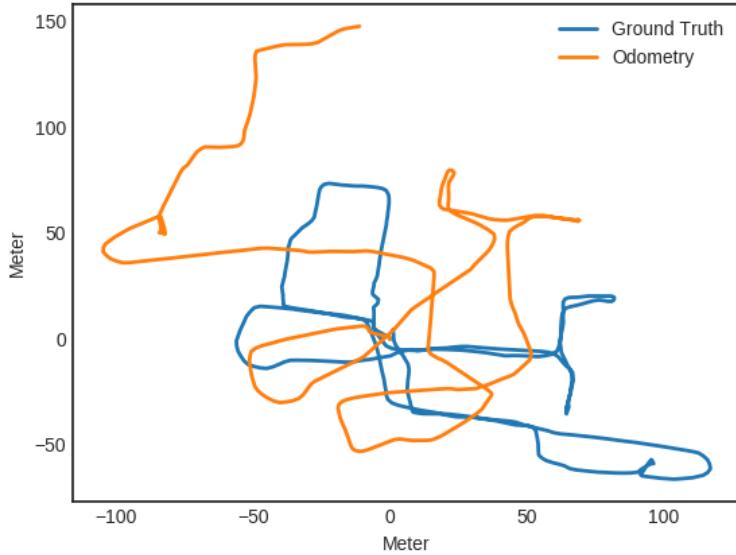
Im Folgenden wird der hier vorgestellte Ansatz auf Basis mehrerer Datensätze evaluiert.

### 5.3 Evaluation der Graph-Optimierung

Dieser Absatz befasst sich mit der Evaluation des zuvor vorgestellten Ansatzes zur Optimierung des Pose-Graphen mittels identifizierter Schleifenschlüsse unter Verwendung der GTSAM Bibliothek [14]. Wie beschrieben werden zur Evaluation des Ansatzes mehrere Datensätze verwendet, die aus einer Initialschätzung des Pose-Graphen mit einer zu jeder Pose  $P_i$  zugehörigen Punktfolge  $C_i$ , die relativ zum Koordinatensystem der zugehörigen Pose gesehen ist. Zu den verwendeten Datensätzen gehört sowohl der *Hannover-1* Datensatz der Universität Osnabrück mit zugehöriger Initialschätzung des Pose-Graphen durch Odometrie und einer *Ground-Truth*, die in [41] vorgestellt wird. Die *Ground-Truth* bezeichnet eine Pose-Historie, die die (näherungsweise) realen Posen enthält, von denen die Daten aufgenommen wurden. Dies erlaubt einen direkten Vergleich der mit diesem Ansatz optimierten Trajektorie mit der *Ground-Truth*. Zusätzlich wurden im Laufe dieser Arbeit weitere Datensätze aufgenommen. Aus diesen Datensätzen erfolgte zunächst die Bestimmung einer Initialschätzung des Pose-Graphen mit einer überarbeiteten Variante des in [48] vorgestellten SLAM-Ansatzes. Bei einer visuellen Überprüfung der so generierten Initialschätzungen fallen direkt mehrere Fehler wie doppelte Wände auf, die durch eine Fehlerfortpflanzung beim SLAM auftreten. Im Zuge dieser Evaluation soll überprüft werden ob diese Fehler durch diesen Ansatz kompensiert werden können.



**Abbildung 5.4:** Dieses Flussdiagramm beschreibt den algorithmischen Ablauf der Graph-Optimierung unter besonderer Betrachtung der in den Faktorgraphen einzufügenden Faktoren. Für den Fall, dass Schleifenschlüsse gefunden werden, wird die Menge der Variablen, hier der Pose-Graph auf Basis der in den Faktorgraphen eingefügten Faktoren optimiert. Als Optimierer wird hier der in GTSAM implementierte *Levenberg-Marquardt-Optimizer* verwendet, der die von Levenberg [24] und Marquard [28] vorgeschlagene Lösung von nicht-linearen *Least-Squares* Problemen implementiert. Im Anschluss an die durchgeführte Optimierung, muss der Faktor-Graph  $F$  auf Basis der neuen Pose-Differenzen in  $G$  neu aufgebaut werden. Dies wird so lange durchgeführt, bis das letzte Pose-Punktwolke Paar der initialen Schätzung abgearbeitet ist. Um die Pose-Differenzen der initialen Schätzung auch nach der Optimierung des Teilgraphen beim Einfügen einer neuen Pose  $P_i$  zu erhalten wird mit *Pose-Deltas* gearbeitet. Dazu wird immer die zuletzt eingefügte Pose der initialen Schätzung gespeichert, bei einer neuen Pose das Pose-Delta beziehungsweise die Pose-Differenz zwischen der neuen und der gespeicherten Pose berechnet und auf die zuletzt eingefügte Pose in  $G$  angewandt.



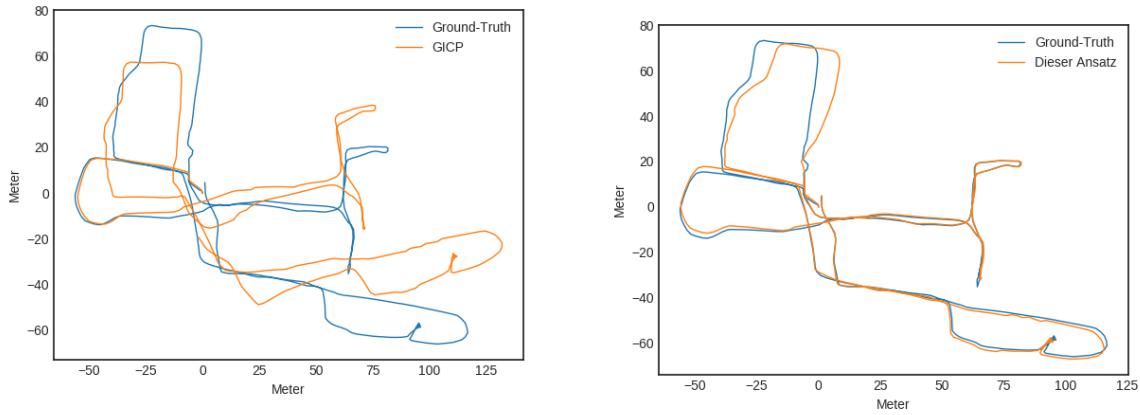
**Abbildung 5.5:** Diese Grafik zeigt die Ground-Truth des Hannover-1 Datensatzes im Vergleich mit der initialen Odometrieschätzung. Es ist ersichtlich, dass die Odometrieschätzung signifikante Fehler aufweist, sodass die Trajektorien stark divergieren.

### 5.3.1 Datensatz: Hannover-1

Zunächst erfolgt eine Evaluation des Hannover-1 Datensatzes. Abbildung 5.5 zeigt eine Gegenüberstellung der beschriebenen Ground-Truth des Datensatzes mit der durch Odometrie gegebenen Initialschätzung. Hier ist eine deutliche Differenz zwischen den beiden Pose-Graphen zu erkennen, die nicht ausschließlich durch die Integration von Schleifenschlüssen aufgelöst werden kann. Aus diesem Grund wird eine Vorregistrierung der aktuell betrachteten Initialschätzung der Pose  $P_i$  mit den zuvor in den Pose-Graphen eingefügten Posen mittels GICP vorgenommen. Lediglich für die erste Pose wird die initiale Schätzung verwendet. Wie zuvor erläutert und in Abbildung 5.2 schematisch dargestellt ist, verbessert eine Anreicherung der Model-Punktwolke mit den Punktwolken der benachbarten Posen das Ergebnis der Registrierung maßgeblich. Diese Erkenntnis kommt auch bei der Vorregistrierung zum Einsatz. Der erörterte Vorregistrierungsschritt findet zusätzlich bei den anderen Datensätzen Verwendung, um eine lokale Konsistenz der Daten zu gewährleisten.

Um die Effektivität der Schleifenschlüsse im hier vorgestellten Ansatz herauszustellen, erfolgt ein Vergleich mit einer Registrierung des Datensatzes durch GICP. Dies ist in Abbildung 5.6 dargestellt. Zu erkennen ist eine deutliche Optimierung des Pose-Graphen durch die Einführung der Schleifenschlüsse. Lediglich eine Teilschleife des Graphen weicht im Vergleich stärker von der Ground-Truth ab. Hier lag zunächst ein großer Fehler in der Vorregistrierung vor, der von den identifizierten Schleifenschlüssen nur zum Teil korrigiert werden konnte. Dies wird hier zusätzlich anhand einer weiteren Grafik deutlich gemacht, die den absoluten Fehler in der Translation

eingehen auf  
inkompatible  
Koordinatensystem  
Situation und  
entsprechend  
notwendige  
Transformation



(a) Vergleich einer Registrierung des Datensatzes mittels GICP, basierend auf den initial geschätzten Posen, mit der Ground-Truth.

(b) Vergleich des hier vorgestellten Ansatzes mit der Ground-Truth.

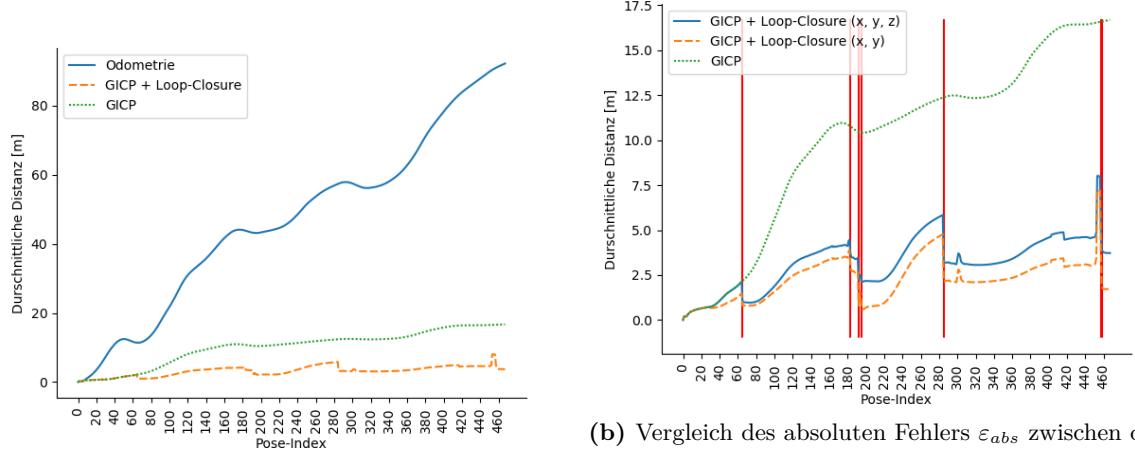
**Abbildung 5.6:** Diese Grafik zeigt einen Vergleich des nur mit GICP registrierten Ergebnisses auf der linken Seite mit dem Ergebnis des hier vorgestellten Ansatzes, der neben einer Vorregistrierung mit GICP zusätzlich Schleifenschlüsse integriert, auf der rechten Seite. Beide Ergebnisse sind jeweils im Vergleich zur genannten Ground-Truth dargestellt. Es ist zu erkennen, dass die Registrierung des Datensatzes mittels GICP, basierend auf den initial geschätzten Posen eine deutliche Verbesserung erzielt, jedoch weiterhin große Abweichung zur Ground-Truth vorliegen. Der hier vorgestellte Ansatz nutzt die durch GICP vorregistrierten Daten und führt zusätzlich eine Optimierung des Graphen mittels Schleifenschlüssen ein. Dies verbessert das Ergebnis unter Betrachtung der Ground-Truth signifikant.

zwischen einer Pose  $P_i$  des mit diesem Ansatz korrigierten Pose-Graphen mit der zugehörigen Pose  $P_i^{GT}$  der Ground-Truth vergleicht. Siehe dazu Abbildung 5.7. Dabei ist der absolute Fehler  $\varepsilon_{abs}$  für die aktuelle Anzahl an Posen  $n_{cur}$ , sowie den Translationsanteilen der Posen des mit diesem Ansatzes korrigierten Pfades  $\vec{t}_i$  und der Ground-Truth  $\vec{t}_i^{GT}$  wie folgt definiert:

$$\varepsilon_{abs} = \frac{\sum_{i=0}^{n_{cur}} \left\| \vec{t}_i^{GT} - \vec{t}_i \right\|}{n_{cur}} \quad (5.7)$$

Die Abbildung 5.7 zeigt dabei die deutlichen Verbesserungen des absoluten Fehlers durch die Nutzung von GICP und die weitere Verbesserung durch die Nutzung von Schleifenschlüssen. Ein direkter Vergleich mit den Ergebnissen aus [41] ist an dieser Stelle nicht möglich, da diese nur für einen anderen Datensatz gegeben sind. In Abbildung A.2 im Anhang ist eine Grafik aus [41] platziert, anhand derer ein visueller Vergleich mit den hier erzielten Ergebnissen ermöglicht wird. Es ist zu erkennen, dass der präsentierte Ansatz in diesem Datensatz an vielen Stellen genauer ist als der Ansatz aus [41]. Daran ändern auch die in [41] genannten Post-Processing Schritte nichts.

Im Folgenden wird der Ansatz auf Basis weiterer Datensätze der Universität Osnabrück validiert.



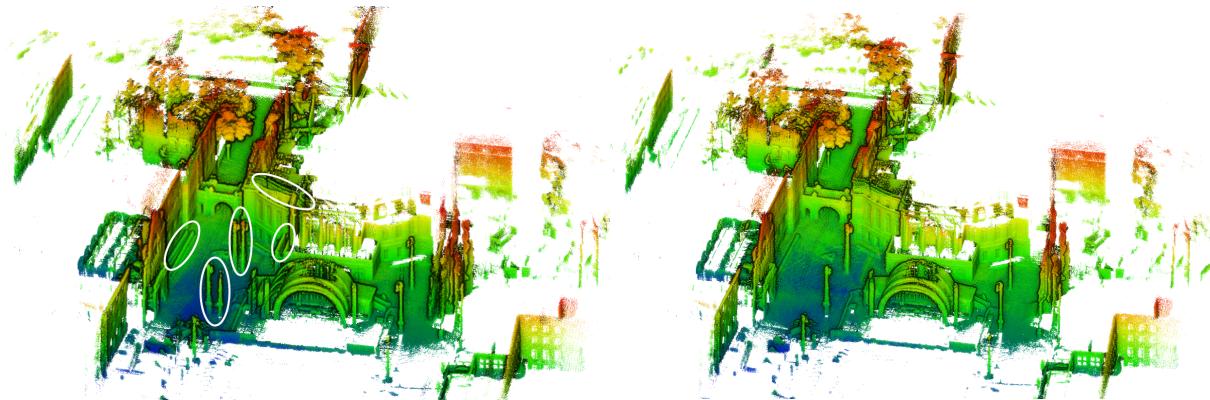
(a) Vergleich des absoluten Fehlers  $\varepsilon_{abs}$  zwischen der initialen Schätzung, des Pose-Graphen nach Registrierung mit GICP und dem Ergebnis des hier vorgestellten Ansatzes mit der Ground-Truth.

(b) Vergleich des absoluten Fehlers  $\varepsilon_{abs}$  zwischen dem Pose-Graphen nach Registrierung mit GICP und dem Ergebnis des hier vorgestellten Ansatzes mit der Ground-Truth. Rote vertikale Linien zeigen dabei die Schleifenschlüsse durch die der absolute Fehler um mindestens 10% reduziert wurde. Die absolute Anzahl an Schleifenschüssen ist deutlich höher.

**Abbildung 5.7:** Diese Grafik vergleicht den absoluten Fehler  $\varepsilon_{abs}$  in der Translation zwischen einer Pose  $P_i$  mit der zugehörigen Pose  $P_i^{GT}$  der Ground-Truth. Zusätzlich zum absoluten Fehler dieses Ansatzes wurde in der rechten Abbildung zusätzlich der absolute Fehler unter Vernachlässigung der z-Achse untersucht. Diese Untersuchung wurde so bereits in [41] durchgeführt, da der aufgenommene Datensatz aufgrund der Konfiguration des Sensorsystems bei der Registrierung aus unbekannten Gründen eine Kurvenform in der z-Achse annimmt. Aus diesen Grund wurde an dieser Stelle ebenfalls eine Projektion der Daten auf die  $z = 0$  Ebene vorgenommen und der entsprechende Fehler verglichen. Dieser ist mit einem durchschnittlichen absoluten Fehler von  $1.7m$  deutlich geringer als der finale Fehler ohne die Projektion, der bei  $3.7m$  liegt.

### 5.3.2 Datensatz: Chemnitzer Opernhaus

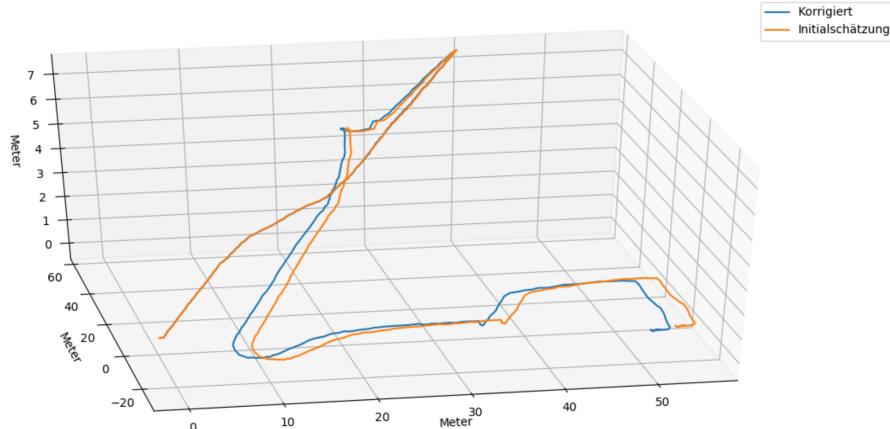
Ein weiterer Datensatz der Universität Osnabrück ist eine Aufnahme des Vorplatzes der Oper in Chemnitz. Grundlage für die Optimierung mit dem hier vorgestellten Ansatz ist eine Initialschätzung des Pose-Graphen mit einer abgewandelten Variante des in [48] vorgestellten SLAM-Ansatzes. Ein Ausschnitt der zur Initialschätzung zugehörigen Punktwolke ist in Abbildung 5.8 dargestellt. Hier wird aufgrund der gekennzeichneten doppelten Wände und Objekte deutlich, dass ein akkumulativer Fehler in der bestimmten Initialschätzung vorliegt. Dieser Fehler soll nun mit Hilfe des hier vorgestellten Ansatzes korrigiert werden. Dazu wird der Pose-Graph wie in Abbildung 5.4 vorgestellt optimiert. Das Ergebnis dieser Optimierung ist die in Abbildung 5.9 gekennzeichnete Anpassung des Pose-Verlaufs. Die Anpassung der Punktwolke auf Basis des korrigierten Pfades wird durch eine Transformation der zu  $P_i$  zugehörigen Punktwolke  $C_i$ . Die dazu verwendete Transformation ist die Transformation von  $P_i$  ins Koordinatensystem der Karte:  $T_{P_i \rightarrow MAP}$ . Das Ergebnis der Korrektur ist ebenfalls in Abbildung 5.8 zu erkennen.



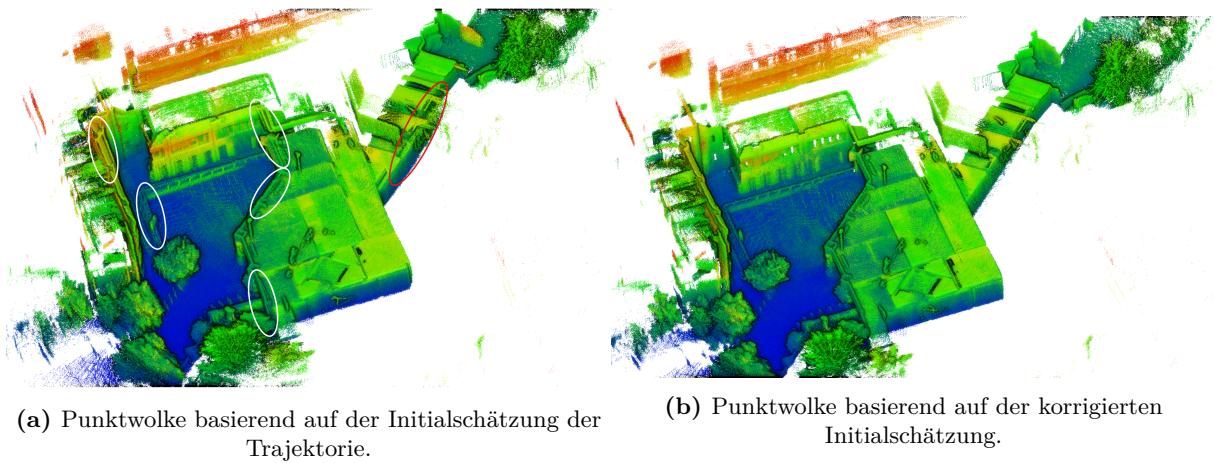
(a) Punktfolke basierend auf der genannten Initialschätzung der Trajektorie.

(b) Punktfolke basierend auf der mit dem hier vorgestellten Ansatz optimierten Trajektorie.

**Abbildung 5.8:** Diese Grafik zeigt einen Vergleich der Punktfolken der Chemnitzer Oper vor und nach der in diesem Ansatz angewandten Korrektur. Zu erkennen ist eine deutliche Verbesserung des Gesamtbildes der Punktfolke durch die Nutzung der Schleifenschlüsse. Doppelte Wände durch akkumulative Fehler konnten nahezu vollständig kompensiert werden.



**Abbildung 5.9:** Grafische Darstellung der Initialschätzung der Trajektorie im Vergleich mit dem korrigierten Pfad. Im linken Teil der Abbildung sind doppelte Objekte und Wände in der Punktfolke gekennzeichnet, die durch einen akkumulativen Fehler im SLAM-Verfahren generiert wurden. Es ist eine deutliche Anpassung der Trajektorie zu beobachten. Diese Anpassung sorgt für die in Abbildung 5.8 erkennbare Kompensation der Fehlerakkumulation und resultiert in einem signifikant besseren Ergebnis, welches keine erkennbaren doppelten Wände ausweist. Die schräge Ausrichtung des Pfades – und damit zusammenhängend auch der Punktfolke – im Raum beruht auf der schrägen Position des Laserscanners. Zum Zeitpunkt der Aufnahme der Daten wurde dieser leicht schräg auf dem Kopf der Person positioniert, die die Daten aufgenommen hat. Dies gilt ebenfalls für den in Abbildung 5.11 dargestellten Verlauf des Pose-Graphen.



**Abbildung 5.10:** Wie Abbildung 5.8 zeigt auch diese Abbildung einen Vergleich der Punktwolken vor und nach Korrektur des in diesem Kapitel vorgestellten Algorithmus. Im linken Teil der Abbildung sind doppelte Objekte und Wände in der Punktwolke gekennzeichnet, die durch einen akkumulativen Fehler im SLAM-Verfahren generiert wurden. Auch hier ist eine signifikante Verbesserung der Trajektorie, erkennbar an der kontinuierlichen Punktwolke, die keine doppelten Wände oder Objekte enthält, zu beobachten.

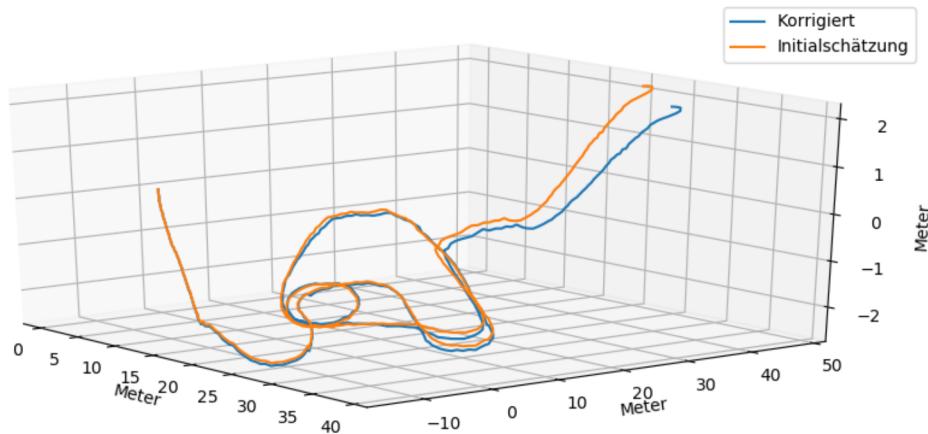
### 5.3.3 Datensatz: Campus Universität Osnabrück

Bei diesem Datensatz handelt es sich um einen Teil des Physikgebäudes der Universität Osnabrück inklusive der Tiefgarage mit Durchgang. Die Evaluation dieses Datensatzes erfolgt entsprechend des vorigen Absatzes und ist in Abbildung 5.10 und 5.11 dargestellt. Zu erkennen ist, dass auch hier eine Kompensation der Fehlerfortpflanzung durch den hier vorgestellten Ansatz erreicht werden konnte.

Die in diesem Kapitel entwickelte Lösung wurde hier zunächst vollständig abgekapselt von der TSDF-Karte betrachtet. Dies wird im nachfolgenden Kapitel nun auf Basis der hier vorgestellten Lösung zur Kompensation von akkumulierten Fehler durch die Integration von Schleifenschlüssen und den Ausführungen aus Kapitel 4 weiter verfolgt.

## 5.4 Kapitel-Zusammenfassung

In diesem Kapitel wurde die Detektion von Schleifenschlüssen und die darauf aufbauende Optimierung des Pose-Graphen behandelt. Dazu wurde zunächst ein Ansatz zur Detektion der Schleifenschlüsse eruiert und auf das Problem invalider beziehungsweise fehlerhafter Schleifenschlüsse eingegangen. Zur Lösung dieses Problems wurden zwei implementierte Validatoren beziehungsweise Rejector implementiert und vorgestellt. Dadurch können fehlerhafte Schleifenschlüsse identifiziert und verworfen werden. Dies führt zu einem deutlich besseren Ergebnis der Optimierung. Für die Optimierung selbst kommt die Bibliothek GTSAM zum Einsatz. Hier wurde die dazu verwendete Datenstruktur des Faktor-Graphen eingeführt und dessen Funktionsweise, insbesondere über die verwendeten Faktoren, erläutert. Der vorgestellte Ansatz liefert gute Ergebnisse und Vergleiche mit anderen Lösungsansätzen zeigen ähnliche und zum Teil bessere



**Abbildung 5.11:** Grafische Darstellung der Initialschätzung der Trajektorie im Vergleich mit dem korrigierten Pfad. Es ist eine deutliche Anpassung der Trajektorie zu beobachten. Diese Anpassung sorgt für die in Abbildung 5.10 erkennbare Kompensation der Fehlerakkumulation und resultiert in einem deutlich besseren Ergebnis, welches keine erkennbaren doppelten Wände ausweist.

Ergebnisse, wie zu sehen in der Evaluation des Hannover-1 Datensatzes.

an dieser Stelle könnte noch eine Menge an Abbildungen folgen, die die Ergebnisse in Abhängigkeit von mehreren Ursachen beschreiben

ggf. auf andere Scan-Matching Verfahren eingehen (ICP, GICP, Teaser++, VGICP)

Zeitmessungen?

**Tabelle 5.1:** Verwendete GTSAM-Faktoren und deren Funktionsweise.

Faktor	Beschreibung	Nutzung
<b>Prior-Faktor</b>	Definiert ein initiales Rauschen für die erste Pose des Pose-Graphen. Dieser Faktor ist der einzige verwendete Faktor, der einen absoluten Pose-Constraint beziehungsweise Faktor definiert. Alle anderen Faktoren sind relative Faktoren zwischen zwei Posen, gegeben durch ihre Indices. Aus diesem Grund wählt [40] an dieser Stelle ein großes initiales Rauschen, um die Optimierung nicht durch eine zu statische erste Pose einzuschränken. [40] definiert einen 6D Varianz-Vektor, der die Varianzen der Rotations- und Translationskomponenten (in dieser Reihenfolge, in $\text{rad}^2$ und $\text{m}^2$ ) enthält. Dieser lautet wie folgt: $(10^{-2}, 10^{-2}, \pi \cdot \pi, 10^8, 10^8, 10^8)^T$ . Dies wurde in dieser Arbeit zunächst übernommen und später parametrisierbar gemacht. Die in dieser Arbeit verwendeten Default-Werte lauten: $(10^{-2}, 10^{-2}, 10^{-2}, 0.064, 0.064, 0.064)^T$ . Diese orientieren sich an dem Ansatz von [16].	Der Prior-Factor wird insgesamt einmal für das definierte initiale Rauschen der ersten Pose verwendet.
<b>Between-Faktor</b>	Definiert einen relativen Pose-Constraint zwischen zwei Posen $P_i$ und $P_j$ , gegeben durch deren Indices $i$ und $j$ . Dieser Constraint ist gegeben als 3D Pose-Differenz, bestehend aus Rotation und Translation. Hierfür stellt GTSAM die Klasse <i>Pose3</i> zur Verfügung. Auch für diesen Faktor kann neben dem relativen Constraint zwischen zwei Posen auch eine Unsicherheit definiert werden. Für aufeinanderfolgende Posen ist diese parametrisch gegeben (Default: $(10^{-2}, 10^{-2}, 10^{-2}, 0.064, 0.064, 0.064)^T$ ), für identifizierte Schleifenschlüsse wird der beim Scan-Matching resultierende Fitness-Score $\Gamma$ verwendet: $(\Gamma, \Gamma, \Gamma, \Gamma, \Gamma, \Gamma)^T$ . Bei dieser Entscheidung wurde sich an [40] orientiert.	Dieser Faktor findet sowohl zur Beschreibung der Pose-Differenzen aufeinanderfolgender Posen (gegeben durch die gegebenenfalls mit GICP optimierte, initiale Schätzung), als auch für die Beschreibung der im Scan-Matching ermittelten Pose-Differenz zwischen den an Schleifenschlüssen beteiligten Posen.

## Kapitel 6

# Karten-Update Strategien

Dieses Kapitel basiert auf den Ausführungen in Kapitel 4. Dabei wurde herausgestellt, dass ein Update der Karte ohne eine zusätzliche Datenbasis in der Nachbehandlung aufgrund einer Vielzahl an Problemen nicht möglich ist. Im Folgenden wird das Problem auf der um die Menge an Punkt-  
wolken  $\mathbb{C}$  erweiterten Datenbasis neu betrachtet. Dabei wird das Problem selbst neu aufgerollt.  
Anstelle in einem fertigen Pose-Graphen wie in Kapitel 5 beschrieben nach Schleifenschlüssen zu suchen, den Graphen auf Basis der identifizierten Schleifenschlüsse zu optimieren und darauf beruhend ein Update auf einer bereits fertigen Karte durchzuführend wird nun ein inkrementelles Vorgehen angestrebt. Ziel ist die Möglichkeit zu bieten, den Ansatz in einen existierenden, auf einer TSDF-Karte beruhenden, SLAM-Algorithmus zu integrieren. In einer Nachbearbeitung ist es nicht zwingend notwendig die Karte nach jedem identifizierten Schleifenschluss und der darauf beruhenden Graph-Optimierung ein Update der Karte durchzuführend, da die TSDF-Karte selbst für den vorgestellten Optimierungsprozess, der auf den Punkt-  
wolken  $\mathbb{C}$  beruht, nicht benötigt wird. Innerhalb eines auf der TSDF-Karte operierenden SLAM-Ansatzes wie [16] ist es allerdings unerlässlich, dass die Karte in jedem Inkrement auf dem neusten Stand ist um eine konsistente Registrierung neuer Daten an die Karte gewährleisten zu können.

Um dieses Ziel zu erreichen, muss nach jedem Inkrement, in dem eine Graph-Optimierung vorgenommen wurde ein Update der bisher erstellten Karte durchgeführt werden. Da eine sichere und lückenlose Ermittlung von Datenassoziationen basierend auf den Posen  $\mathbb{P}$  und der TSDF-Karte nicht ohne weiteres möglich ist, ist an dieser Stelle eine andere Herangehensweise an das Problem des Updates gefragt. In einem ersten Schritt wird hier ein *Greedy*-Ansatz gewählt. Ziel eines solchen Ansatzes ist ein Problem auf eine möglichst einfache Weise zu lösen und dabei längere Laufzeiten der gefundenen Lösung in Kauf zu nehmen. Eine möglichst einfache Lösung beim Update der Karte besteht darin zunächst vollständig auf lokale Updates zu verzichten und stattdessen die gesamte Karte zu löschen und neu zu generieren. Dies ist bezogen auf die Laufzeit besonders bei großen Datensätzen keine gute Idee, da auch Teile der Karte vollständig gelöscht und neu generiert werden, die keines Updates bedürfen. Aus diesem Grund wird im weiteren Verlauf dieses Kapitel zusätzlich auf ein partielles, lokales Update der Karte eingegangen und die benötigten Voraussetzungen und Fallstricke beschrieben. Ziel ist hier eine erhebliche

Reduktion der Laufzeit. Zunächst wird im folgenden Abschnitt auf das beschriebene globale Update eingegangen.

## 6.1 Globales Update der Karte

Dieser Abschnitt befasst sich mit dem beschriebenen Greedy-Ansatz zur Lösung des Kartenupdates. Ziel ist das Löschen der gesamten TSDF-Karte und die nachfolgende Regeneration der Karte basierend auf der erweiterten Datenbasis. Im ersten Schritt wird betrachtet, wie die Karte am effizientesten gelöscht werden kann. Hier lohnt sich eine Betrachtung des Datenflusses zwischen der lokalen und globalen Karte. Dieser wurde in Kapitel 3 bereits kurz angeschnitten. Die globale Karte kapselt die Funktionalität zur Serialisierung und Deserialisierung von Daten basierend auf der HDF5-Datei als Speichermedium. Die globale Karte tauscht die benötigten Daten Chunk weise mit der HDF5 aus. Jeder Chunk beinhaltet eine fest definierte Anzahl an TSDF-Gewichten und zugehörigen Werten und deckt einen vorgegebenen Bereich der globalen Karte ab, der über den Index des Chunks definiert ist. Die lokale Karte ist ein 3D Fenster mit vorgegebenen Seitenlängen, welches den aktuell betrachteten Teil der globalen Karte enthält und über die globale Karte wandern kann. Die lokale Karte liefert dabei eine Abstraktion zur globalen Karte. Grundsätzlich werden neue Daten nur über die lokale Karte geschrieben und schlussendlich an die globale Karte zurückgeliefert, die diese gegebenenfalls serialisiert. Dieses Konstrukt sorgt für eine geringe Auslastung des Arbeitsspeichers, da immer nur ein Teil der gesamten Karte aus der HDF5 geladen wird. Die Abstraktion über die lokale ist sinnvoll, da in der Regel nur einzelne TSDF-Zellen beschrieben werden. An dieser Stelle ist es allerdings von Nöten, dass alle Chunks der globalen Karte gelöscht werden, beziehungsweise die enthaltenen Daten mit Default-Werten ersetzt werden. HDF5 erlaubt zwar ein Löschen einzelner Datensätze (in diesem Fall Chunks), dies gibt allerdings nicht den von dem Datensatz beanspruchten Speicher wieder frei. Dies sorgt dafür, dass die Karte bei einer Löschung aller Datensätze und der darauf folgenden Regeneration der Karte und Chunks auf Basis des neuen Pose-Graphen stetig wächst. Das Beschreiben aller TSDF-Zellen über die Abstraktion der lokalen Karte ist zusätzlich keine gute Idee, da dies hohe Laufzeiten durch eine große Anzahl von Schreibbefehlen und mehrere Verschiebungen (*Shifts*) der lokalen Karte zur Folge hat. Aus diesem Grund wird an dieser Stelle auf die Abstraktion der lokalen Karte verzichtet und innerhalb der globalen Karte eine Methode entwickelt, die alle Chunks auf ihren Ursprungszustand zurücksetzt und mit Default-Werten füllt. Diese Methode ist um ein Vielfaches schneller als das Zurücksetzen der Karte über die Abstraktion der lokalen Karte und die damit verbundenen, benötigten Shifts der lokalen Karte. Doch auch diese Methode sorgt gegebenenfalls für leere Chunks, die nie zur Verwendung kommen, aber Speicher einnehmen. Eine drastische, aber auch schnellere Lösung ist das Löschen der gesamten HDF5 und der anschließenden Neuerstellung der Datei unter demselben Namen mit identischen Metadaten.

Im Anschluss an die Neuerstellung der HDF5 gilt es nun, die Karte auf Basis des neuen Pfades  $\mathfrak{P}_{new}$  zu regenerieren. Dazu ist keine Berechnung der Transformationen zwischen altem und neuen Pfad oder eine Transformation der zu den Posen zugehörigen Punktwolken notwendig, da die Punktwolken jeweils relativ zu den Posen gesehen werden und entsprechend relative Punktkoordinaten enthalten. Es ist für jede Pose, beginnend bei der ersten Pose des neuen

ggf. erklären,  
dass auch das  
wegen HDF5  
nicht geht, weil  
die Dateien  
nicht geschlos-  
sen werden  
und auch  
manuell nicht  
geschlossen  
werden können

Pfades, ein Shift der lokalen Karte zur aktuellen Pose und darauf folgend ein TSDF-Update basierend auf der zugehörigen Punktwolke durchzuführen. Für genanntes TSDF-Update wird hier wieder die Abstraktion über die lokale Karte verwendet. Dies ist zur Veranschaulichung als Pseudo-Code in Abbildung 3 dargestellt.

---

**Algorithm 3** Globales TSDF-Kartenupdate

---

```

1: procedure GLOBALUPDATE(  $map_{global}, map_{local}, \mathfrak{P}_{new}, \mathbb{C}$  )
2:   Lösche die zu  $map_{global}$  zugehörige HDF5
3:   Regeneriere besagte HDF5 mit identischen Metadaten
4:   for  $P_i$  in  $\mathfrak{P}_{new}$  do
5:     Verschiebe  $map_{local}$  nach  $P_i$ 
6:     Führe ein TSDF-Update basierend auf  $P_i$  und der zugehörigen Punktwolke  $C_i$  aus
7:     Schreibe die Daten aus  $map_{local}$  zurück in  $map_{global}$ 
8:   end for
9: end procedure

```

---

Dieses Update sorgt für eine konsistente Karte entsprechend des neuen Pfades, ist aber aufgrund des Löschens und Regenerierens von Daten die keiner Regeneration bedürften sehr Laufzeit intensiv. Dies ist besonders bei großen Umgebungen mit vielen Posen merklich. Besonders vor dem Hintergrund der für einen Shift der lokalen Karte benötigten Laufzeit von häufig mehr als einer Sekunde, abhängig von der Kartengröße der Größe des betroffenen Bereichs. Um diese hohe Laufzeit zu reduzieren und nur den Teil der Karte zu Updaten, der von den Optimierungen des Pose-Graphen betroffen ist, wird im Folgenden auf ein partielles Update eingegangen. Dabei wird der zuvor vorgestellte Ansatz als Base-Line für die Evaluation verwendet, da keine anderen vergleichbaren Ansätze existieren und der beschriebene Ansatz die einfachste Art ist das angestrebte Update der Karte mit den gegebenen Mitteln durchzuführen.

## 6.2 Partielles Update der Karte

Dieser Absatz befasst sich mit einem partiellen Karten-Update der durch Optimierungen am Pose-Graphen betroffenen Teilbereiche der TSDF-Karte. Dazu gilt es zunächst die Teile der Karte zu bestimmten, die ein genanntes Update benötigen. Diese Teile der Karte ergeben sich aus den verschobenen Posen des Pose-Graphen. Jedoch sollte nicht bei jeder Transformation einer Pose ein Update des entsprechenden Kartenbereichs durchgeführt werden. Dazu zählen zum Beispiel Transformationen die nahezu keine Verschiebung der entsprechenden Pose bewirken. Dazu werden an dieser Stelle zwei Schwellen für die minimale Translation  $t_{min}$  und die minimale Rotation um eine beliebige Achse  $rot_{min}$  definiert. Im Anschluss wird für jedes Pose-Paar aus alter Pose  $P_i^{old}$  und neuer Pose  $P_i^{new}$  nach der Graphen-Optimierung die relative Transformation  $T_{P_i^{old} \rightarrow P_i^{new}}$  von  $P_i^{old}$  nach  $P_i^{new}$  ermittelt. Diese ergibt sich aus:

$$T_{P_i^{old} \rightarrow P_i^{new}} = \left( T_{P_i^{new} \rightarrow MAP} \right)^{-1} \cdot T_{P_i^{old} \rightarrow MAP} \quad (6.1)$$

Für jede ermittelte relative Transformation wird nun der Translations- und Rotationsanteil mit den zuvor definierten Schwellen  $t_{min}$  und  $rot_{min}$  verglichen. Dazu wird die euklidische Norm der ermittelten relativen Translation berechnet und überprüft ob diese die Schwelle überschreitet. Bei der Rotation genügt es, wenn eine der Rotationskomponenten die definierte Schwelle überschreitet. Ist mindestens eine der Schwellen überschritten ist für dieses Pose-Paar ein Kartenupdate durchzuführen. Die entsprechenden Indices der Paare werden in einem Array gespeichert, das im Anschluss durchlaufen wird. In Kapitel 4 wurde beschrieben, wie an dieser Stelle Datenassoziationen zwischen der betrachteten Pose  $P_i$  und der TSDF-Karte hergestellt werden können. Zusätzlich stellt das Kapitel heraus, dass eine solche Assoziationsgeneration in vielerlei Hinsicht problematisch und fehlerbehaftet ist. Aus diesem Grund wird an dieser Stelle ein anderer Ansatz verwendet. Wie zuvor eruiert, basiert der hier vorgestellte Ansatz nicht auf einer bereits fertig generierten TSDF-Karte, sondern soll in einen inkrementellen SLAM-Prozess eingegliedert werden. Durch diese neue Grundlage können Anpassungen an der inkrementellen Generation der TSDF-Karte vorgenommen werden. Ein großes Problem der ursprünglichen TSDF-Karte besteht darin, dass in ihr keine relationalen Informationen vorhanden sind. Ein Speichern aller relationalen Daten, wie behandelt in Kapitel 4, durch behandelte Assoziationsbestimmung ist aus Sicht des dafür benötigten Speichers und der dynamischen Anzahl relationaler Daten keine sinnvolle Herangehensweise. Dies wurde in Kapitel ?? allerdings nur angestrebt, um die nicht vorhandenen Umgebungsdaten durch die vorhandene Karte auszugleichen. Dies ist an dieser Stelle nun nicht mehr nötig. Eine Herangehensweise auf der breiteren Datenbasis wäre es, den betroffenen Teil der Karte zu löschen und anhand der vorhandenen Umgebungsdaten in Form der Punktwolken  $\mathbb{C}$  an anderer Stelle neu zu generieren. Problematisch ist hier nur der Schritt des Löschens alter, fehlerhafter Daten aus der Karte. Hierfür werden im Folgenden zwei verschiedene Ansätze vorgestellt und evaluiert. Grundlage hierfür bietet die Erweiterung jeder TSDF-Zelle, bestehend aus einem TSDF-Wert und einem TSDF-Gewicht, um ein weiteres Feld. Dieses beinhaltet den Index der letzten Pose, die in diese Zelle geschrieben hat. Dafür sind nur minimale Anpassungen an der Datenstruktur, sowie dem TSDF-Update vorzunehmen, da nur ein Erstellen des Feldes und die entsprechende Befüllung der Indices im TSDF-Update durchzuführen ist. Eine Zelle, die Default-Werte enthält und bisher nicht durch ein TSDF-Update beschrieben wurde erhält den Index  $-1$ . Durch diese Anpassung wird die Karte aus Sicht des Speichers um 50% vergrößert. Das Ergebnis ist eine diskretisierte Karte die folgende Tupel enthält:

$$\langle value, weight, index \rangle \quad (6.2)$$

Anhand dieser um die Pose-Indices angereicherten Karte kann nun eine Löschung der betroffenen Kartenabschnitte vorgenommen werden. Dazu wird das erstellte Array durchlaufen, welches Informationen zu den Posen enthält, deren Änderungen durch die Graphen-Optimierung in Translation oder Rotation größer ist als die definierten Schwellen. Für jede Pose werden alle TSDF-Zellen ermittelt, deren Pose-Index dem der aktuell betrachteten Pose entspricht und dementsprechend zuletzt von der betrachteten Pose aus beschrieben wurde. Zunächst wurde an dieser Stelle der implementierte Ray-Tracer verwendet, dessen Zentrum auf die derzeit betrachtete Pose gesetzt wird. Schneidet ein Ray eine Zelle, deren Index mit der derzeit betrachteten Pose übereinstimmt, wird sie auf ihren Ursprungszustand zurückgesetzt, indem sie mit Default-Werten

gefüllt wird:  $\langle \tau, 0, -1 \rangle$ . Dieses Verfahren liefert bei bekannten Sensorauflösungen und unter Nutzung der Parameter bei der Generation der Karte gute Ergebnisse. Ist die Sensorauflösung der gegebenen Datensätze unbekannt oder das Sensorsystem durch den simpel aufgebauten Ray-Tracer nicht nachbildbar (wie zum Beispiel bei den Daten des im vorigen Kapitel vorgestellten Hannover-1 Datensatzes) treten ungewünschte Nebeneffekte auf. Dazu gehören zum Beispiel Artefakte in der Karte, die nicht durch den Ray-Tracer gelöscht werden konnten. Aus diesem Grund wurden an dieser Stelle zwei weitere Ansätze entwickelt, die im Folgenden vorgestellt und miteinander verglichen werden. Beide Ansätze teilen den an die Löschung der Daten anschließenden Prozess der Regeneration der Daten basierend auf den Posen des optimierten Graphen. Dieser besteht aus einem iterativen Ablauf der neuen Posen aus den ermittelten Pose-Paaren, in aufsteigender Reihenfolge der Pose-Indices. Für jede neue Pose  $P_i^{new}$  wird beruhend auf der zugehörigen Punktwolke  $C_i$  ein TSDF-Update durchgeführt. Resultat ist eine durch das partielle Update optimierte globale Karte. Die folgenden Abschnitte beziehen sich jeweils auf die Löschung der Teilabschnitte der Karten.

### Reverse-TSDF-Update

Der erste hier vorgestellte Ansatz nutzt die in der erweiterten Datenbasis gegebenen Punktwolken  $C$  zur Identifikation und Löschung der Zellen, die einen identischen Index haben, wie die dazu betrachtete Pose  $P_i$ . Analog zum TSDF-Update werden in diesem Ansatz Rays zwischen der betrachteten Pose  $P_i$  und den Punkten der zugehörigen Punktwolke  $C_i$  generiert. Identisch zum TSDF-Update werden diese Rays nun abgelaufen und die Zellen bestimmt, die im Normalfall durch das TSDF-Update verändert werden. Dazu gehören auch die interpolierten Zellen. Anstelle die Werte der bestimmten Zellen nun so zu manipulieren wie im TSDF-Update, werden die Werte aller Zellen wie oben beschrieben durch Default-Werte ersetzt. Diese Lösung sorgt für die gewünschte partielle Optimierung der Karte, ist allerdings sehr langsam, da für jede Pose ein Shift der lokalen Karte zur aktuell betrachteten Pose notwendig ist. In vorigen Ausführungen wurde bereits beschrieben, dass die Shifts sehr Zeit-intensive Operationen sind. Aus diesem Grund ist die Anzahl an Shifts auf ein Minimum zu reduzieren. Nach diesem Ansatz sind für  $n$  benötigte Karten-Updates  $n$  Shifts für die Löschung der Zellen mittels des Reverse-TSDF-Update und  $n$  weitere Shifts für das grundlegende TSDF-Update durchzuführen. Insgesamt sind dies  $2 \cdot n$  Shifts der lokalen Karte. Besonders bei großen Kartenupdates führt dies zu großen Laufzeiten der Updates. Aus diesem Grund wurde eine weitere Lösung des Problems implementiert, die auf den bisherigen Ausführungen aufbaut. Dies wird im folgenden vorgestellt.

### Global-Map basiert

Wie den vorigen Ausführungen zu entnehmen ist, sollte die Anzahl der Map-Shifts möglichst reduziert werden. Die vorgestellte Abstraktion des Zugriffs auf die globale Karte über eine lokale Karte fester Größe und die dadurch entstehende Notwendigkeit der Verschiebungen stellt allerdings an dieser Stelle ein Problem dar. Eine mögliche Minimierung der Shifts liegt darin, die lokale Karte nur zu verschieben, wenn die aktuell betrachtete Pose eine definierte Distanz in  $x$ ,  $y$  oder  $z$ -Richtung, wie zum Beispiel einem Viertel der jeweiligen Seitenlängen, vom Zentrum der lokalen Karte entfernt ist. Dies reduziert die Anzahl der benötigten Shifts, macht den Ansatz allerdings anfällig für Artefakte, da Zellen mit dem Index der betrachteten Pose nun außerhalb der Begrenzungen der lokalen Karte liegen und somit nicht mehr gelöscht werden können. Aus

Balkendiagramm  
Laufzeit  
Update -> Shift  
vs. restliches  
Update

diesem Grund wird an dieser Stelle ein anderer Ansatz gewählt, der nicht die Abstraktion der lokalen Karte verwendet, sondern direkt auf der globalen Karte arbeitet. Dies reduziert die Anzahl der benötigten Shifts auf 0. Dabei wird wie folgt vorgegangen. Zunächst werden die Namen beziehungsweise Tags aller Chunks der globalen Karte ermittelt. Im Anschluss werden die Chunks nacheinander aus der HDF5 geladen und die enthaltenen TSDF-Zellen durchlaufen. Um zu verhindern, dass für jede Zelle alle Posen durchlaufen und der Index abgeglichen werden muss, wird der Methode ein Array übergeben, das für jede Pose einen Wahrheitswert darüber enthält, ob für die zum Index zugehörige Pose ein Update notwendig ist. Nun ist für die Entscheidung, ob der Inhalt einer Zelle mit Default-Werten überschrieben wird nur eine Abfrage des entsprechenden Array-Elements an der Stelle des in der Zelle enthaltenen Indices von Nöten. Dadurch liegt diese Operation in  $\mathcal{O}(n)$  mit  $n$  als Anzahl der Zellen der globalen Karte. Eine weitere Optimierung dieses Ansatzes wird durch die Vernachlässigung von Chunks, die ausschließlich Default-Werte enthalten, erreicht. Die Anzahl dieser "leeren" Chunks ist stark abhängig von der Größe der lokalen Karte, da bei einer Verschiebung alle neu abgedeckten Chunks zunächst mit Default-Werten initialisiert und danach gegebenenfalls nie wieder beschrieben werden. Je größer die lokale Karte, desto größer die Anzahl leerer Chunks. Im folgenden Abschnitt wird nun das optimierte partielle Update mit dem globalen Update als Base-Line verglichen. Dabei wird sowohl auf die Laufzeit, als auch auf qualitative Unterschiede eingegangen. Die Evaluation erfolgt auf Basis der in Kapitel 5 vorgestellten Datensätze.

### 6.3 Evaluation der Update-Strategien

In diesem Abschnitt werden die zuvor beschriebenen Ansätze zum Karten-Update eruiert und evaluiert. Zunächst erfolgt ein Vergleich der Laufzeiten der beiden Algorithmen. Abbildung 6.1 vergleicht die Laufzeiten der unterschiedlichen Herangehensweisen an das Problem des Karten-Updates grafisch miteinander. Zu erkennen ist eine deutliche Verbesserung der Laufzeit durch die Einführung des partiellen Updates. Näheres hierzu ist der Unterschrift der Abbildung 6.1 zu entnehmen. D

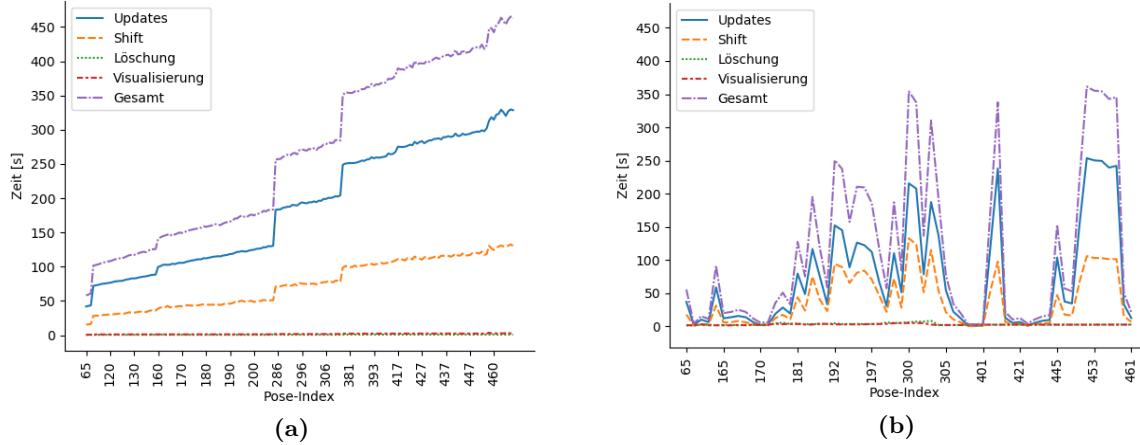
Im Folgenden werden die Ergebnisse des partiellen Updates mit denen des globalen Updates durch einen Vergleich der TSDF evaluiert. Dazu wird ein in [16] implementierter Ansatz zur Rekonstruktion der Oberfläche aus TSDF-Karten in Form eines Dreiecksnetzes verwendet. Dies ergibt sowohl für das globale, als auch für das partielle Update ein Dreiecksnetz bestehend aus *Vertices (Knoten)* und *Faces (Flächen, hier Dreiecksflächen)*. Mit Hilfe der Software *CloudCompare* [12] können die resultierenden Dreiecksnetze, sowie die durch die *Vertices* gegebenen Punktwolken miteinander verglichen werden. Ziel ist hier die Validierung des vorgestellten Ansatzes zum partiellen Update der Karte. Dazu wird untersucht, wie sehr die Ergebnisse voneinander abweichen, indem ein Vergleich mit der qualitativ optimalen Lösung des globalen Updates hergestellt wird. Dies ist in den Abbildungen 6.2 und 6.3 anhand unterschiedlicher Datensätze dargestellt.

### 6.4 Kapitel-Zusammenfassung

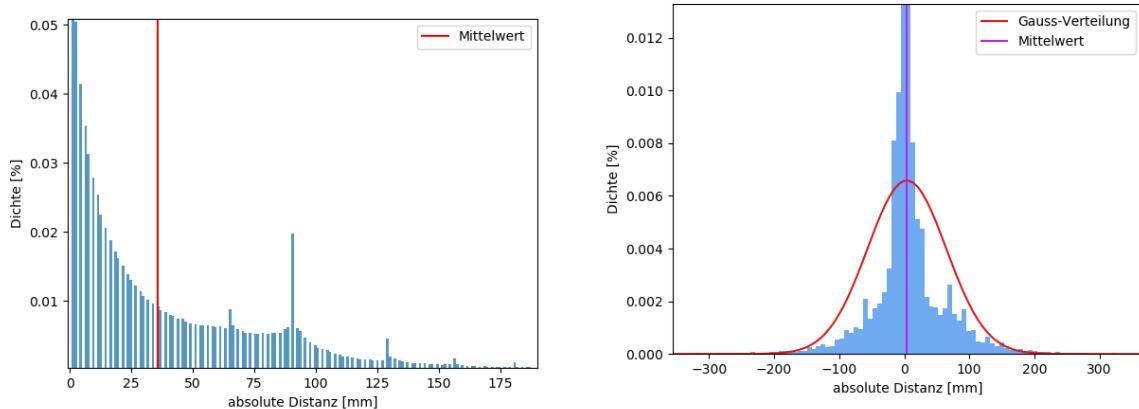
Dieses Kapitel behandelt die Implementation und Konzeption zweier distinkter Verfahren zum Update der TSDF-Karte. Dies ist zum Einen das globale Update und zum anderen zwei

Darauf eingehen, dass die Karte nach dem Update nicht identisch zum globalen Update ist, da spezifische Gewichte und Werte im Überlappungsbereich durch einen Wert ersetzt werden, der nicht auf den vonvorigen posen geschriebenen Werten basiert.

verschiedene Versionen des partiellen Updates, wobei eine Version bei identischem Ergebnis wesentlich weniger Zeit in Anspruch nimmt, indem sie die Abstraktion der lokalen Karte umgeht. Ein Benchmark zwischen den Laufzeiten der Algorithmen stellt die Laufzeit-Optimierung des partiellen Updates heraus, welches für diesen Datensatz nur 15% der Zeit des globalen Updates benötigt. Bei einem qualitativen Vergleich zwischen dem globalen und partiellen Update konnten leichte Abweichungen des partiellen Updates, abhängig von den Eigenschaften der Datensätze wie der Länge des Pose-Graphen, der gegebenen Punktdichte, sowie – damit verbunden – einer schlechten initialen Schätzung, identifiziert werden. Diese sind in den meisten Fällen allerdings geringer als die Größe der Zellen, die der begrenzende Faktor für die Genauigkeit der Karte ist. Nachfolgendes Kapitel fasst die Gesamtergebnisse der Arbeit zusammen und liefert einen Ausblick über mögliche zukünftige Arbeiten im Themengebiet dieses Projektes.



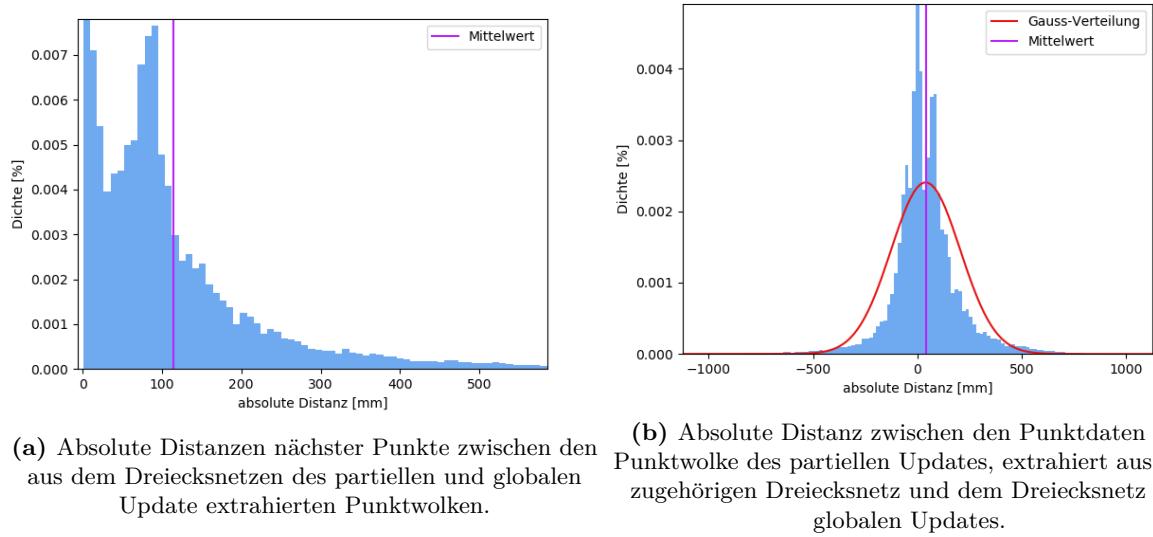
**Abbildung 6.1:** Grafischer Vergleich der Laufzeiten des globalen und partiellen Updates auf Basis des vorgestellten Hannover-1 Datensatzes. Dargestellt sind die Laufzeiten für jedes einzelne durchgeführte Update. Zusätzlich wurden kenntlich gemacht, wie sich welche Komponenten der Updates auf die Laufzeit auswirken. Die Laufzeit des globalen Updates ist links, die des partiellen rechts abgebildet. Es ist deutlich zu erkennen, dass die Laufzeit im globalen Update stetig ansteigt. Sprünge in diesem Graphen entstehen durch Teilbereiche des Pfades, in denen keine Schleifen geschlossen wurden und entsprechend kein Update der Karte nötig ist. Im Graphen, der die Laufzeit des partiellen Updates beschreibt sind starke Sprünge zu beobachten. Dies liegt an der variablen Anzahl nötiger Löschungen und TSDF-Updates, basierend auf den angegebenen Schwellen, anhand derer bestimmt wird, ob ein Update durchgeführt wird. Hier betragen diese Schwellen in der Translation  $3,2\text{cm}$  und in der Rotation  $2^\circ$ . In der Gesamtheit benötigt das globale Karten-Update für den Hannover-1 Datensatz mit 468 Posen  $13.2\text{h}$ , während das partielle Update  $1.96\text{h}$  benötigt. Dies entspricht einer Verringerung der Laufzeit auf 15% der Laufzeit der vorgegebenen Base-Line in Form des globalen Updates. Diese Verringerung gründet sich in der Verringerung der Laufzeiten der einzelnen Bestandteile des Algorithmus durch eine geringere Anzahl an Posen, die an einem Update beteiligt sind. In einigen Fällen reduziert sich diese Anzahl sogar auf 0. Dementsprechend ist vorstellbar, dass in einem optimalen Datensatz mit regelmäßigen Schleifenschlüssen, die nur eine geringe Auswirkung auf den Verlauf des Pfades haben nur sehr wenige oder nahezu keine Updates durchzuführen sind, während beim naiven globalen Update nach jedem Schleifenschluss ein Update durchgeführt wird, ohne Berücksichtigung der genannten Fälle. Die durchschnittliche Zeit, die das Update pro Pose gemäß dieser Daten benötigt, beträgt  $0.91\text{s}$ .



(a) Absolute Distanzen nächster Punkte zwischen den aus dem Dreiecksnetzen des partiellen und globalen Update extrahierten Punktfolgen.

(b) Absolute Distanz zwischen den Punktfolgen der Punktfolke des partiellen Updates, extrahiert aus dem zugehörigen Dreiecksnetz und dem Dreiecksnetz des globalen Updates.

**Abbildung 6.2:** Die hier dargestellten Histogramme zeigen die Verteilungen der absoluten Distanzen zwischen den vorgestellten Methoden zum Update der TSDF-Karte unter Verwendung des in Kapitel 5 vorgestellten Datensatzes des Campus der Universität Osnabrück. Verglichen wird jeweils der partielle Ansatz im mit dem Globalen. Dazu werden zwei verschiedene Methoden verwendet. Im linken Teil der Abbildung ist eine Verteilung der absoluten Distanzen nächster Nachbarn der Punkte der aus den Dreiecksnetzen resultierenden Punktfolgen des partiellen und globalen Updates dargestellt. Im Rechten wird die absolute Distanz der Punkte der Punktfolke des partiellen Updates zu den Flächen des Dreiecksnetzes des globalen Updates in einer Verteilung herausgestellt. Beide Abbildungen stellen den Mittelwert der Verteilung in Form einer vertikalen Linie dar. Im rechten Teil der Abbildung ist zusätzlich eine an den Datensatz angeglichenen Normalverteilung zu sehen. Im linken Teil der Abbildung liegt viel mehr ein exponentieller Abfall in der Verteilung vor. Dieser Verlauf gründet sich in den positiven Entfernungswerten zwischen zwei Punkten. Im rechten Teil der Abbildung wird dagegen untersucht, auf welcher Seite der Oberfläche der Karte nach dem globalen Update sich ein Vergleichspunkt befindet. Entsprechend wird hier das Vorzeichen gesetzt. Aus diesem Grund wird für den linken Teil der Abbildung nur der sich ergebende Mittelwert evaluiert, der  $35.89\text{mm}$  beträgt. Im rechten Teil der Abbildung ergibt sich aus der Normalverteilung ein Erwartungswert von  $3.98\text{mm}$  und eine Standardabweichung von  $60.6\text{mm}$ . Dies macht deutlich, dass zwar ein Unterschied zwischen den Ergebnissen der betrachteten Update-Verfahren besteht, dieser aber im Schnitt deutlich geringer ist, als die in beiden Datensätzen verwendete TSDF-Zellgröße mit einer Seitenlänge von  $128\text{mm}$ . Dabei stellt die Zellgröße den begrenzenden Faktor für die Genauigkeit der Ergebnisse dar.



**Abbildung 6.3:** Die dargestellten Histogramme sind analog zu denen aus Abbildung 6.2 generiert, jedoch hier für den Datensatz Hannover-1. Zu erkennen sind größere Abweichungen im Vergleich zur Abbildung 6.2. Dies ist jedoch an dieser Stelle zu erwarten, da der Pose-Graph des Hannover-1 Datensets um ein Vielfaches größer ist, bei deutlich geringerer Punktdichte der Punktwellen. Zusätzlich ist die Anzahl durchgeföhrter Updates wesentlich höher als beim oben verwendeten Datensatz. Trotz diesen initialen Hürden beträgt der mittlere Abstand nächster Punkte hier nur  $114.14\text{mm}$  und ist damit weiterhin geringer als die verwendete Zellgröße. Der durchschnittliche Abstand der Punktwellen zum Dreiecksnetz beträgt  $39.51\text{mm}$  bei einer Standardabweichung von  $165.76\text{mm}$ . Hier streuen die Werte deutlich mehr als im oben betrachteten Datensatz. Ursache hierfür sind ebenfalls die oben genannten Gründe.

# Kapitel 7

# Zusammenfassung und Ausblick

Diese Kapitel fasst die Ergebnisse der Arbeit basierend auf den Teilergebnissen der vorigen Kapitel zusammen und liefert einen Ausblick über mögliche Folgethemen, die im Laufe dieser Arbeit herausgearbeitet wurden.

## 7.1 Zusammenfassung

Dieser Abschnitt bietet eine Zusammenfassung der einzelnen Kapitel dar und stellt eine Verbindung der Ergebnisse aller Kapitel her. Zu Beginn dieser Arbeit zunächst in Kapitel 4 die Optimierung einer fertigen TSDF-Karte mit initialer Pose-Historie algorithmisch analysiert. Dazu wurde untersucht, inwiefern Assoziationen zwischen dem initialen Pose-Graphen und der gegebenen TSDF-Karte hergestellt werden können. Dazu wurde im ersten Schritt herausgestellt, dass anhand der TSDF-Karte ohne zusätzliche Informationen keine gute Assoziationsbestimmung möglich ist. Wird die Karte zusätzlich für jede Zelle um eine Historie erweitert, die aufzeigt, von welchen Posen ausgehend die entsprechende Zelle beschrieben wird, relativiert sich dieses Problem. Dies sorgt wie herausgestellt allerdings für eine starke Vergrößerung des für die Karte benötigten Speichers. Zusätzlich stellt dies Probleme für die HDF5-Datenstruktur dar. Aus diesem Grund wurde die Ermittlung von Assoziationen mittels eines Raytracers untersucht, der ausgehend von den einzelnen Posen Strahlen aussendet und mit dem TSDF schneidet und entsprechend geschnittene Zellen mit der Pose assoziiert. Diese Bestimmung der Assoziationen funktioniert im Grundsatz, eröffnet allerdings weitere Probleme wie Karten-Bereiche die durch Verdeckungen nicht assoziiert werden können. Dazu gehören unter anderem die Teile der Karte, die durch die Optimierung aus der Karte herausgelöscht werden sollen, wie zum Beispiel doppelte Wände. Dadurch prägte sich heraus, dass der gewählte Prozess von großen Unsicherheiten geprägt ist. Dies verstärkte sich zusätzlich durch Probleme bei der Identifikation von Schleifenschlüssen, da die Datenbasis, auf Basis der Schleifenschlüsse identifiziert und validiert werden, hier die TSDF-Karte, zum Zeitpunkt der Identifikation bereits fehlerhaft ist. Dies sorgt implizit für fehlerhafte Schleifenschlüsse. Aus diesen Grund wurde der zunächst gewählte Ansatz verworfen und stattdessen auf einer größeren Datenbasis gearbeitet, die eine initiale Pose-Schätzung und die zugehörigen Punktwolken erhält. Ziel die Implementation und Konzeption eines Ansatzes,

der in ein SLAM Verfahren wie den Ansatz von Eisoldt et al. [16] integriert werden kann und zur Laufzeit die zur Registrierung neuer Daten genutzt TSDF-Karte auf Basis identifizierter Schleifenschlüsse zu optimieren.

Um dieses Ziel zu erreichen wurde zunächst in Kapitel 5 die Detektion von Schleifenschlüssen und die Optimierung des Pose-Graphen basierend auf der neuen Datenbasis behandelt. Dazu wird mittels eines *k-d Baumes*, der die 3-D Position jeder Pose des Pose-Graphen enthält, für die aktuell betrachtete Pose eine *Radius-Suche* mit einem parametrisierten Radius durchgeführt. Dies liefert eine Reihe von Kandidaten, die über ein *Scan-Matching* zwischen den Punktwolken der beiden beteiligten Posen validiert werden. Dies liefert bereits gute Ergebnisse, jedoch ist die Anzahl so detektierter Schleifenschlüsse gering. Zur Verbesserung wurde auf der Annahme lokaler Konsistenz ein Fenster eingeführt, welches die (Model-)Punktwolke der Kandidaten-Pose mit den Punktwolken der umgebenden Posen anreichert beziehungsweise verbindet. Dies sorgt für eine deutlich dichtere Model-Punktwolke und damit verbunden für eine bessere Konvergenz des Scan-Matching und eine größere Anzahl validierter Schleifenschlüsse. Trotz der bereits vorgenommenen Validierung wurden Sonderfälle identifiziert, bei denen fehlerhafte Schleifenschlüsse validiert wurden. Dies tritt besonders in Umgebungen auf, in denen vergleichsweise wenig Features vorhanden sind, wie zum Beispiel in Fluren. Aus diesen Grund wurden zwei weitere Validatoren implementiert, die eine zusätzliche Beschränkung für Schleifenschlüsse darstellen. Sie stellen sicher, dass die Schleifenschlüsse sich innerhalb eines statischen Rahmens, gegeben durch die Unsicherheiten des Faktor-Graphen, der für die Optimierung des Pose-Graphen verwendet wird, bewegen. Dies erhöht die Robustheit dieses Ansatz enorm, da fehlerhafte Schleifenschlüsse zu großen Problemen innerhalb der Optimierung sorgen. Hier wird die Implementation des Faktor-Graphen von GTSAM ?? mitsamt der zugehörigen Optimierungsfunktionen verwendete. Dies sorgt für eine Optimierung des Pose-Graphen anhand von Schleifenschlüssen, die sowohl die Validierung durch das Scan-Matching, als auch die beiden weiteren vorgestellten Validierungsstufen durchlaufen haben. Insgesamt liefert der Ansatz sehr gute und mit anderen Herangehensweisen an dieses Optimierungsproblem wie zum Beispiel ELCH [41] vergleichbare Ergebnisse.

Basierend auf diesen Ergebnissen der Pose-Graph Optimierung wurde in Kapitel 6 die Optimierung der TSDF-Karte erneut beleuchtet. Dazu wurden zwei Möglichkeiten des Kartenupdates erläutert und miteinander verglichen. Das globale Update löscht die gesamte Karte nach Identifikation eines oder mehrerer Schleifenschlüsse und der resultierenden Anpassung des Pose-Graph. Nachdem die Karte gelöscht ist, wird sie vollständig neu generiert, indem inkrementelle TSDF-Updates basierend auf den neuen Posen und zugehörigen Punktwolken durchgeführt werden. Dieses globale Update ist allerdings sehr zeitintensiv und es werden jeweils Teile der Karte gelöscht, die keiner Löschung bedürfen, weil die mit den Teilbereichen assoziierten Posen nicht, oder nur minimal verschoben wurden. Aus diesem Grund wurde ein partielles Update entwickelt, welches nur die betroffenen Teilbereiche löscht. Zum Vergleich dient das globale Update als Base-Line. Um das partielle Update zu realisieren wurde zunächst das Tupel jeder TSDF-Zelle um ein weiteres Feld erweitert, welches den Index der Pose enthält, die zuletzt in diese Zelle geschrieben hat. Basierend auf dieser neuen Karten-Struktur wurden zwei Methoden vorgestellt, das Update durchzuführen. Dazu wurde die Teilmenge der Posen des Pose-Graphen bestimmt, deren Veränderung durch die Optimierung des Pose-Graphen größer ist als eine definierte Schwelle. Daraufhin werden alle Zellen, deren Pose-Index in der bestimmten Teilmenge der Posen enthalten ist, mit Default-Werten

überschrieben. Hierfür wurden zwei Methoden entwickelt, wobei performantere Methode die Abstraktion der lokalen Karte umgeht und lediglich die Strukturen der globalen Karte verwendete. Im Anschluss wird die Karte per inkrementellem Update neu gefüllt. Dies sorgt für eine deutliche Reduktion der Laufzeit des Algorithmus. Im Falle vom Hannover-1 Datensatz benötigt das partielle Update nur 15% der Laufzeit des globalen Updates. Dabei ist eine leichte Verringerung der Genauigkeit zu beobachten, die allerdings im Schnitt nicht größer ist als die Auflösung der lokalen Karte, die der begrenzende Faktor für die Genauigkeit des Ergebnisses ist.

Zusammenfassend lässt sich sagen, dass der vorgestellte Ansatz zur Optimierung des Pose-Graphen in Kombination mit dem partiellen Update der TSDF-Karte gute Ergebnisse liefert und die initiale Schätzungen – und damit verbunden auch die Karte – deutlich verbessert. Bezogen auf die Laufzeit ist an dieser Stelle allerdings noch viel Optimierungspotential und der Ansatz nicht näherungsweise Echtzeit fähig. Zusätzlich ist die verwendete Kartenstruktur mitsamt der Kapselung über die lokale Karte nicht optimal für den vorgestellten Ansatz, da eine Vielzahl von Operationen durchgeführt werden muss, die sehr zeitintensiv sind. Im Folgenden Abschnitt wird ein Ausblick über Themen gegeben, die nicht in den zeitlichen oder thematischen Rahmen gepasst haben, aber für zukünftige Forschungen in diesem Bereich von Interesse sein könnten.

ggf. über  
die Place  
recognition  
von Canelhas  
schreiben: [10]

## 7.2 Ausblick

Dieser Abschnitt stellt mögliche zukünftige Arbeiten heraus, die auf den hier vorgestelltem Themenschwerpunkt aufbauen. Dabei wird an dieser Stelle nur auf inhaltliche Themen eingegangen. Im folgenden Absatz wird gekapselt davon auf mögliche Optimierungen der implementierten Lösung eingegangen, insbesondere im Bereich der Laufzeitoptimierung.

Ein Teil dieser Arbeit, der weiterer Evaluation und Arbeit bedarf sind die im Kapitel 5 vorgestellten Validatoren für Schleifenschlüsse, die dem Scan-Matching nachgestellt sind und so eine weitere Validationsebene darstellen. Diese zusätzliche Validation ist essentiell, da fehlerhafte Schleifenschlüsse die Ergebnisse der Faktograph-Optimierung merklich verschlechtern. Die beiden Validatoren wurden innerhalb dieser Arbeit als Reaktion auf die Identifikation fehlerhafter Schleifenschlüsse entwickelt und erfüllen grundsätzlich ihren Zweck. An dieser Stelle wurde allerdings nicht evaluiert ob die Validatoren in der Lage sind, jegliche fehlerhafte Schleifenschlüsse zu identifizieren. Zusätzlich gilt es zu analysieren, welche anderen Lösungen für diese zusätzliche Evaluation existieren. Grundlage hierfür könnten die Ausführungen von Xie et al. bieten, die ebenfalls eine Zwischen-Ebene zur Validierung identifizierter Schleifenschlüsse bieten um die Robustheit des SLAM-Algorithmus zu verbessern. Ein weiterer Bereich des hier vorgestellten Ansatzes, der optimiert werden kann, ist das Scan-Matching, welches sowohl für die Vorregistrierung neuer Daten als auch für die erste Validierungsstufe bei der Schleifenschluss-Detektion verwendet wird. Je besser die Ergebnisse des Scan-Matching, desto robuster das SLAM-Verfahren. In dieser Arbeit wird an beiden Stellen GICP verwendet. Es wurden zusätzlich allerdings bereits Versuche unternommen die Bibliothek *TEASER++* [47] in diesen Ansatz zu integrieren, um das Scan-Matching basierend auf zuvor berechneten Korrespondenzen zu verbessern. Bei der Integration wurde allerdings ein Fehler in der von *TEASER++* zur Verfügung gestellten API festgestellt. Aufgrund dieses Fehlers wurde am GitHub-Repository der Bibliothek ein Bug-Ticket erstellt

und die Integration der Bibliothek vorerst hinten an gestellt. Vor Kurzem gab es nun Aktivität am erstellten Ticket und der Fehler scheint behoben. In einer zukünftigen Arbeit lohnt es sich gegebenenfalls, an dieser Stelle anzusetzen und Teaser++ zu integrieren. Auch im Bereich des Karten-Updates sind mehrere Optimierungen, insbesondere bezogen auf die Laufzeit, möglich. An dieser Stelle wird allerdings ein experimenteller Ansatz eruiert, dessen Evaluation sich in zukünftigen Arbeiten bezahlt machen könnte. Kapitel 6 stellt eine Methode vor, mit deren Hilfe ein partielles Update durch die Speicherung des Pose-Indices in einer Zelle der TSDF-Karte, die diese zuletzt bearbeitet hat, möglich ist. Diese Methode könnte an dieser Stelle verwendet werden um einige der in Kapitel 4 identifizierten Probleme bei der Generation von Datenassoziationen zu lösen. Dies betrifft insbesondere Verdeckungen. Trifft ein Strahl des Raytracers eine TSDF-Zelle können direkt mehr Informationen abgelesen werden. So kann ein simulierter Scan, ausgesendet von einer Pose  $P_i$  bedenkenlos durch Wände hindurch schauen, wenn die Pose-Indices der Zellen der Wand niedriger sind als der Index der Pose selbst. Dadurch können zum Beispiel falsch platzierte Wände nun trotz der räumlichen Verdeckung innerhalb des TSDF identifiziert werden. An dieser Stelle lohnt sich eine Evaluation dieses neuen Ansatzes unter Berücksichtigung der weiteren, in Kapitel 4 dargelegten Problemstellungen. Lässt sich durch diesen Ansatz ebenfalls das Problem der Identifikation von Schleifenschlüssen basierend auf einer TSDF-Karte lösen, könnte die in dieser Arbeit um die Punktwolken erweiterte Datenbasis möglicherweise wieder um diese reduziert werden.

Zu Beginn dieser Arbeit lag der Fokus vornehmlich auf der Identifikation von Assoziationen auf Basis einer initialen Schätzung innerhalb einer fertigen TSDF-Karte. Allerdings existierten zu diesem Zeitpunkt lediglich fertige TSDF-Karten ohne zugehörige initiale Schätzung der Pose-Historie. Aus diesem Grund wurde eine naive Pfad-Exploration implementiert, die innerhalb einer fertigen Karte, gegeben einen Startpunkt  $S_i$ , eine Schätzung des abgelaufenen Pfades generiert und abspeichert. Auch an dieser Stelle wurde der implementierte Laserscanner verwendet. Für die Pfadschätzung wurden zur Vereinfachung als mögliche Posen nur die Ursprungspositionen der Chunks der globalen Karte verwendet. Dazu wurde zunächst die Anzahl der betrachteten Chunks reduziert, indem für jeden Chunk eine Abschätzung darüber getroffen wird, ob dieser dafür in Frage kommt. Dies ist der Fall, wenn alle Chunks um den betrachten Chunk herum, in einem Bereich identischer Größe zu der der lokalen Karte initialisiert wurden. Dies liegt daran, dass alle Chunks, die sich zu einem beliebigem Zeitpunkt innerhalb der lokalen Karte befinden, bereits initialisiert sind und mit Default-Werten gefüllt werden. Gilt dies für den betrachteten Chunk nicht, heißt das implizit, dass das Zentrum der lokalen Karte sich nie in der Nähe dieses Chunks befunden hat. Dieser Chunk kommt entsprechend nicht für die Exploration in Frage. Für alle in Frage kommenden Chunks wird im Anschluss mittels des Raytracers ein Scan simuliert und das Verhältnis zwischen der Anzahl von Strahlen gebildet, die eine Datenassoziation herstellen mit denen, die lediglich leeren Raum passieren. Dies liefert für die in Frage kommenden Chunks ein Raster, welches die zuvor berechneten Verhältnisse enthält. Innerhalb dieses Rasters kann nun mit einer Such-Methode wie zum Beispiel einer abgewandelten Variante des Dijkstra Algorithmus für kürzeste Pfade [33] ein Pfad generiert werden. Diese Variante wurde an dieser Stelle rein experimentell verwendet und nicht weiter ausgearbeitet. Es konnten allerdings Pfade generiert werden, die – gegeben die aktuell betrachtete Karte – als mögliche Pfade durch die Karte angesehen werden können und gegebenenfalls für Roboter-Trajektorien durch bekannte

Umgebungen in Frage kommen. An dieser Stelle lohnt sich eine weitere Betrachtung in Hinsicht auf die Verwendbarkeit des Ansatzes zur Identifikation von Pfaden innerhalb einer gegebenen TSDF-Karte.

Im Folgenden wird ein Ausblick auf zeitliche Optimierungen des vorgestellten Ansatzes zur Kartenoptimierung nach der Detektion von Schleifenschlüssen gegeben.'

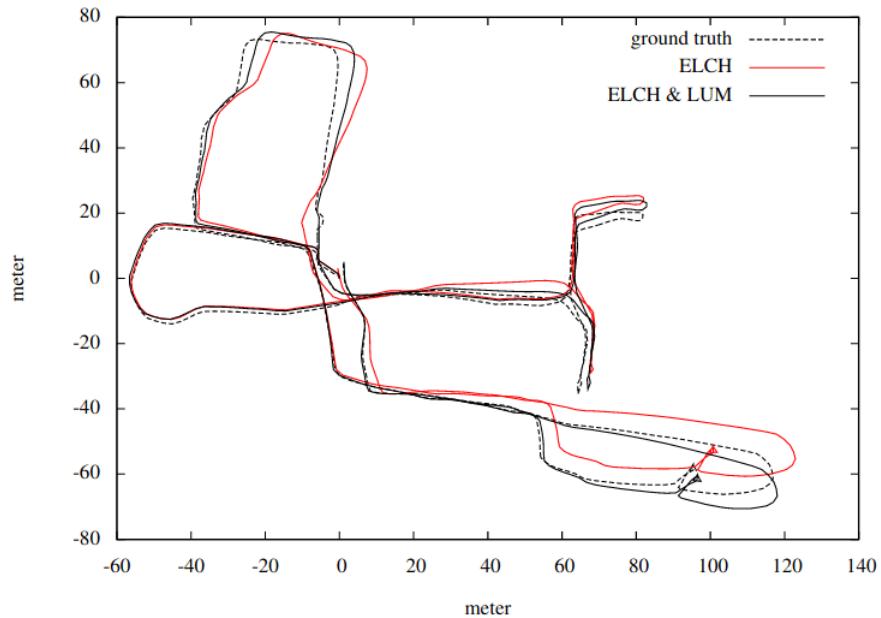
### 7.2.1 Optimierungen des vorgestellten Ansatzes

Wie in Kapitel 6 herausgestellt ist, ist die vorhandene Map-Repräsentation, besonders durch die Abstraktion der lokalen Karte, nicht gut für das Szenario des Schleifenschlusses und der damit verbundenen Graph-Optimierung geeignet. Hauptgrund ist die benötigte Durchführung mehrerer laufzeitintensiver Operationen um die Karte in einen konsistenten Zustand überführen zu können. Für das TSDF-Update haben Eisoldt et al. [?] bereits für eine kleine lokale Karte gezeigt, dass eine Optimierung der Laufzeit vom Sekundenbereich in den Bereich weniger Millisekunden durch die Nutzung eines *Field Programmable Gate Array (FPGA)* möglich ist. Dies wurde allerdings für den *Shift* der lokalen Karte, der ebenfalls einen großen Teil der Laufzeit des hier vorgestellten Ansatzes zum Karten-Update ausmacht, nicht weiter verfolgt. Ein Umgehen der Abstraktion der lokalen Karte konnte an dieser Stelle beim Zurücksetzen der vom Update betroffenen TSDF-Zellen konnte an dieser Stelle bereits eine deutliche Reduktion der Laufzeit erwirken, da dadurch die Anzahl benötigter Shifts um die Hälfte reduziert werden konnte. Für das Schreiben der neuen Zellen ist allerdings bei der gegebenen Struktur der Karte die Durchführung mehrerer Shifts notwendig. Um dieses Problem zu lösen gibt es mehrere Lösungsansätze, die im folgenden unterbracht werden. Eine Möglichkeit besteht in der Konzeption einer Datenstruktur für die Karte, die besser auf die Anforderungen des Karten-Updates ausgerichtet ist und den Datenaustausch mit der Festplatte auf ein Minimum reduziert. Ergibt sich an dieser Stelle keine Variante, die die Anforderungen abbilden kann, sollte der Fokus auf der Optimierung der bereits bestehenden Strukturen liegen. Eine weitere Optimierung des TSDF-Update – zum Beispiel durch die Nutzung von Grafikprozessoren – und eine initiale Optimierung des Shifts könnten hier erste Schritte darstellen. Beide Operationen sind für den Großteil der Laufzeit des partiellen Updates der Karte verantwortlich. Die TSDF-Updates benötigen in etwa 65% der Zeit, die Shifts der Karte ungefähr 35%. Aus diesem Grund sind beide Operationen die *Bottlenecks* des Karten-Updates und erfordern eine tiefere Betrachtung. Bereits in vorigen Betrachtungen des Shifts wurde festgestellt, dass eine Parallelisierung zwar möglich, aber sehr komplex ist. Hier ist abzuwegen, ob der Aufwand für diese Parallelisierung gerechtfertigt ist, oder ein Ansatz gewählt wird, der sich vollständig vom Aktuellen unterscheidet. In jedem Fall ist hier durch eine Parallelisierung mittels FPGAs oder Grafikprozessoren eine erhebliche Reduktion des zeitlichen Aufwandes zu erwarten. Es bleibt zu evaluieren, ob durch die Optimierungen eine Integrierung dieses Ansatzes in einen Echtzeit SLAM Ansatz möglich ist, oder ob gegebenenfalls das Update der Karte parallel zum Rest des SLAM-Ansatzes geschaltet wird. Neben der Optimierung durch eine Beschleunigung der bestehenden Operationen ist auch eine Optimierung durch eine Anpassung der Algorithmik für den Karten-Shift denkbar. Dies wurde bereits in Kapitel 6 kurz behandelt. Derzeit wird vor jedem Schritt des Updates ein Shift in Richtung der zugehörigen Pose durchgeführt. Dies ist unter gewissen Umständen nicht immer nötig. Stattdessen kann hier eine andere Strategie genutzt werden, die die lokale Karte nur dann verschiebt, wenn es notwendig ist.

Die genannten Punkte liefern nur einen ausgewählten Überblick der möglichen Themen, die basierend auf diesem Ansatz weiter behandelt werden können. Dazu kann der hier vorgestellte Ansatz als Grundlage oder Base-Line für weitere Forschungen dienen.

## **Anhang A**

## **Anhang**



**Abbildung A.1:** Diese Grafik wurde aus [41] entnommen und dient als Vergleich zu den in Kapitel 5 herausgearbeiteten Ergebnissen. Ein direkter, wertebasierter Vergleich mit den Ergebnissen aus [41] ist nicht möglich, da diese dort nur für einen anderen Datensatz angegeben sind. Ein visueller Vergleich der Ansätze zeigt aber eine deutliche Verbesserung des in dieser Arbeit vorgestellten Ansatzes im Gegensatz zum vorgeschlagenen Ansatz aus [41]. Nur an wenigen Stellen ist eine leicht größere Abweichung zur Ground-Truth zu erkennen. An allen anderen Stellen ist eine deutliche Verbesserung erkennbar.



**Abbildung A.2:** *Marching-Cubes*-Rekonstruktion [25] des in Kapitel 5 vorgestellten Datensatzes des Physikgebäudes der Universität Osnabrück. Mit anschließendem Schließen von Löchern und Smoothing.



# Literaturverzeichnis

- [1] AULINAS, Josep; PETILLOT, Yvan; SALVI, Joaquim; LLADÓ, Xavier: The SLAM problem: a survey. In: *Artificial Intelligence Research and Development* (2008), S. 363–371
- [2] BAJAJ, Chandrajit L.; BERNARDINI, Fausto; XU, Guoliang: Automatic reconstruction of surfaces and scalar fields from 3D scans. In: *Proceedings of the 22nd annual conference on Computer graphics and interactive techniques*, 1995
- [3] BENTLEY, Jon L.: Multidimensional binary search trees used for associative searching. In: *Communications of the ACM* 18 (1975), Nr. 9, S. 509–517
- [4] BESL, P.; MCKAY, N.: A Method for Registration of 3-D Shapes. In: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 14 (1992), Februar, Nr. 2, S. 239–256
- [5] BESL, Paul J.; MCKAY, Neil D.: Method for registration of 3-D shapes. In: *Sensor fusion IV: control paradigms and data structures* Bd. 1611 Spie, 1992
- [6] BORRMANN, Dorit; ELSEBERG, Jan; LINGEMANN, Kai; NÜCHTER, Andreas; HERTZBERG, Joachim: Globally consistent 3D mapping with scan matching. In: *Robotics and Autonomous Systems* 56 (2008), Nr. 2, S. 130–142
- [7] BREEN, David E.; MAUCH, Sean; WHITAKER, Ross T.: 3D scan conversion of CSG models into distance volumes. In: *Proceedings of the 1998 IEEE symposium on Volume visualization*, 1998
- [8] BRESENHAM, Jack E.: Algorithm for computer control of a digital plotter. In: *IBM Systems journal* 4 (1965), Nr. 1, S. 25–30
- [9] CADENA, Cesar; CARLONE, Luca; CARRILLO, Henry; LATIF, Yasir; SCARAMUZZA, Davide; NEIRA, José; REID, Ian; LEONARD, John J.: Past, present, and future of simultaneous localization and mapping: Toward the robust-perception age. In: *IEEE Transactions on robotics* 32 (2016), Nr. 6, S. 1309–1332
- [10] CANELHAS, Daniel R.: Truncated Signed Distance Fields Applied To Robotics, 2017

- [11] CHEN, Yang; MEDIONI, Gérard: Object modelling by registration of multiple range images. In: *Image and vision computing* 10 (1992), Nr. 3, S. 145–155
- [12] CLOUDCOMPARE: *CloudCompare - home*. <https://www.cloudcompare.org/main.html>. – zuletzt abgerufen am: 16.11.2022
- [13] CURLESS, Brian; LEVOY, Marc: A volumetric method for building complex models from range images. In: *Proceedings of the 23rd annual conference on Computer graphics and interactive techniques*, 1996
- [14] DELLAERT, Frank: Factor graphs and GTSAM: A hands-on introduction / Georgia Institute of Technology. 2012. – Forschungsbericht
- [15] DISSANAYAKE, MWM G.; NEWMAN, Paul; CLARK, Steve; DURRANT-WHYTE, Hugh F.; CSORBA, Michael: A solution to the simultaneous localization and map building (SLAM) problem. In: *IEEE Transactions on robotics and automation* 17 (2001), Nr. 3, S. 229–241
- [16] EISOLDT, Marc; FLOTTMANN, Marcel; GAAL, Julian; BUSCHERMÖHLE, Pascal; HINDE-RINK, Steffen; HILLMANN, Malte; NITSCHMANN, Adrian; HOFFMANN, Patrick; WIEMANN, Thomas; PORRMANN, Mario: HATSDF SLAM – Hardware-accelerated TSDF SLAM for Reconfigurable SoCs. In: *2021 European Conference on Mobile Robots (ECMR)*, 2021
- [17] FRISKEN, Sarah F.; PERRY, Ronald N.; ROCKWOOD, Alyn P.; JONES, Thouis R.: Adaptively sampled distance fields: A general representation of shape for computer graphics. In: *Proceedings of the 27th annual conference on Computer graphics and interactive techniques*, 2000
- [18] GARG, Sourav; FISCHER, Tobias; MILFORD, Michael: Where is your place, visual place recognition? In: *arXiv preprint arXiv:2103.06443* (2021)
- [19] HDF-GROUP: *THE JDF5 LIBRARY FILE AND FORMAT*. <https://www.hdfgroup.org/solutions/hdf5/>. – zuletzt abgerufen am: 02.11.2022
- [20] HE, Ying; LIANG, Bin; YANG, Jun; LI, Shunzhi; HE, Jin: An iterative closest points algorithm for registration of 3D laser scanner point clouds with geometric features. In: *Sensors* 17 (2017), Nr. 8, S. 1862
- [21] HO, Kin L.; NEWMAN, Paul: Loop closure detection in SLAM by combining visual and spatial appearance. In: *Robotics and Autonomous Systems* 54 (2006), Nr. 9, S. 740–749
- [22] IZADI, Shahram; KIM, David; HILLIGES, Otmar; MOLYNEAUX, David; NEWCOMBE, Richard; KOHLI, Pushmeet; SHOTTON, Jamie; HODGES, Steve; FREEMAN, Dustin; DAVISON, Andrew u. a.: Kinectfusion: real-time 3d reconstruction and interaction using a moving depth camera. In: *Proceedings of the 24th annual ACM symposium on User interface software and technology*, 2011

- [23] JONES, M.W.; BAERENTZEN, J.A.; SRAMEK, M.: 3D distance fields: a survey of techniques and applications. In: *IEEE Transactions on Visualization and Computer Graphics* 12 (2006), Nr. 4, S. 581–599. <http://dx.doi.org/10.1109/TVCG.2006.56>. – DOI 10.1109/TVCG.2006.56
- [24] LEVENBERG, Kenneth: A method for the solution of certain non-linear problems in least squares. In: *Quarterly of applied mathematics* 2 (1944), Nr. 2, S. 164–168
- [25] LORENSEN, W. E.; CLINE, H. E.: Marching Cubes: A High Resolution 3D Surface Construction Algorithm. In: *ACM SIGGRAPH '87*, 1987
- [26] LOWRY, Stephanie; SÜNDERHAUF, Niko; NEWMAN, Paul; LEONARD, John J.; COX, David; CORKE, Peter; MILFORD, Michael J.: Visual place recognition: A survey. In: *IEEE Transactions on Robotics* 32 (2015), Nr. 1, S. 1–19
- [27] LU, Feng; MILIOS, Evangelos: Globally consistent range scan alignment for environment mapping. In: *Autonomous robots* 4 (1997), Nr. 4, S. 333–349
- [28] MARQUARDT, Donald W.: An algorithm for least-squares estimation of nonlinear parameters. In: *Journal of the society for Industrial and Applied Mathematics* 11 (1963), Nr. 2, S. 431–441
- [29] MAUCH, Sean P.: *Efficient algorithms for solving static Hamilton-Jacobi equations*. California Institute of Technology, 2003
- [30] MCCORMAC, John; CLARK, Ronald; BLOESCH, Michael; DAVISON, Andrew; LEUTENECKER, Stefan: Fusion++: Volumetric object-level slam. In: *2018 international conference on 3D vision (3DV)* IEEE, 2018
- [31] MONTEMERLO, Michael; THRUN, Sebastian; KOLLER, Daphne; WEGBREIT, Ben u. a.: FastSLAM: A factored solution to the simultaneous localization and mapping problem. In: *Aaaai/iaai 593598* (2002)
- [32] MONTEMERLO, Michael; THRUN, Sebastian; KOLLER, Daphne; WEGBREIT, Ben u. a.: FastSLAM 2.0: An improved particle filtering algorithm for simultaneous localization and mapping that provably converges. In: *IJCAI* Bd. 3, 2003
- [33] NOTO, Masato; SATO, Hiroaki: A method for the shortest path search by extended Dijkstra algorithm. In: *Smc 2000 conference proceedings. 2000 ieee international conference on systems, man and cybernetics.'cybernetics evolving to systems, humans, organizations, and their complex interactions'(cat. no. 0* Bd. 3 IEEE, 2000
- [34] NOVOTNY, P.; SRAMEK, M.: Representation of objects with sharp details in truncated distance fields. In: *Fourth International Workshop on Volume Graphics, 2005.*, 2005

- [35] PRISACARIU, Victor A.; KÄHLER, Olaf; GOLODETZ, Stuart; SAPIENZA, Michael; CAVALLARI, Tommaso; TORR, Philip H.; MURRAY, David W.: Infinitam v3: A framework for large-scale 3d reconstruction with loop closure. In: *arXiv preprint arXiv:1708.00783* (2017)
- [36] RUSU, Radu B.; COUSINS, Steve: 3d is here: Point cloud library (pcl). In: *2011 IEEE international conference on robotics and automation* IEEE, 2011
- [37] SCHULTZ, Jarvis: *tf*. <http://wiki.ros.org/tf>. – zuletzt abgerufen am: 09.10.2022
- [38] SEGAL, Aleksandr; HAEHNEL, Dirk; THRUN, Sebastian: Generalized-icp. In: *Robotics: science and systems* Bd. 2 Seattle, WA, 2009
- [39] SHAN, Tixiao; ENGLOT, Brendan: Lego-loam: Lightweight and ground-optimized lidar odometry and mapping on variable terrain. In: *2018 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* IEEE, 2018
- [40] SHAN, Tixiao; ENGLOT, Brendan; MEYERS, Drew; WANG, Wei; RATTI, Carlo; RUS, Daniela: Lio-sam: Tightly-coupled lidar inertial odometry via smoothing and mapping. In: *2020 IEEE/RSJ international conference on intelligent robots and systems (IROS)* IEEE, 2020
- [41] SPRICKERHOF, Jochen; NÜCHTER, Andreas; LINGEMANN, Kai; HERTZBERG, Joachim: A heuristic loop closing technique for large-scale 6d slam. In: *Automatika* 52 (2011), Nr. 3, S. 199–222
- [42] TAKETOMI, Takafumi; UCHIYAMA, Hideaki; IKEDA, Sei: Visual SLAM algorithms: A survey from 2010 to 2016. In: *IPSJ Transactions on Computer Vision and Applications* 9 (2017), Nr. 1, S. 1–11
- [43] TSINTOTAS, Konstantinos A.; BAMPIS, Loukas; GASTERATOS, Antonios: The Revisiting Problem in Simultaneous Localization and Mapping: A Survey on Visual Loop Closure Detection. In: *IEEE Transactions on Intelligent Transportation Systems* (2022)
- [44] WERNER, Diana; AL-HAMADI, Ayoub; WERNER, Philipp: Truncated signed distance function: experiments on voxel size. In: *International Conference Image Analysis and Recognition* Springer, 2014
- [45] WHELAN, Thomas; KAESZ, Michael; FALLON, Maurice; JOHANSSON, Hordur; LEONARD, John; McDONALD, John: Kintinuous: Spatially extended kinectfusion. (2012)
- [46] XIE, Linhai; WANG, Sen; MARKHAM, Andrew; TRIGONI, Niki: GraphTinker: Outlier rejection and inlier injection for pose graph SLAM. In: *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)* IEEE, 2017
- [47] YANG, H.; SHI, J.; CARLONE, L.: TEASER: Fast and Certifiable Point Cloud Registration. In: *IEEE Trans. Robotics* (2020)

- [48] ZHANG, Ji; SINGH, Sanjiv: LOAM: Lidar odometry and mapping in real-time. In: *Robotics: Science and Systems* Bd. 2 Berkeley, CA, 2014



Endpage für  
Unterschrift  
einbauen